Introducción a la epidemiología genómica y filogenética

Taller de secuenciación de genoma completo y análisis bioinformático de *Salmonella* spp.

Laboratorio de genómica y biología molecular, CNRIMA. Inciensa

Marzo de 2026

Epidemiología genómica

Epidemiología

- Estudio de la distribución, frecuencia y factores determinantes de las enfermedades existentes en poblaciones humanas definidas y la aplicación de este estudio para controlar los problemas de salud

Epidemiología genómica

- **Uso de datos genómicos** de patógenos para determinar la distribución y propagación de una enfermedad infecciosa en una población específica y la aplicación de esta información para controlar problemas de salud

Muchos estudios destacan la **utilidad de la epidemiología genómica frente a los métodos tradicionales** para la vigilancia de patógenos y la investigación de brotes

Nancy Chow, COVID-19 Genomic Epidemiology Toolkit: Module 1.1. What is genomic epidemiology?

Epidemiología genómica

La epidemiología genómica comprende:

- Vigilancia y tipificación de patógenos en el tiempo y el espacio

- Historia evolutiva (filogenética)

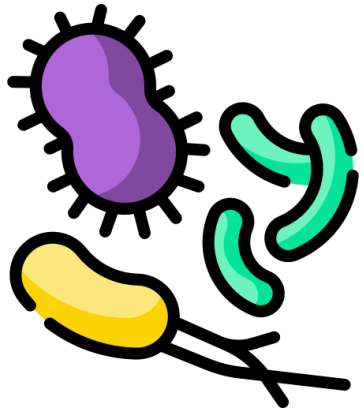

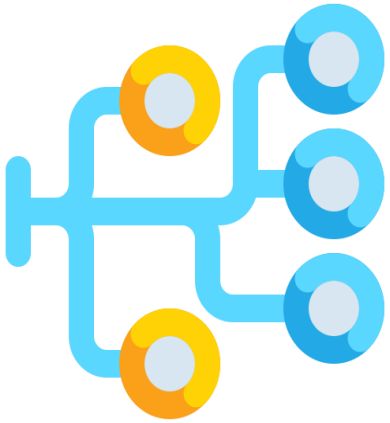

La epidemiología genómica facilita...

- La identificación de introducciones de nuevos patógenos
- La comprensión de la dinámica de transmisión
- La comprensión de la evolución de los patógenos

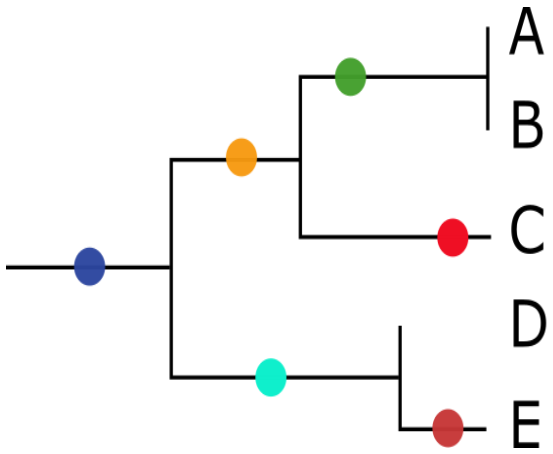

Proceso epidémico

Todos los casos de la cadena de transmisión representados en el tiempo

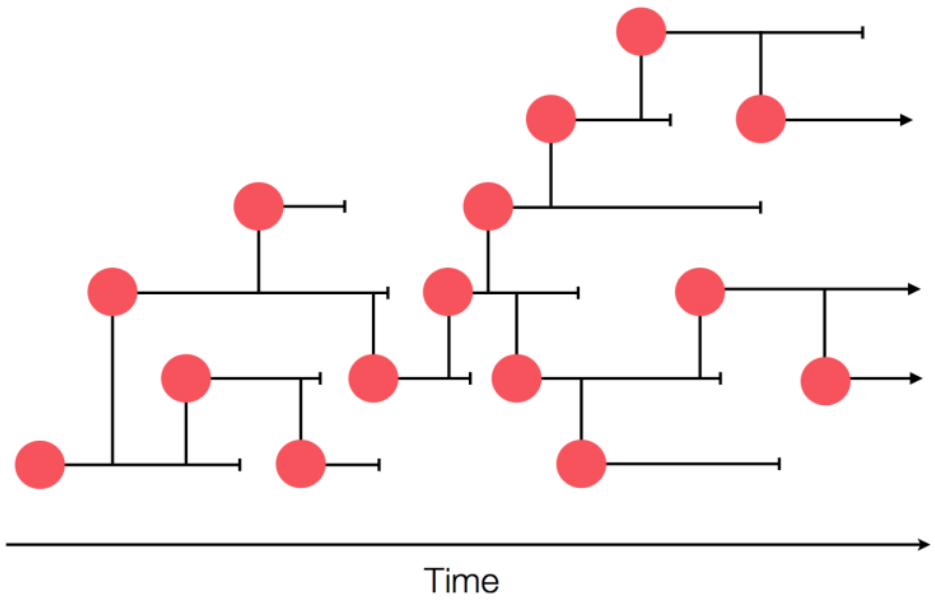

Individuos muestreados

Secuencias genómicas disponibles sólo para algunos casos

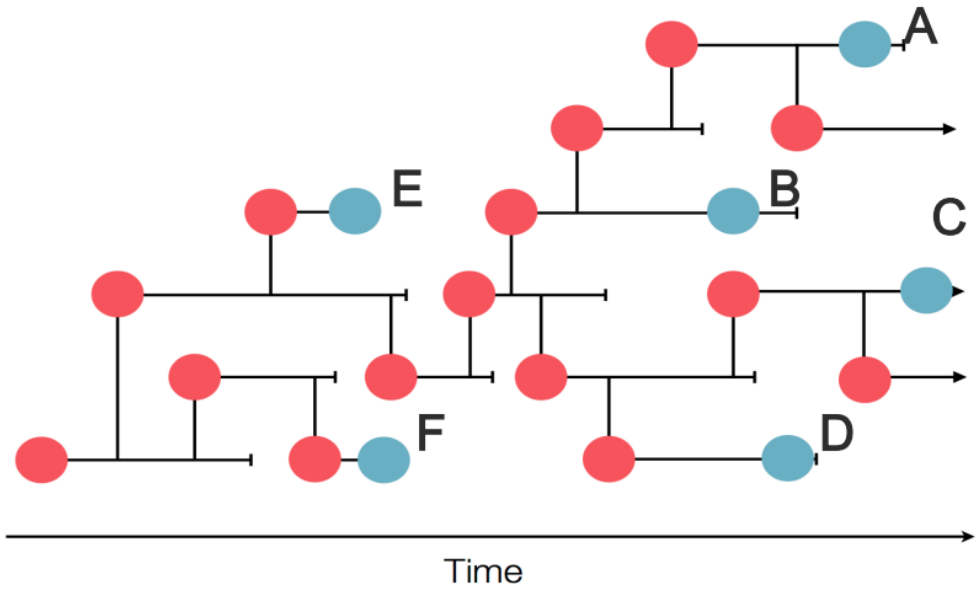

Image adapted from Trevor Bedford Group: https://docs.nextstrain.org

Secuencia del genoma

Por medio de la secuencias disponibles se pueden identificar conexiones

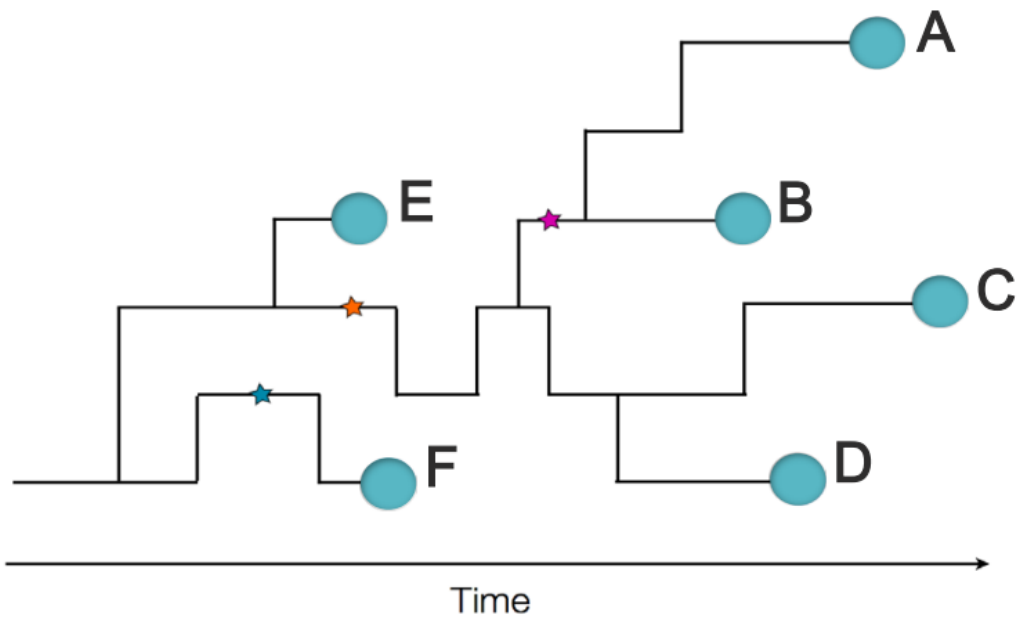

Determinar filogenia

Estas conexiones pueden ser representadas en un árbol filogenético

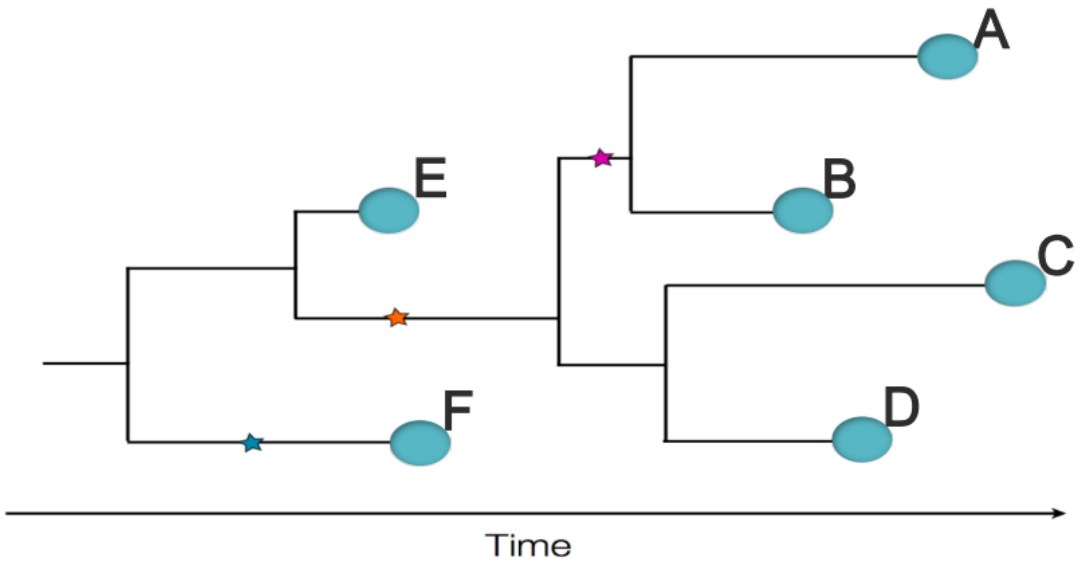

Usando la filogenética, esas relaciones se pueden visualizar como un "árbol" que <u>siempre es una aproximación</u> de la verdadera cadena de transmisión.

Image adapted from Trevor Bedford Group: https://docs.nextstrain.org

Introducción a la filogenética

¿Qué es un árbol filogenético?

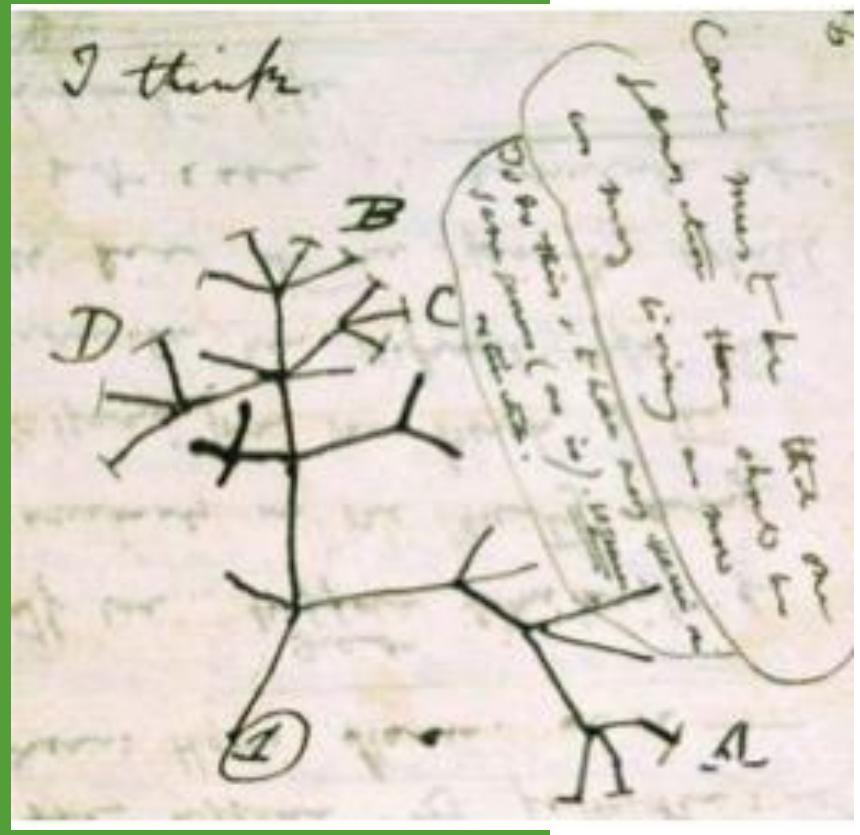

1837, Charles Darwin

- **Diagrama** utilizado para representar las **relaciones ancestrales** entre genes y organismos.
- Muestra qué genes/organismos están **más estrechamente relacionados** y cuáles están más **alejados**.
- **Si está enraizado**, también muestra la dirección del proceso evolutivo a lo largo del tiempo.

Análisis filogenético en la investigación de brotes epidémicos

- Evaluación de la **relación evolutiva** de un conjunto de muestras como un indicador de la **probabilidad de transmisión** de enfermedades infecciosas
  - La secuenciación y la bioinformática ofrecen una comprensión de **alta resolución** de la relación genética

Muchos enfoques disponibles para realizar análisis filogenéticos

Construyendo árboles filogenéticos

Steps to Build a Phylogeny (Very Simplified)

FASTQ

FASTA

1. Define the objective: What evolutionary question do you want to answer?

2. Define the dataset: Select appropriate sequences based on the question.

3. Obtain sequences: Scientific articles; public databases such as NCBI, Ensembl, UniProt, GISAID.

4. Align sequences: you could use MAFFT; verify and correct alignment (Aliview).

5. Reconstruct the phylogenetic tree: Recommended software: IQ-TREE.

6. Evaluate tree reliability: Perform bootstrap or other support analyses; interpret node support values.

7. Visualize and export the tree: Tools like FigTree, iTOL, Dendroscope; adjust labels, colors, and branches.

8. Interpret results: Relate findings to the original question and available epidemiological information.

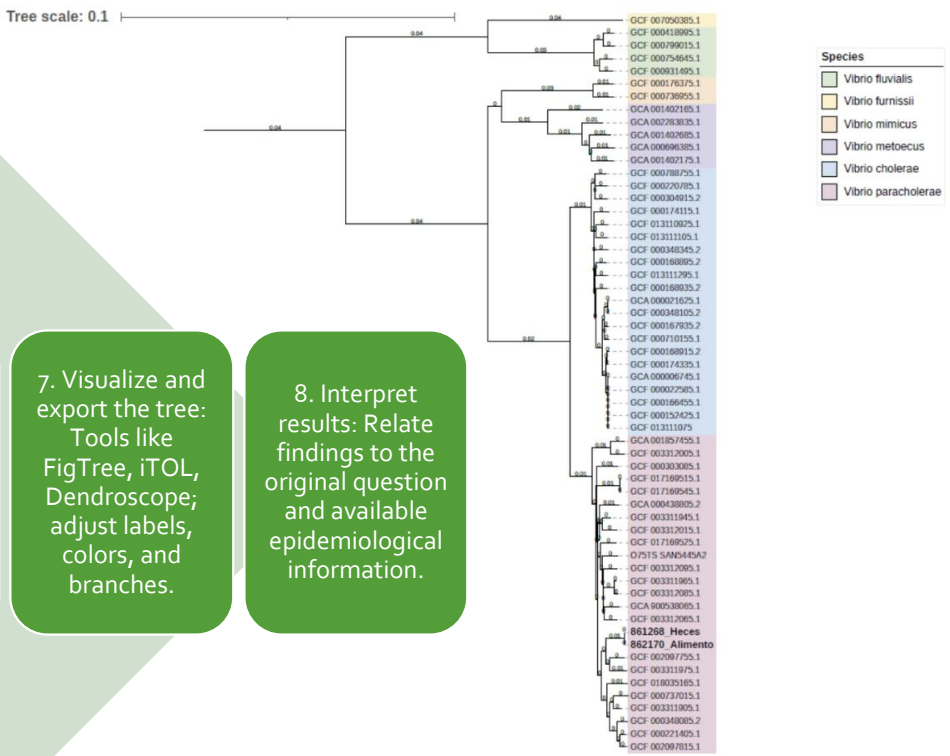

9. Comunicate the results.

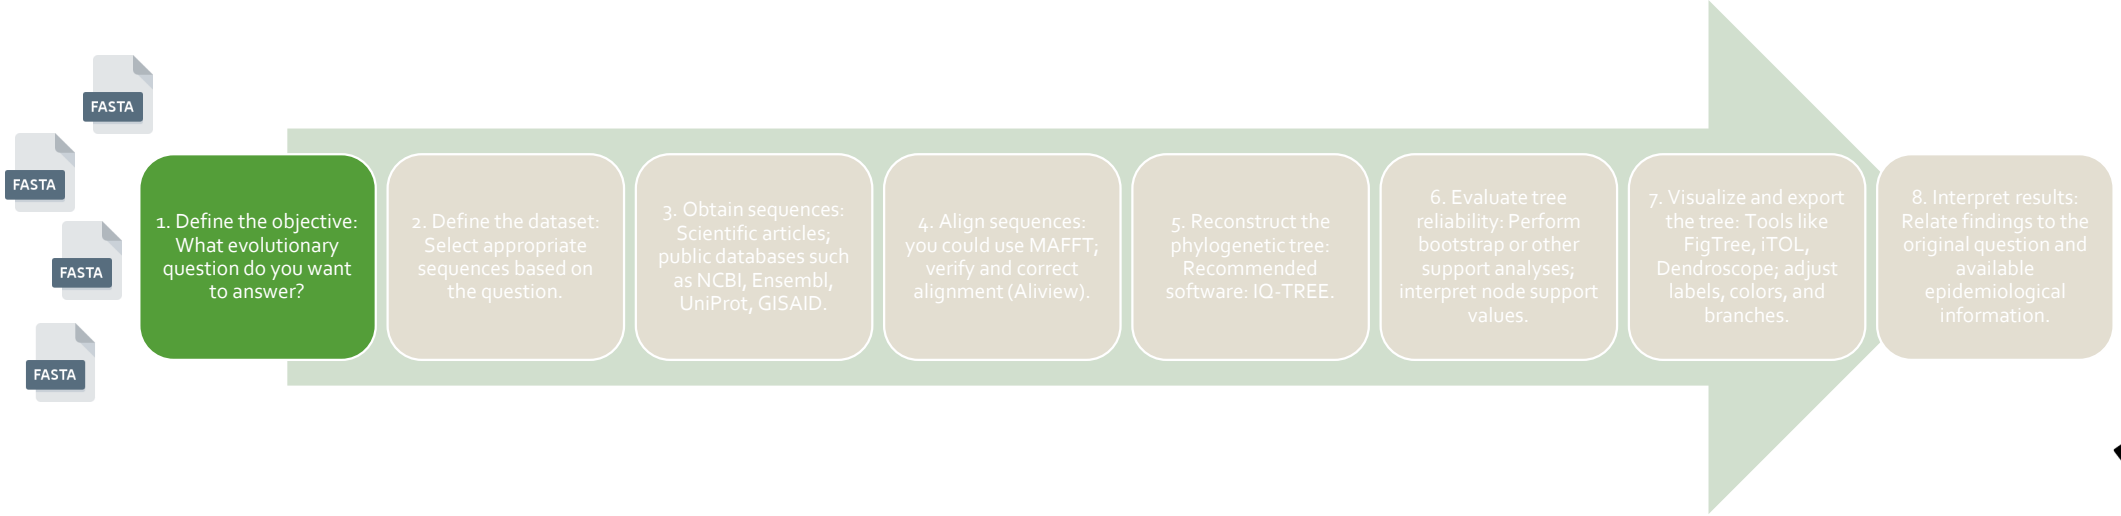

Tipo de actividad:
Secuenciación de genoma completo y análisis bioinformático de las muestras Inciensa # 861268 y # 862170 correspondientes a cepas bacterianas identificadas como *V. cholerae,* aisladas a partir de una muestra clínica de heces de paciente y de una muestra de licuado de verduras respectivamente, ambas muestras estaban asociadas a un evento de enfermedad diarreica aguda ocurrido en el centro de cuido Fundación [redacted] a finales de abril del año en 2025.

Cuadro 1. Identificación a nivel de especie de las secuencias obtenidas por cuatro herramientas bioinformáticas diferentes.

	Herramienta bioinformática			
Muestra	**ani_top_species_match**	**gambit_predicted_taxon**	**kmerfinder_top_hit**	**Ribosomal MLST**
861268	*Vibrio_cholerae*	*Vibrio paracholerae*	*Vibrio cholerae*	*Vibrio paracholerae*
862170	*Vibrio_cholerae*	*Vibrio paracholerae*	*Vibrio cholerae*	*Vibrio paracholerae*

- ¿La muestra del paciente y de alimento están geneticamente relacionadas entre sí?.
- ¿Cuál es la identificación a nivel de especie del aislamiento?

FASTA

FASTA

FASTA

FASTA

1. Define the objective: What evolutionary question do you want to answer?

2. Define the dataset: Select appropriate sequences based on the question.

3. Obtain sequences: Scientific articles; public databases such as NCBI, Ensembl, UniProt, GISAID.

4. Align sequences: you could use MAFFT; verify and correct alignment (Aliview).

5. Reconstruct the phylogenetic tree: Recommended software: IQ-TREE.

6. Evaluate tree reliability: Perform bootstrap or other support analyses; interpret node support values.

7. Visualize and export the tree: Tools like FigTree, iTOL, Dendroscope; adjust labels, colors, and branches.

8. Interpret results: Relate findings to the original question and available epidemiological information.

AMERICAN SOCIETY FOR MICROBIOLOGY | Applied and Environmental Microbiology®

MICROBIAL ECOLOGY
September 2021 Volume 87 Issue 17 e00422-21
https://doi.org/10.1128/AEM.00422-21

Population Analysis of *Vibrio cholerae* in Aquatic Reservoirs Reveals a Novel Sister Species (*Vibrio paracholerae* sp. nov.) with a History of Association with Humans

Mohammad Tarequl Islam [a], Tania Nasreen[a], Paul C. Kirchberger [b], Kevin Y. H. Liang [a], Fabini D. Orata [a], Fatema-Tuz Johura[c], Nora A. S. Hussain [a], Monica S. Im[d], Cheryl L. Tarr[d], Munirul Alam[c], Yann F. Boucher [a,e]

[a]Department of Biological Sciences, University of Alberta, Edmonton, Alberta, Canada
[b]Department of Integrative Biology, University of Texas at Austin, Austin, Texas, USA
[c]Infectious Diseases Division, International Centre for Diarrheal Disease Research, Bangladesh (icddr,b), Dhaka, Bangladesh
[d]National Center for Emerging and Zoonotic Infectious Diseases, Centers for Disease Control and Prevention, Atlanta, Georgia, USA
[e]Saw Swee Hock School of Public Health, National University of Singapore, Singapore

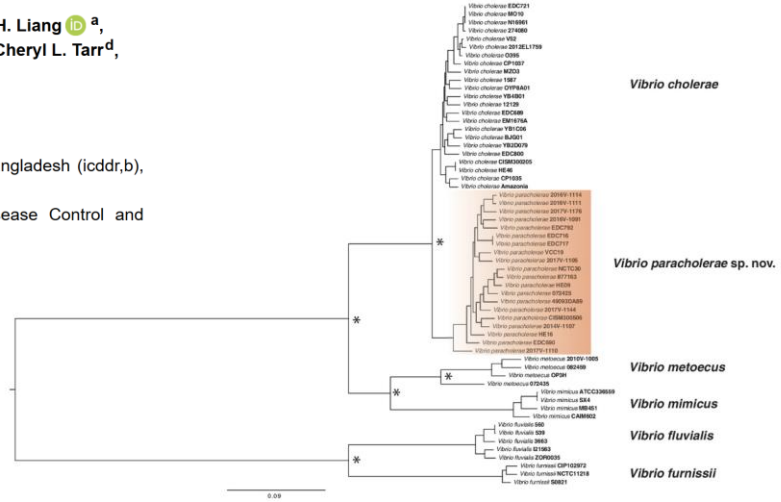

FIG 5 Whole-genome phylogenetic tree of *Vibrio paracholerae* along with its closest relatives. The maximum likelihood phylogenetic tree was constructed from the core genome alignment of ≈2.1 Mbp using the GTR gamma substitution model. Corresponding nodes with relevant bootstrap support over 70% from the 100 replicates were indicated with an asterisk (*). The scale bar represents nucleotide substitutions per site.

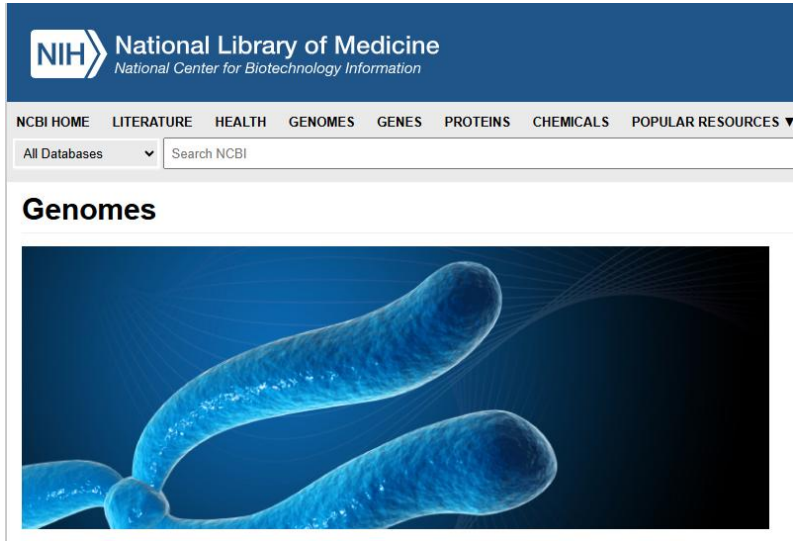

¿Qué secuencias deben incluirse en un árbol filogenético?

- Las secuencias que debes incluir en un árbol filogenético dependen de la pregunta epidemiológica que estés tratando de responder:

  - ¿Estas secuencias representan un brote?

Incluir todas las secuencias de alta calidad de un ST específico

  - ¿Estas secuencias forman parte de un brote en curso?

Incluir todas las secuencias de alta calidad del genotipo conocido, además de algunas secuencias que se sabe que son parte del brote

  - Esta secuencia pertenece a un genotipo nuevo?

Incluir secuencias de alta calidad de múltiples genotipos

  - Sin pregunta, simplemente descriptivo

Incluir todas las secuencias de alta calidad de la especie que estás tratando de describir

La selección de la muestra es fundamental

- Es fundamental disponer de **muestras de alta calidad que aprueben los umbrales de control de calidad**
- Se necesitan muestras que puedan responder a la pregunta que se desea abordar
- Para los análisis de brotes, las muestras deben estar taxonómicamente relacionadas
  - **Misma especie**
  - Normalmente el **mismo ST** (MLST) o linaje
    - (No serotipo, perfiles AMR, etc., ya que son fenotipos)

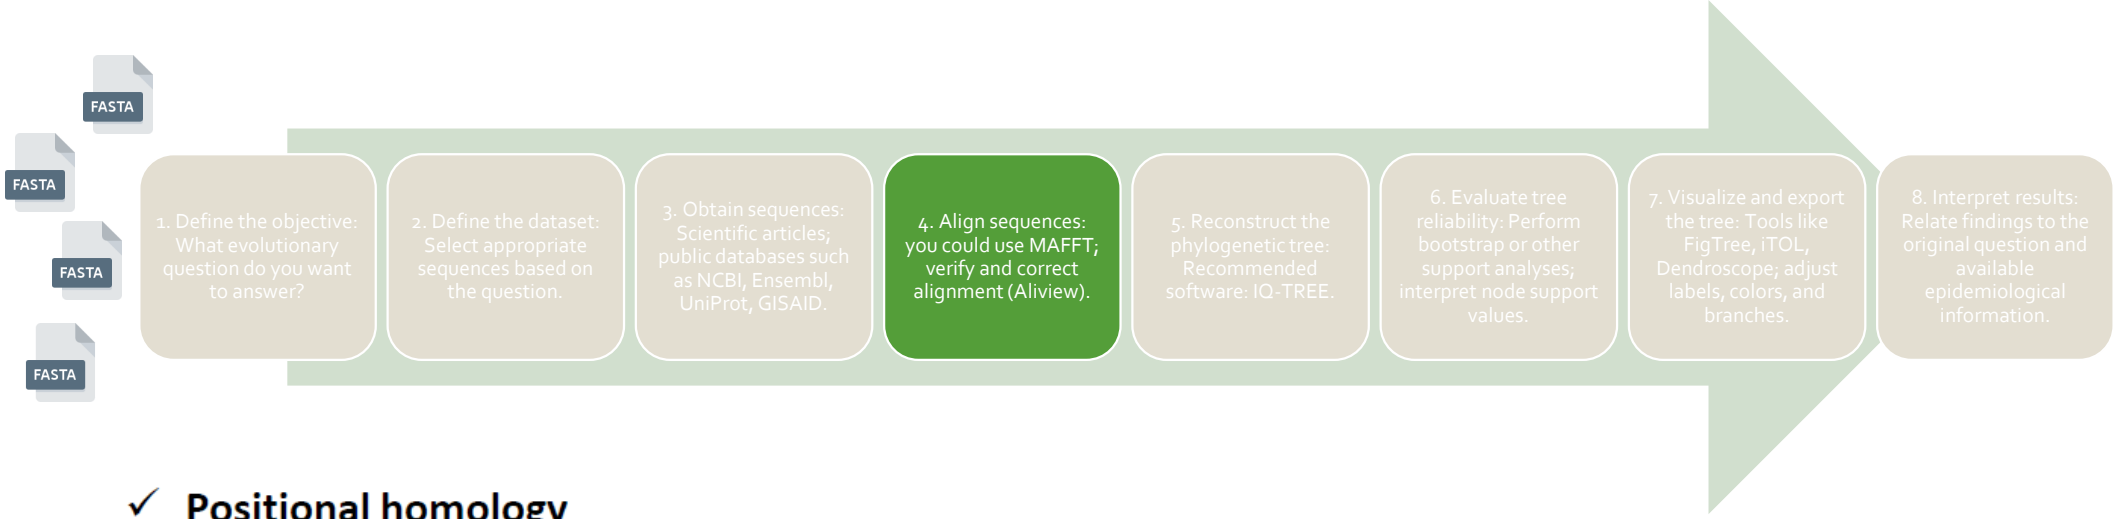

✓ Positional homology

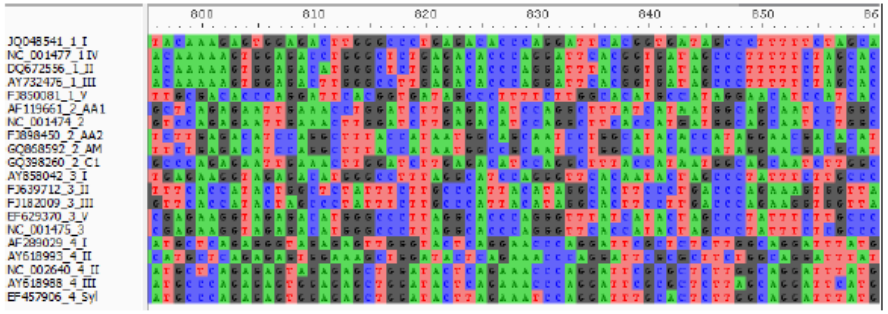

Non-aligned sequences

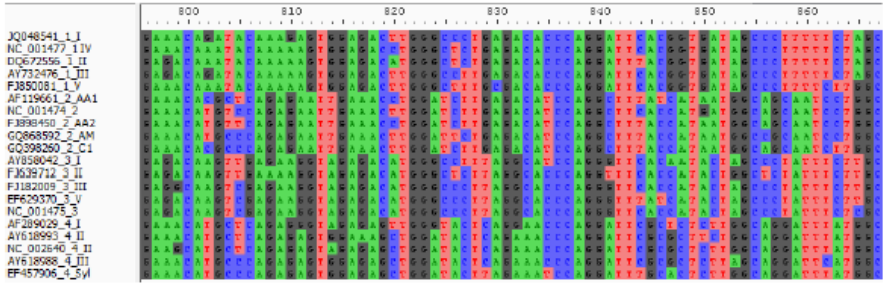

Aligned sequences

- Los nts o AA encontrados en una posición (columna) en las secuencias se consideran descendientes de un sitio ancestral común (homólogo).
- Todos los métodos intentan maximizar las coincidencias / similitudes y minimizar las discrepancias / diferencias entre secuencias.
- Diferentes programas buscan la "mejor" alineación a través de diferentes métodos.

Carolina Torres, Introduction to multiple sequence alignments. Viral Genomics and Bioinformatics.

Programas para construir alineamientos

ClustalW/X: Progressive alignment.

Muscle: Iterative method.

MAFFT: multiple methods.

T-Coffee

ProbCons

Probalign

Alineamiento de secuencias múltiples
Multiple sequence alignment (MSA)

Genetic relatedness (SNP differences)

	2016K-0438	PNUSAS010651	PNUSAS011968	PNUSAS013510	PNUSAS013903	PNUSAS013904	PNUSAS013905
2016K-0438	0	35	37	36	25	28	26
PNUSAS010651	35	0	2	41	31	35	34
PNUSAS011968	37	2	0	41	30	34	33
PNUSAS013510	36	41	41	0	28	33	30
PNUSAS013903	25	31	30	28	0	1	1
PNUSAS013904	28	35	34	33	1	0	2
PNUSAS013905	26	34	33	30	1	2	0

Phylogenetic trees

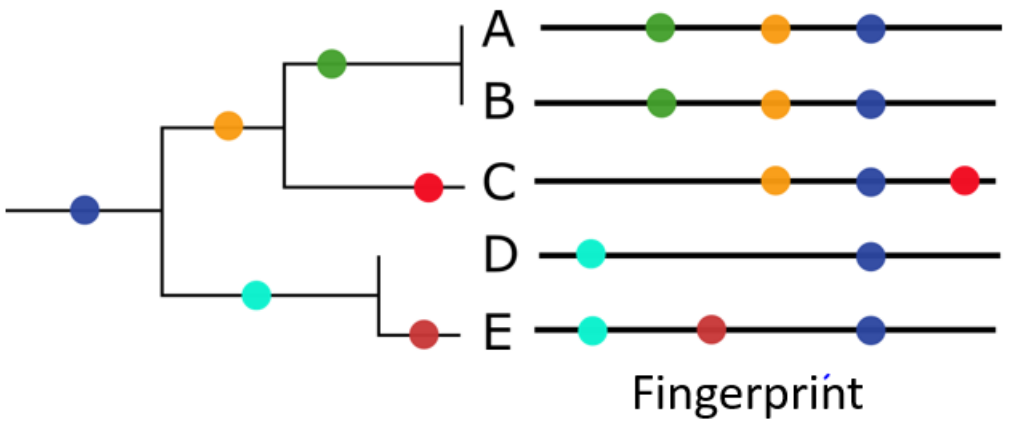

MichaelWeigand, COVID-19 Genomic Epidemiology Toolkit: Module 1.3. How to read a phylogenetic tree

Matrices de SNP

- Una matriz de SNP es otra forma de visualizar las diferencias entre secuencias de genomas completos

- En lugar de tener la divergencia entre muestras mostrada como longitudes de rama, una matriz de SNP te dará el número de SNP que diferencian cada par de muestras ("matriz de SNP por pares")

	S1	S2	S3	S4	S5	S6	S7	S8	S9	S10	S11	S12	S13	S14	S15	S16	S17	S18	S19	S20
S1	0	0	0	0	0	0	2	2	3	3	8	5	6	6	1	1	2	2	2	1
S2	0	0	0	0	0	0	2	2	3	3	8	5	6	6	1	1	2	2	2	1
S3	0	0	0	0	0	0	2	2	3	3	8	5	6	6	1	1	2	2	2	1
S4	0	0	0	0	0	0	2	2	3	3	8	5	6	6	1	1	2	2	2	1
S5	0	0	0	0	0	0	2	2	3	3	8	5	6	6	1	1	2	2	2	1
S6	0	0	0	0	0	0	2	2	3	3	8	5	6	6	1	1	2	2	2	1
S7	2	2	2	2	2	2	0	2	3	3	8	5	6	6	1	1	0	0	0	1
S8	2	2	2	2	2	2	2	0	1	1	6	3	4	4	1	1	2	2	2	3
S9	3	3	3	3	3	3	3	1	0	0	5	2	3	3	2	2	3	3	3	4
S10	3	3	3	3	3	3	3	1	0	0	5	2	3	3	2	2	3	3	3	4
S11	8	8	8	8	8	8	8	6	5	5	0	3	4	4	7	7	8	8	8	9
S12	5	5	5	5	5	5	5	3	2	2	3	0	1	1	4	4	5	5	5	6
S13	6	6	6	6	6	6	6	4	3	3	4	1	0	0	5	5	6	6	6	7
S14	6	6	6	6	6	6	6	4	3	3	4	1	0	0	5	5	6	6	6	7
S15	1	1	1	1	1	1	1	1	2	2	7	4	5	5	0	0	1	1	1	2
S16	1	1	1	1	1	1	1	1	2	2	7	4	5	5	0	0	1	1	1	2
S17	2	2	2	2	2	2	0	2	3	3	8	5	6	6	1	1	0	0	0	1
S18	2	2	2	2	2	2	0	2	3	3	8	5	6	6	1	1	0	0	0	1
S19	2	2	2	2	2	2	0	2	3	3	8	5	6	6	1	1	0	0	0	1
S20	1	1	1	1	1	1	1	3	4	4	9	6	7	7	2	2	1	1	1	0

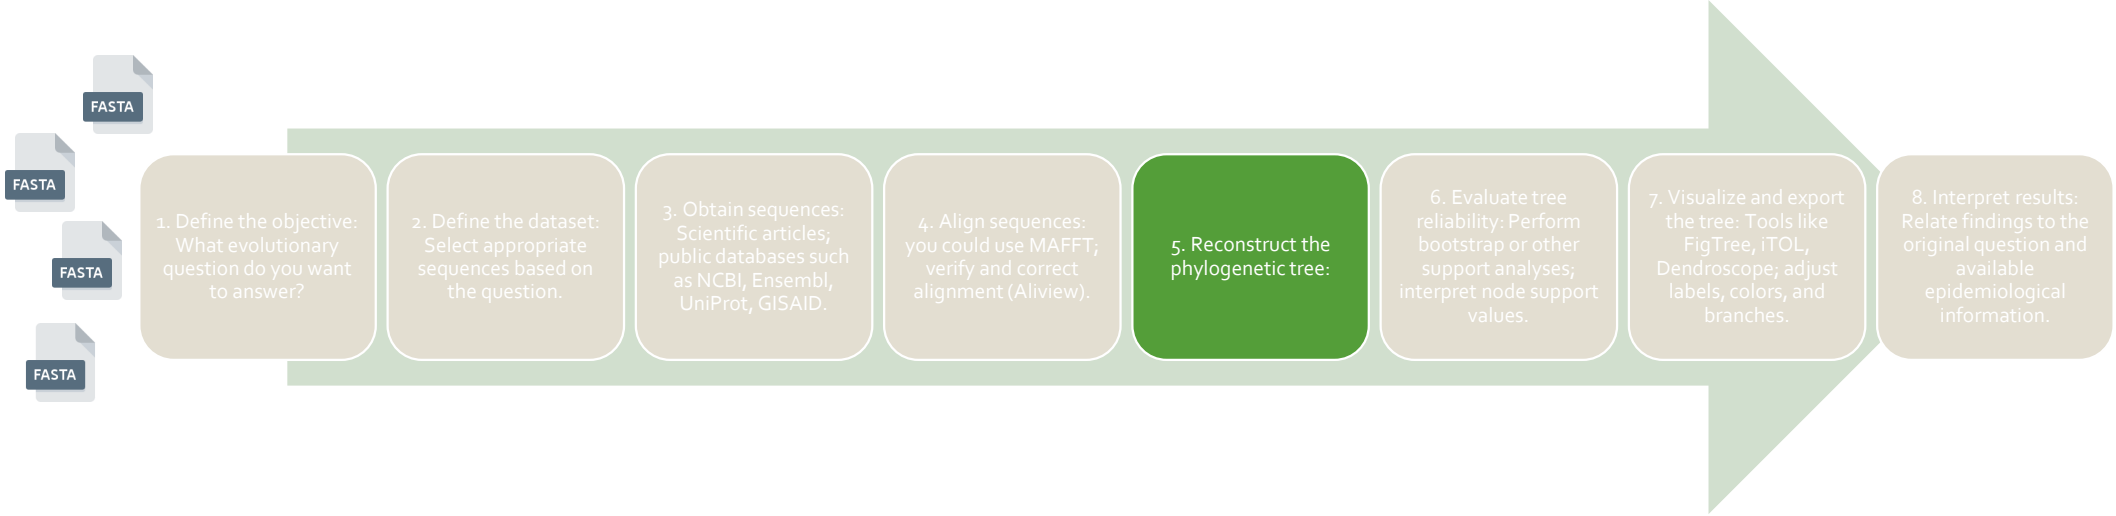

Enfoques de análisis filogenético

Enfoque general de la filogenética

1. **Identificar las diferencias genéticas** entre las muestras de un conjunto de datos
2. **Opcional: Enmascarar** las diferencias que probablemente no procedan de relaciones ancestrales
3. Utilizar estas diferencias para **inferir relaciones evolutivas**

Muchas maneras de hacer cada cosa

Análisis filogenético

1. Identificación de diferencias genéticas

- **Polimorfismo de un solo nucleótido (SNP)**
  - Identificación de variaciones nucleotídicas
- **Core/whole-genome Multilocus sequence types (cg/wgMLST)**
  - Identificación de variaciones alélicas

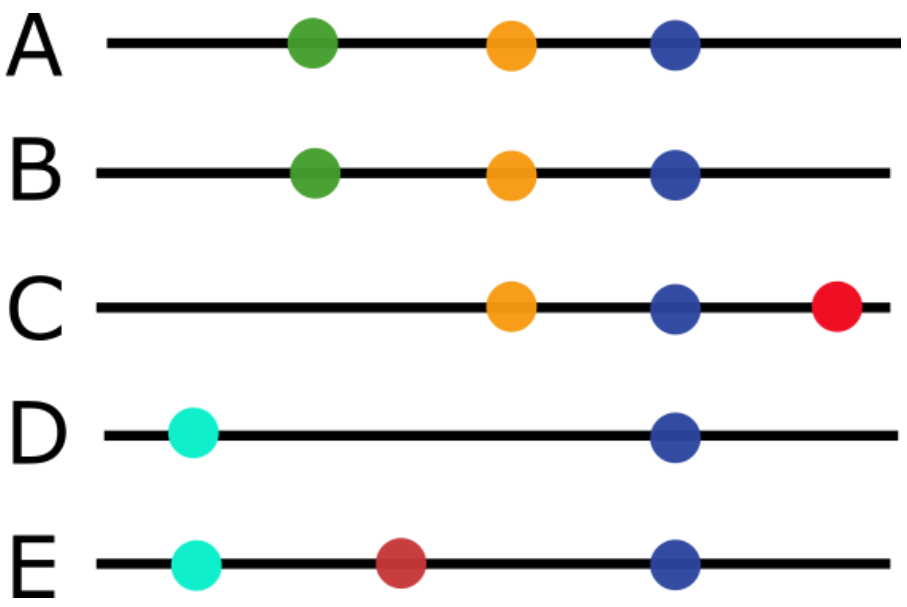

Unidad básica de diferencia: SNPs (polimorfismos de nucleótido único)

- SNP = Single Nucleotide Polymorphism
  - Secuencia: ATGTT**C**CTC
  - Referencia: ATGTT**G**CTC
- Los SNP ocurren en todo el genoma, con frecuencia variada:

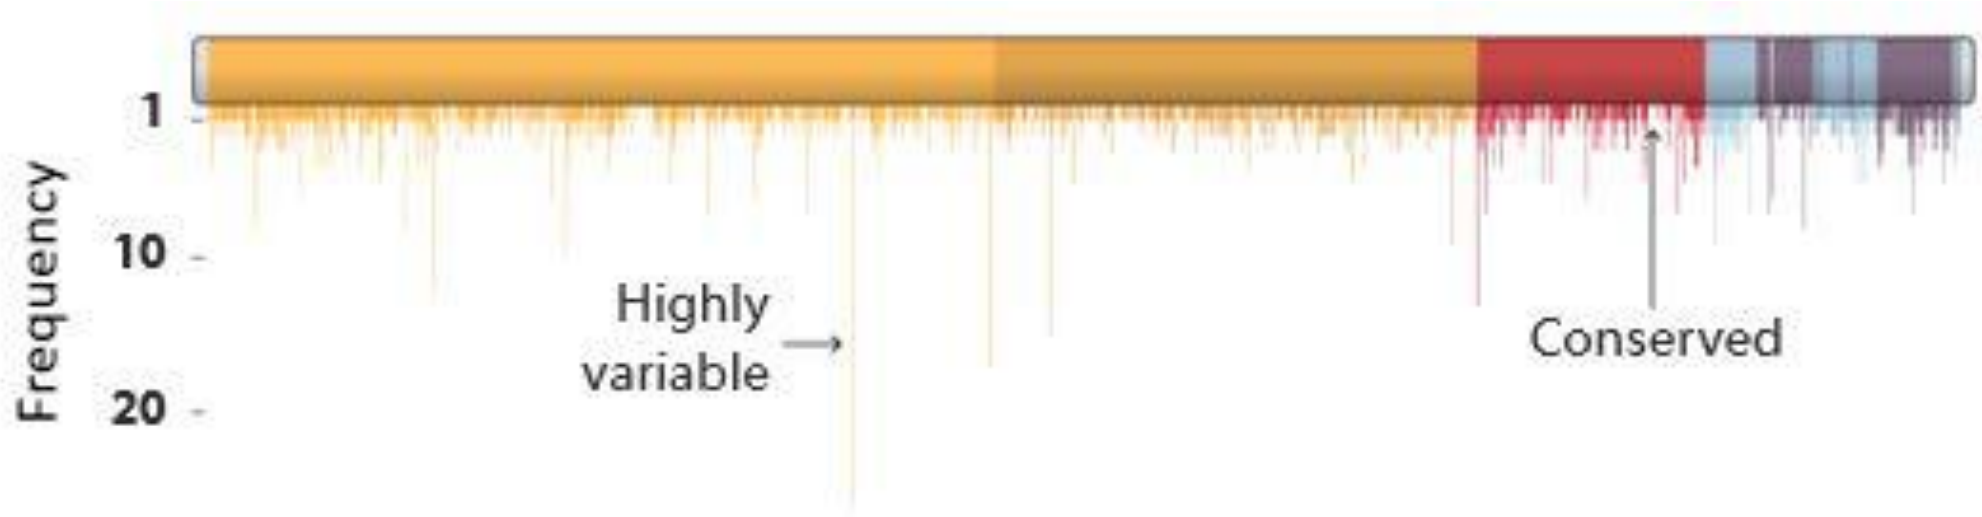

MichaelWeigand, COVID-19 Genomic Epidemiology Toolkit: Module 1.3. How to read a phylogenetic tree

cgMLST

Muestra X
Lecturas de secuenciación

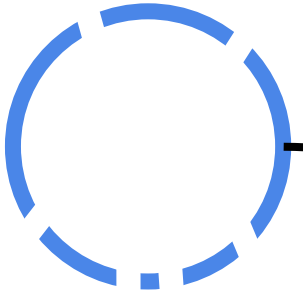

Muestra X
Ensamblaje del genome

Base de datos de secuencias alélicas de referencia

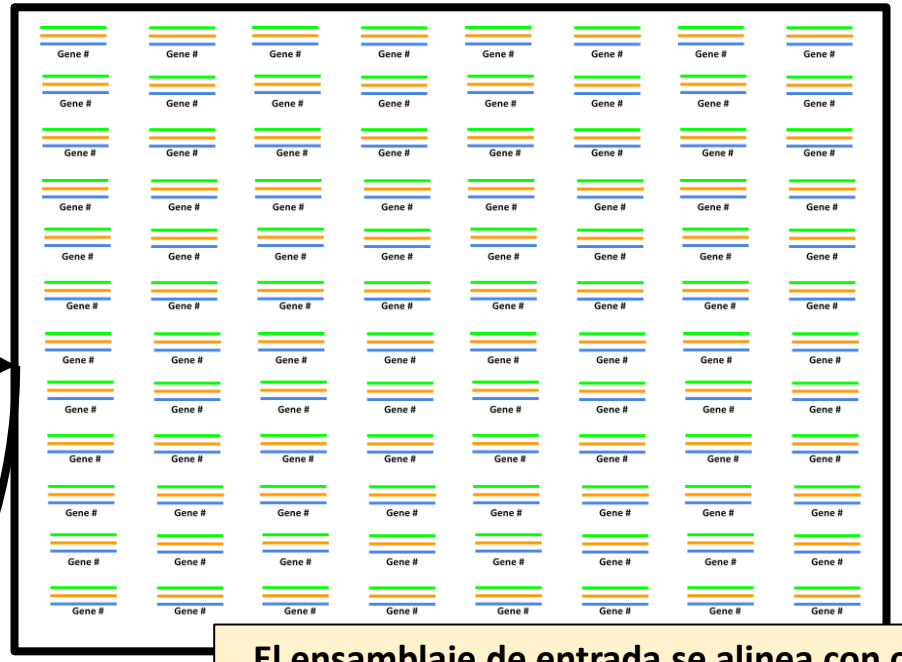

El ensamblaje de entrada se alinea con cada conjunto de alelos de referencia para todos los genes que se encuentran dentro del genoma central para caracterizar la muestra

"Perfil alélico de la muestra X: 1-2-1-3-3-….."

	Gen 1	Gen 2	Gen 3	Gen 4	Gen 5	Gen ….
Muestra X	Alelo 1	Alelo 2	Alelo 1	Alelo 3	Alelo 3	Alelo ….

Análisis filogenético

2. Opcional: Enmascarar las diferencias que probablemente no se deban a relaciones ancestrales

- **Recombinación**
- **Posibles desajustes en regiones repetitivas**
- **Regiones accesorias del genoma**

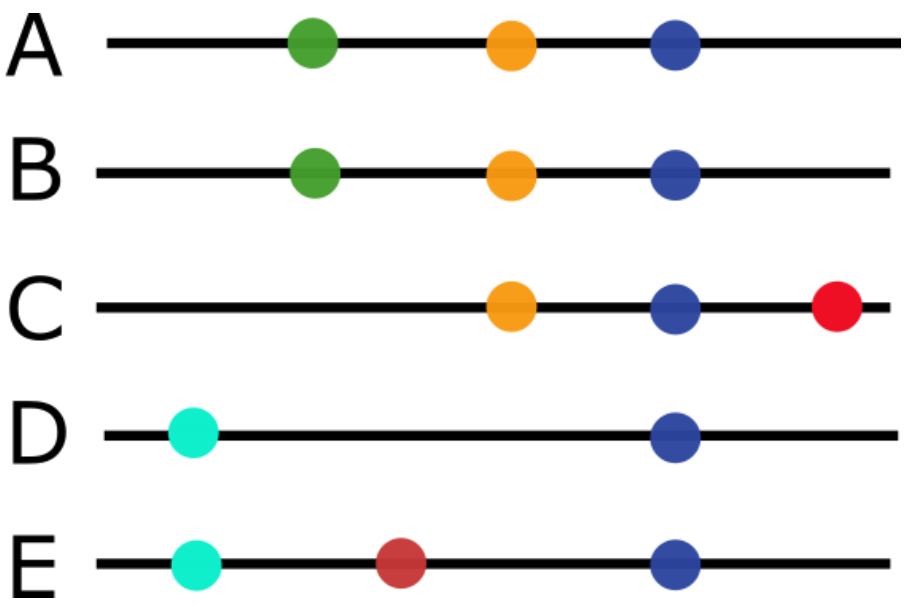

Análisis filogenético

Utiliza un **modelo matemático** para predecir cómo evolucionó probablemente la secuencia e inferir el árbol

3. Inferir relaciones evolutivas

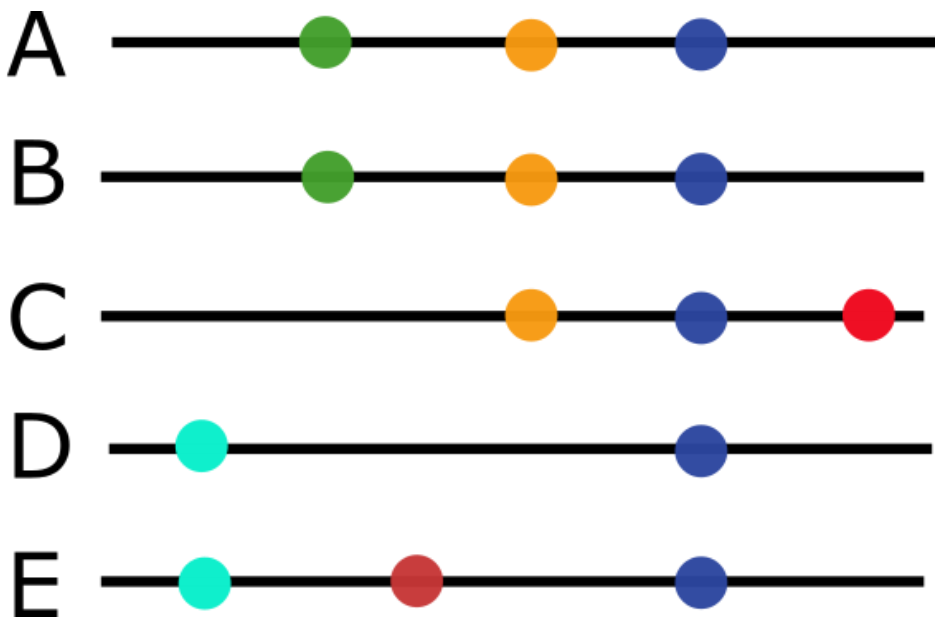

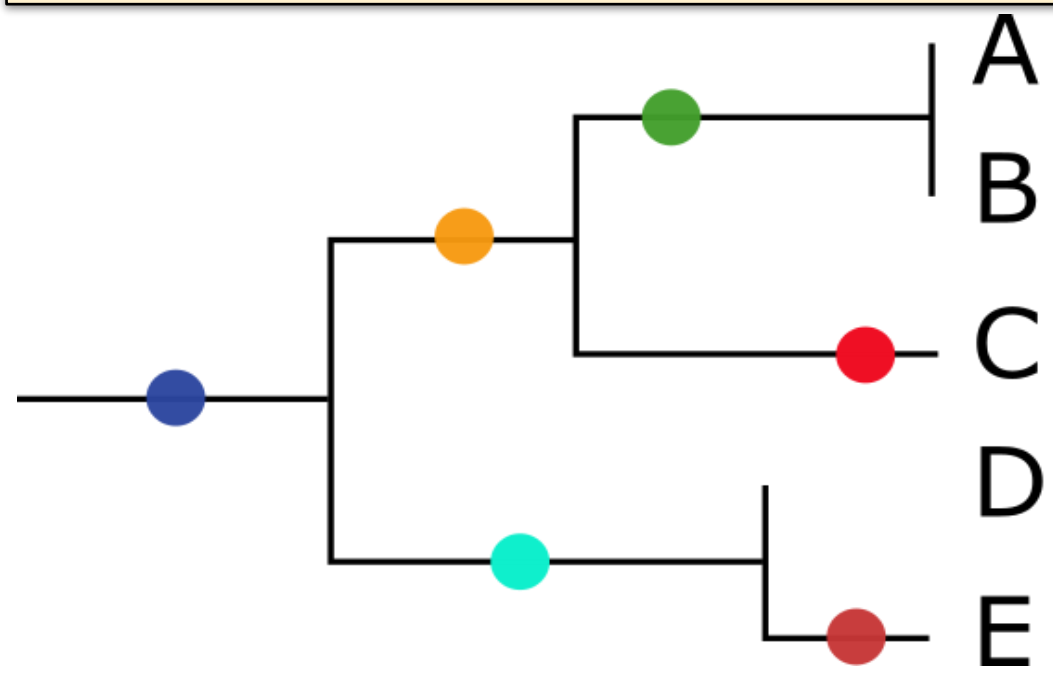

Phylogenetic analysis

Evolutionary history of the population

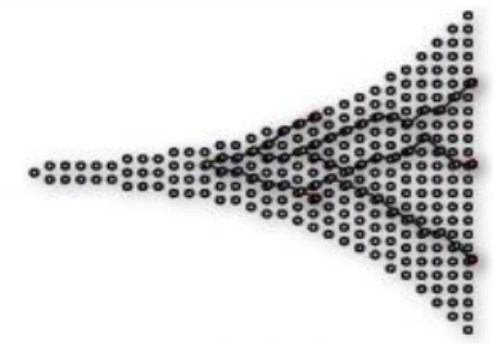

Sequences
(from some individuals of the population)

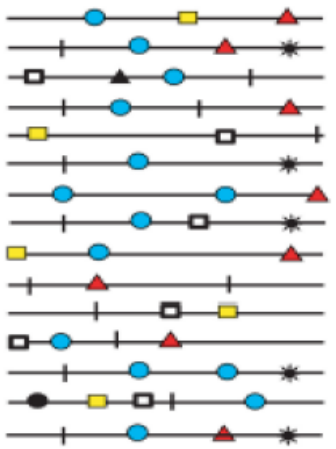

Genomes contain information about their origin

Models and methods are used to retrieve this information

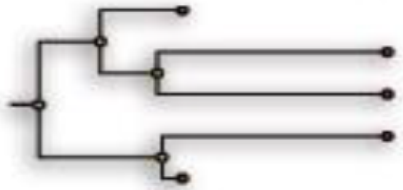

EVOLUTIONARY HYPOTHESIS

Phylogenetic analysis allows us to reconstruct the evolutionary history and study the processes that gave rise to it.

3. Inferir relaciones evolutivas

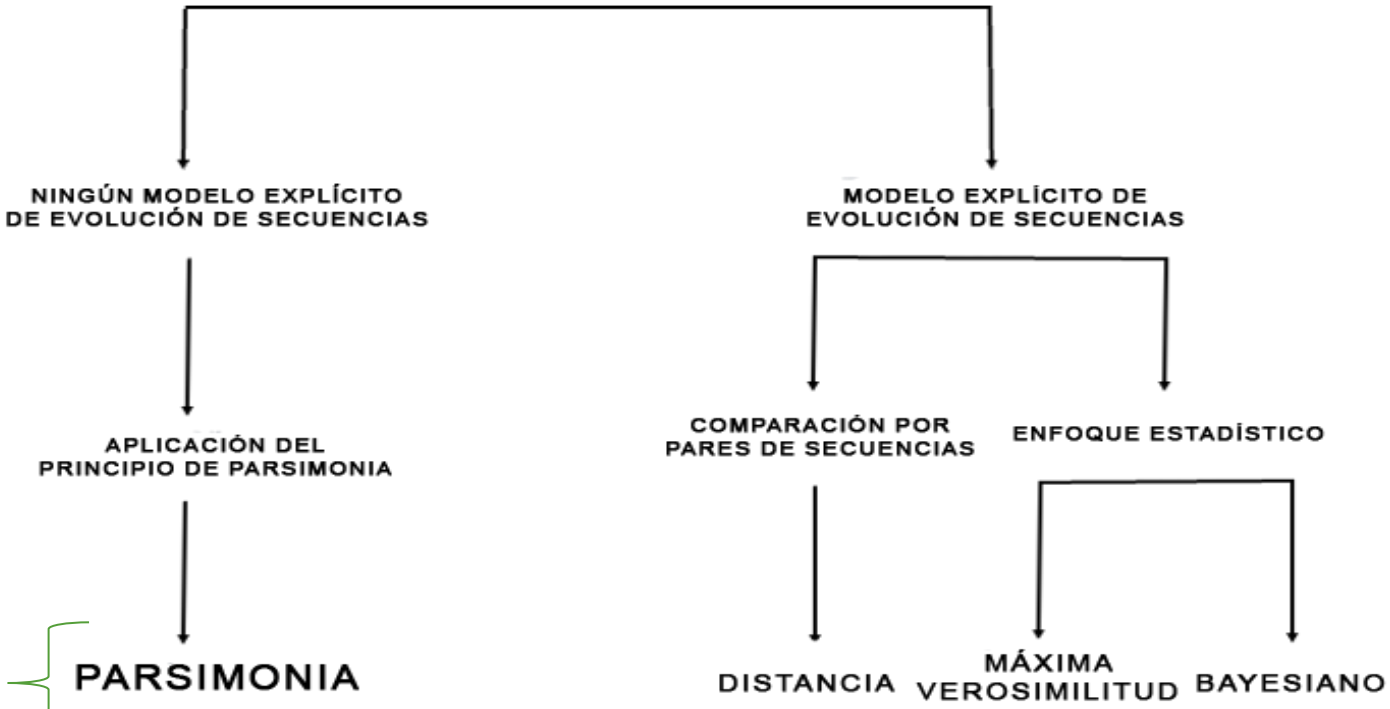

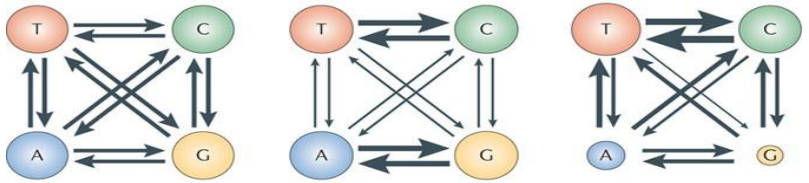

MODELOS SELECCIONADOS DE EVOLUCIÓN DEL ADN UTILIZADOS A MENUDO EN FILOGENÉTICA MOLECULAR

MODELO	PARÁMETROS DE INTERCAMBIABILIDAD	PARÁMETROS DE FRECUENCIA BASE	REFERENCIA
JC69 (or JC)	$a = b = c = d = e = f$	$\pi_A = \pi_C = \pi_G = \pi_T = 0.25$	Jukes and Cantor (1969)[9]
F81	$a = b = c = d = e = f$	all π_i values free	Felsenstein (1981)[32]
K2P (or K80)	$a = c = d = f$ (TRANSVERSIONES), $b = e$ (TRANSICIONES)	$\pi_A = \pi_C = \pi_G = \pi_T = 0.25$	Kimura (1980)[33]
HKY85	$a = c = d = f$ (TRANSVERSIONES), $b = e$ (TRANSICIONES)	all π_i VALORES LIBRES	Hasegawa et al. (1985)[34]
K3ST (or K81)	$a = f$ (γ TRANSVERSIONES), $c = d$ (β TRANSVERSIONES), $b = e$ (TRANSICIONES)	$\pi_A = \pi_C = \pi_G = \pi_T = 0.25$	Kimura (1981)[35]
TN93	$a = c = d = f$ (TRANSVERSIONES), b ($A \leftrightarrow G$ TRANSICIONES), e ($C \leftrightarrow T$ TRANSICIONES)	all π_i VALORES LIBRES	Tamura and Nei (1993)[36]
SYM	TODOS LOS PARÁMETROS DE INTERCAMBIABILIDAD LIBRES	$\pi_A = \pi_C = \pi_G = \pi_T = 0.25$	Zharkikh (1994)[37]
GTR (or REV[28])	TODOS LOS PARÁMETROS DE INTERCAMBIABILIDAD LIBRES	all π_i VALORES LIBRES	Tavaré (1986)[26]

Clases de métodos de construcción de árboles: Modelos de inferencia

Method	Data used	Tree search	Evolutionary Model
Distance	Pairwise distance	Simple algorithm	Can be complex
Parsimony *	All sites	Mainly hill climbing	Simple
Maximum likelihood *	All sites	Hill climbing	Can be complex
Bayesian inference *	All sites (+ other info)	MCMC	Can be very complex

UPGMA, NJ

* attempt to find the BEST tree

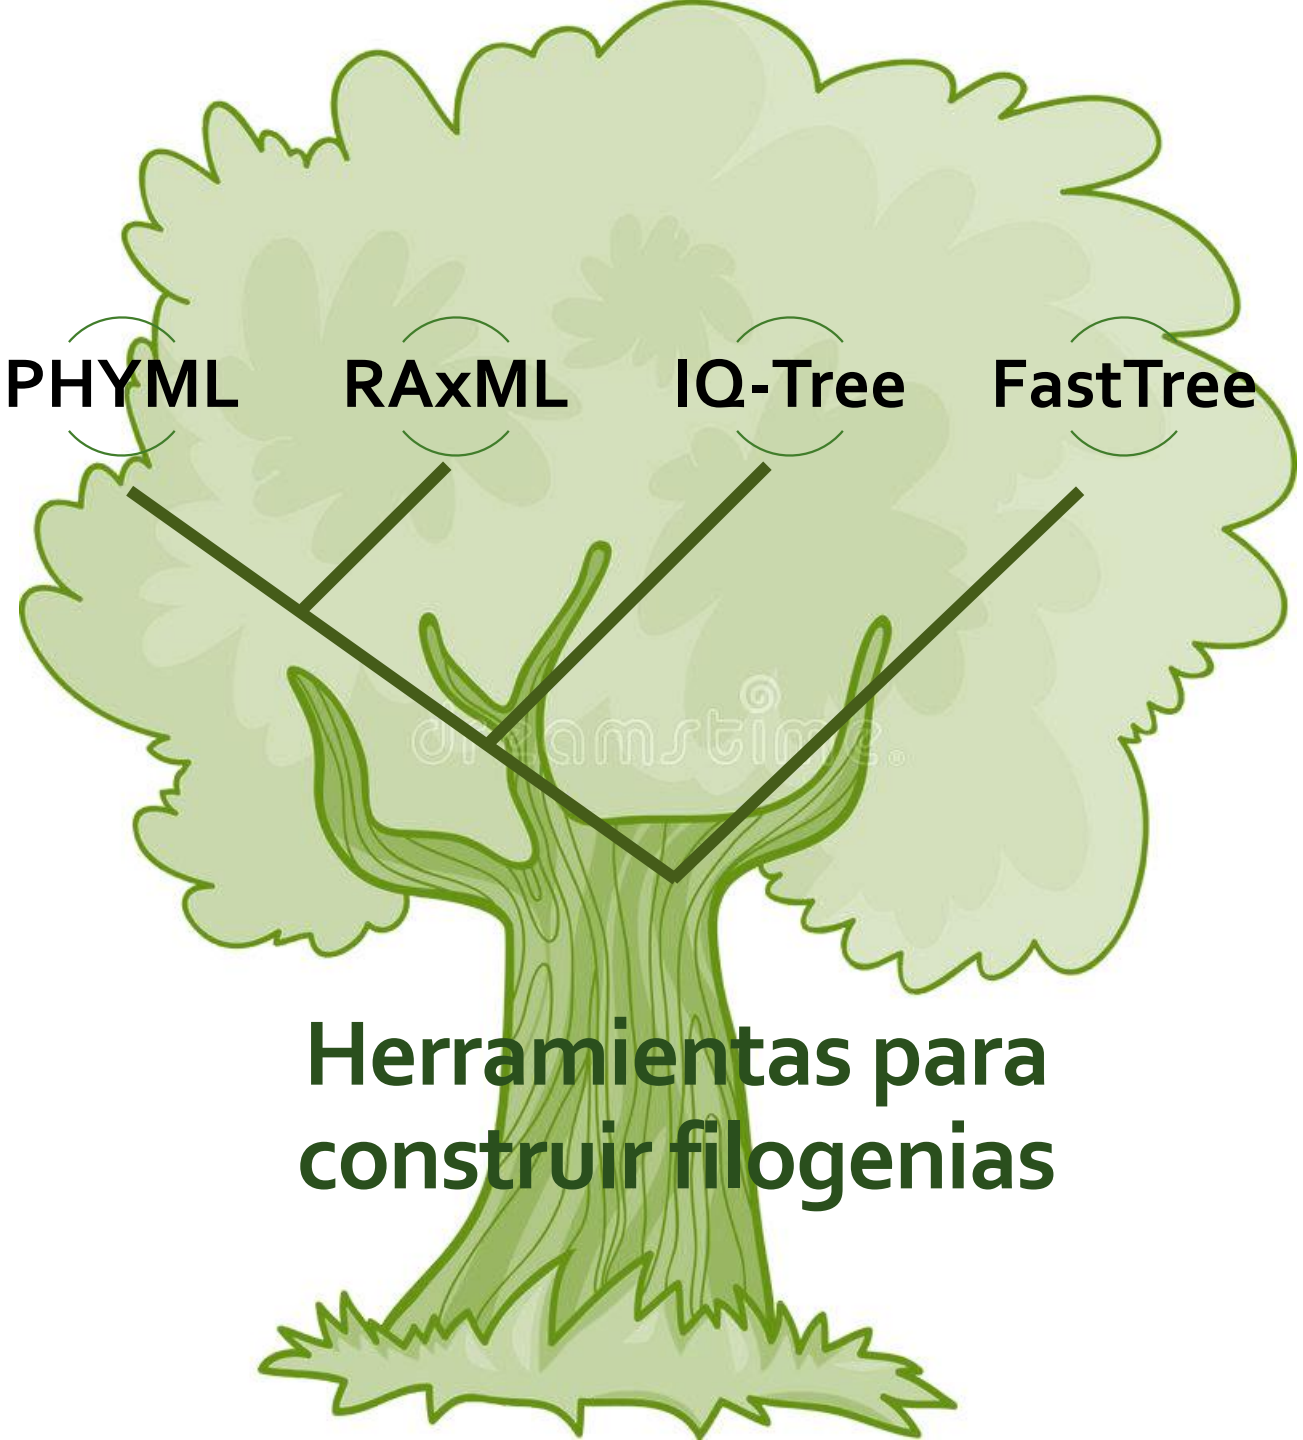

Herramientas para construir filogenias

Steps for phylogenetic analysis

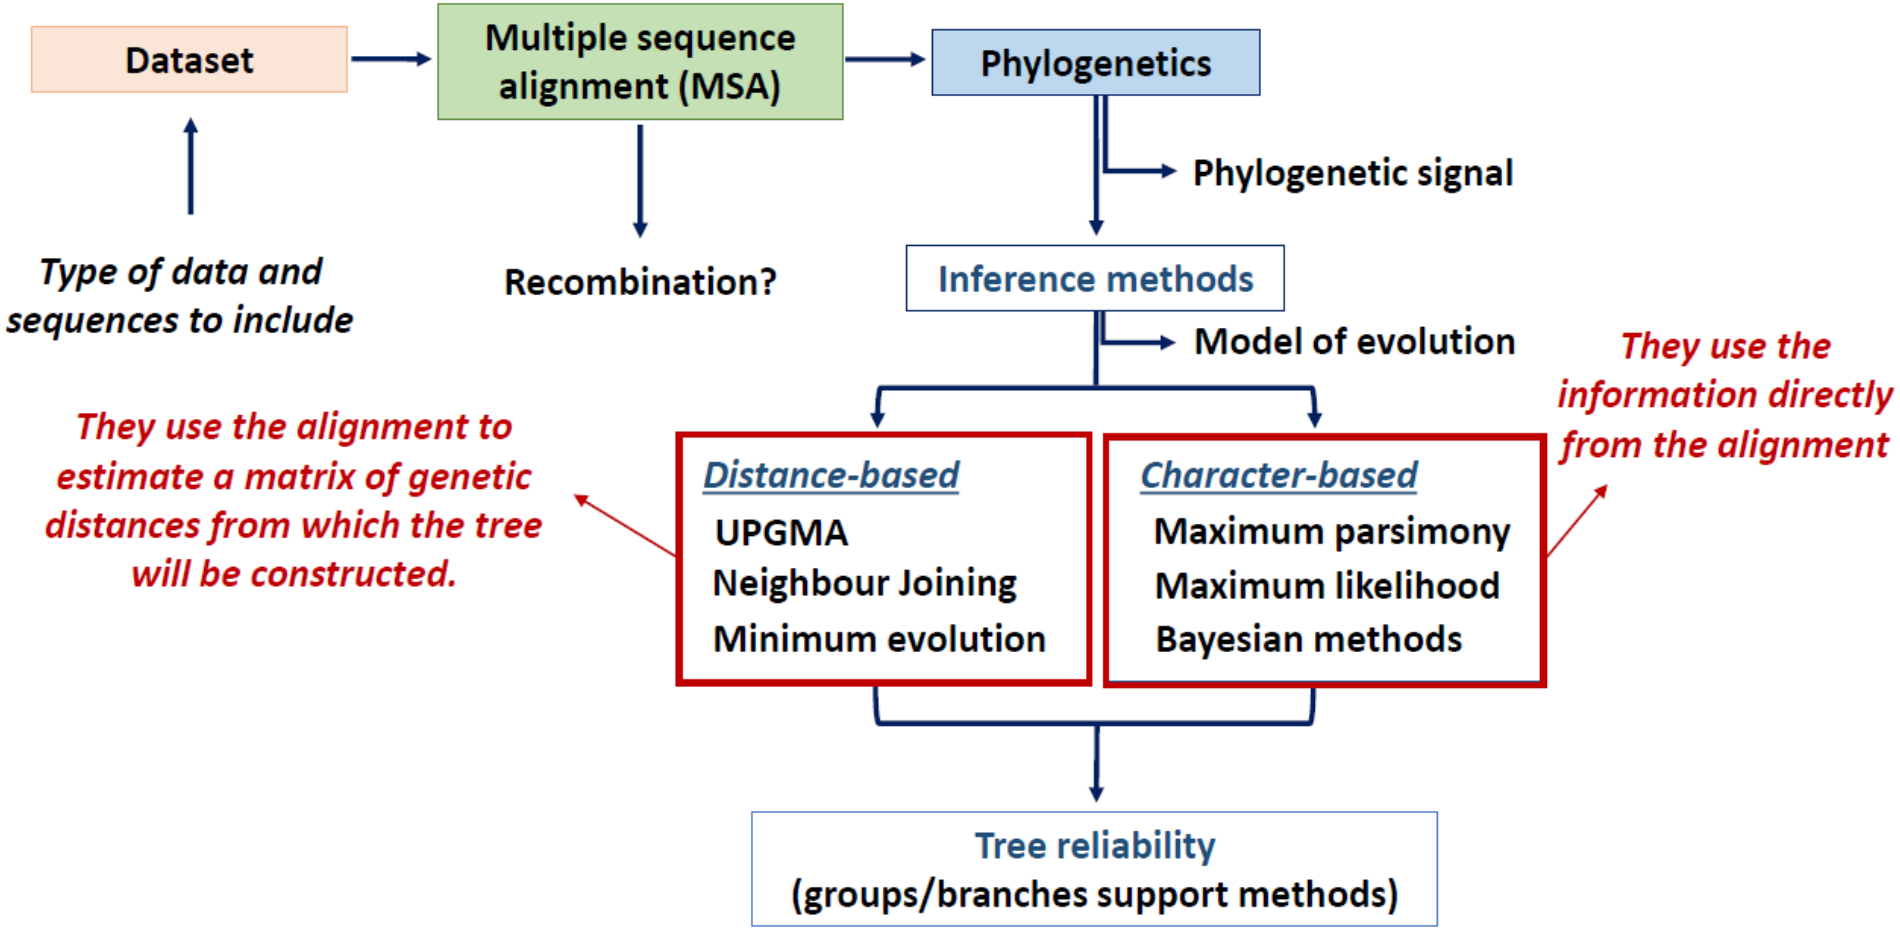

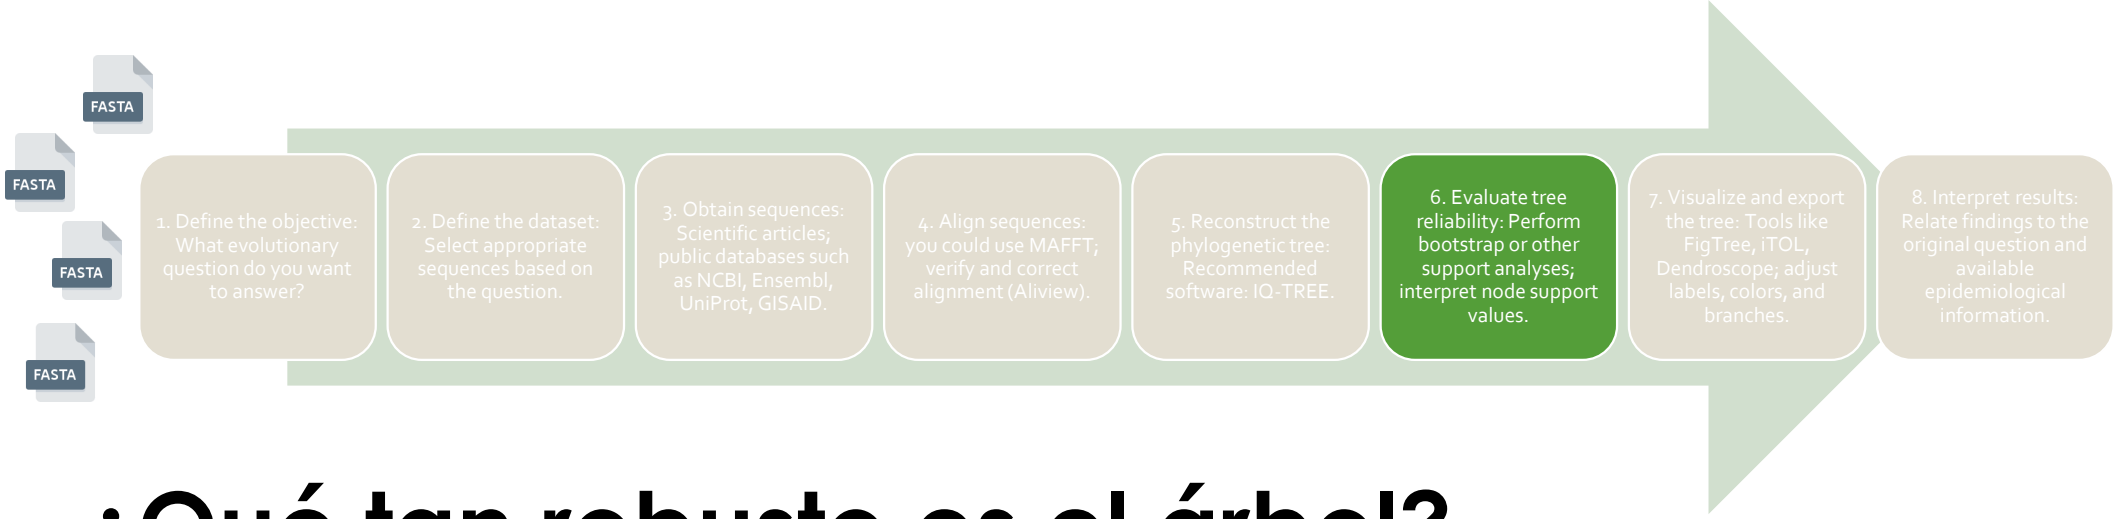

¿Qué tan robusto es el árbol?

- **Bootstrapping** es una técnica estadística que utiliza el **remuestreo aleatorio** de datos para determinar el error de muestreo.

- Da una idea de la **"fiabilidad"** de las ramas y los grupos.
- X número de bootstraps (réplicas remuestreadas) que se crean de sus datos de entrada (MSA)
- Normalmente ejecuta entre 100 y 1.000 bootstraps para el análisis de ML

- Normalmente se considera significativo cuando es superior al 70% (o 0.7 o 70/100)

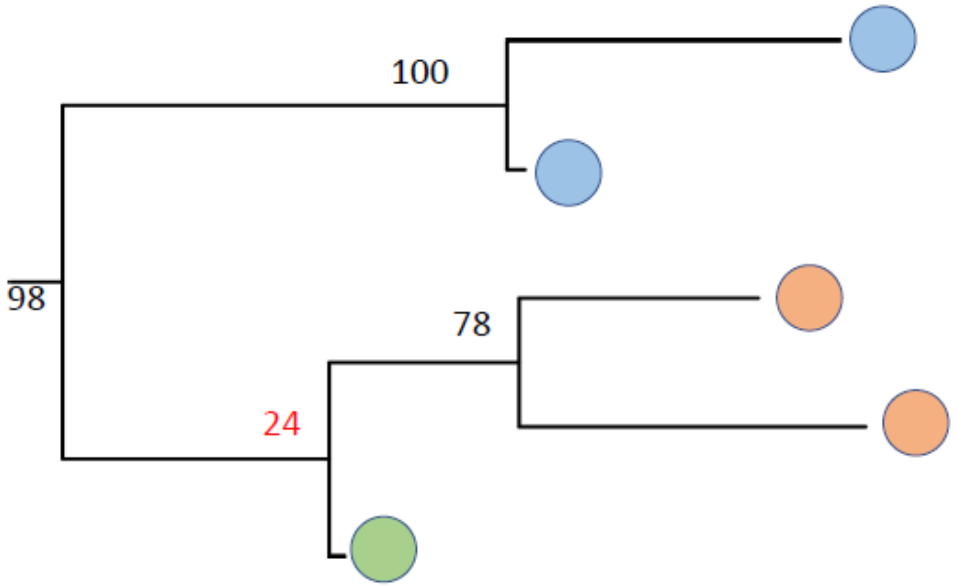

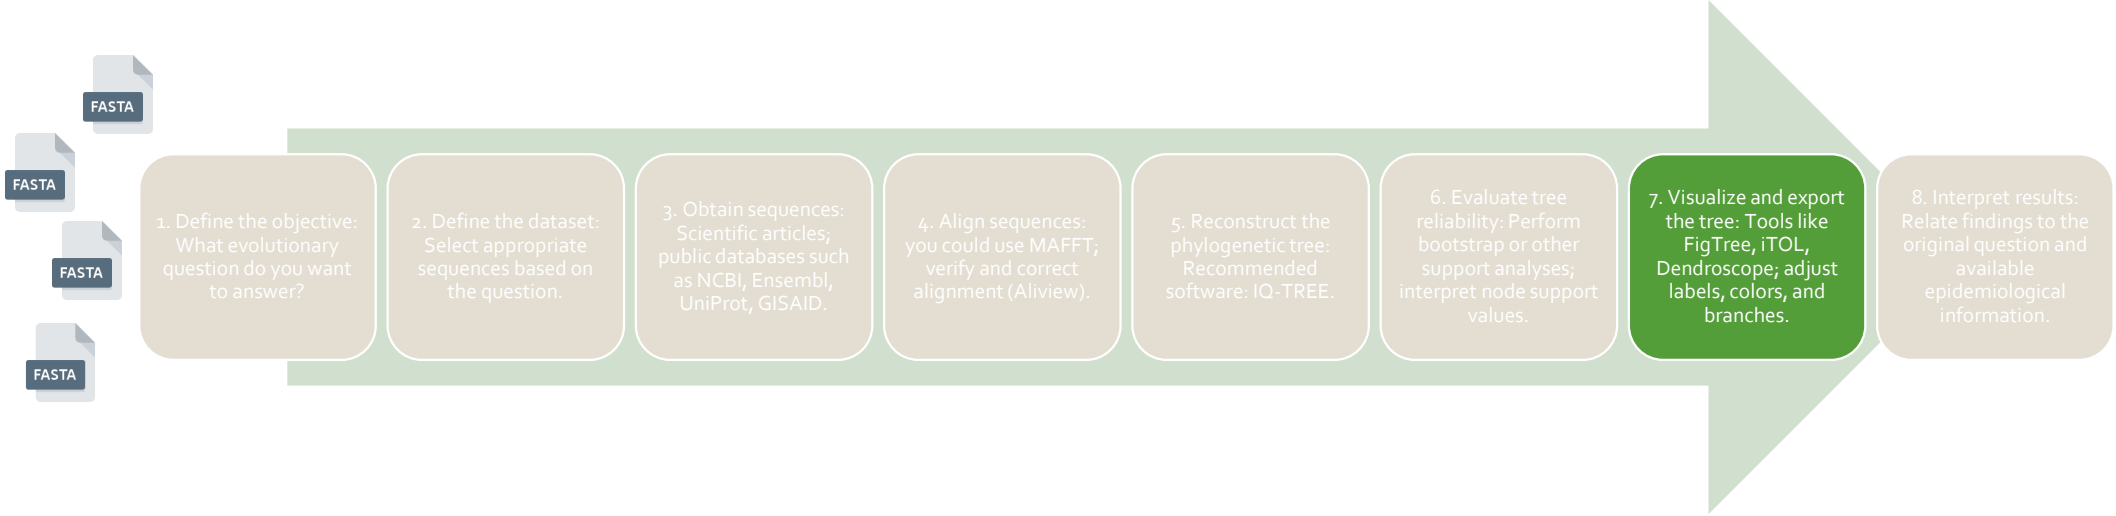

Herramientas para visualización de árboles filogenéticos

- FigTree(download, free): http://tree.bio.ed.ac.uk/software/figtree/
- Geneious(download, $$): https://www.geneious.com/
- UGENE (download, free): http://ugene.net/
- TreeView(download, free): http://jtreeview.sourceforge.net/
- iTOL(online, free or $$): https://itol.embl.de/
- ETE Toolkit (online, free): http://etetoolkit.org/treeview/
- MicroReact(online, free): http://microreact.org/

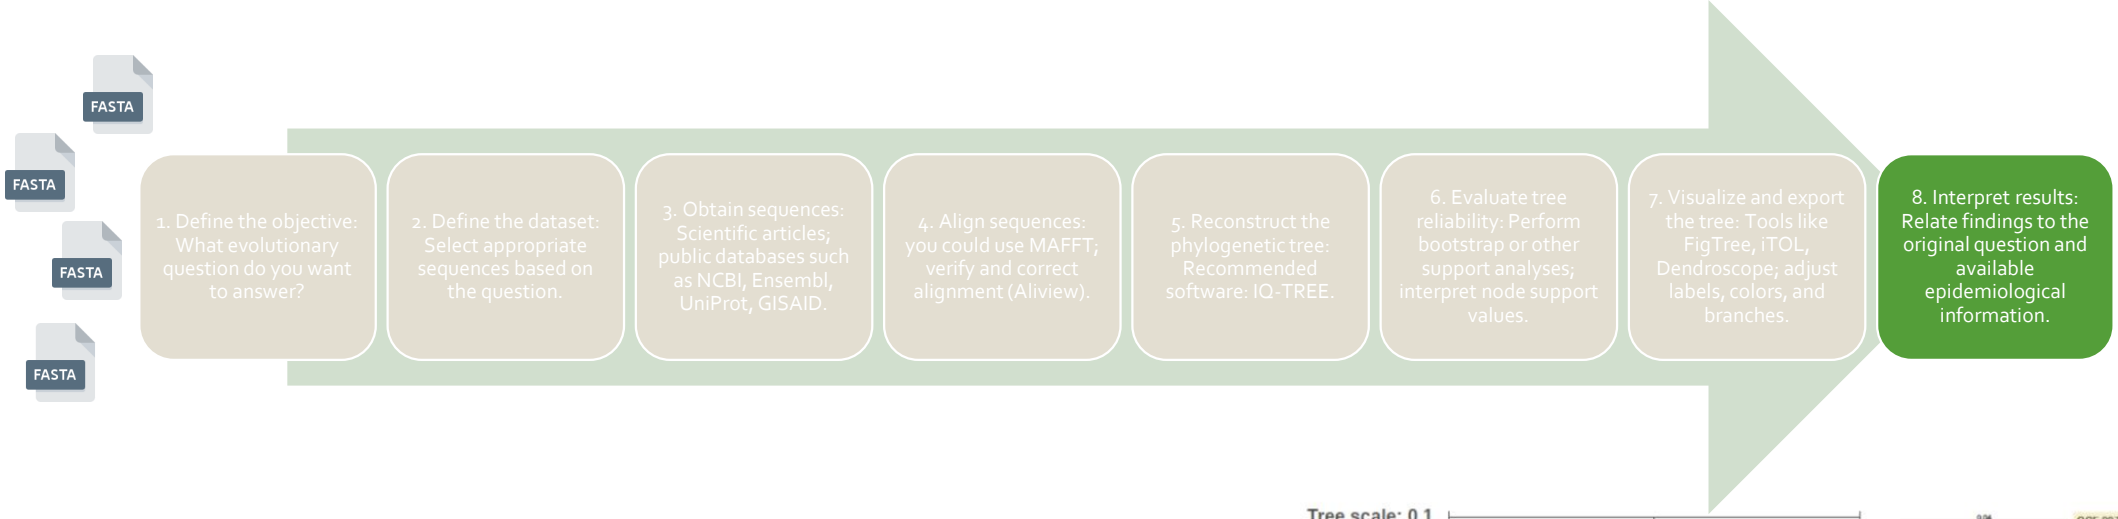

Interpretación de árboles filogenéticos

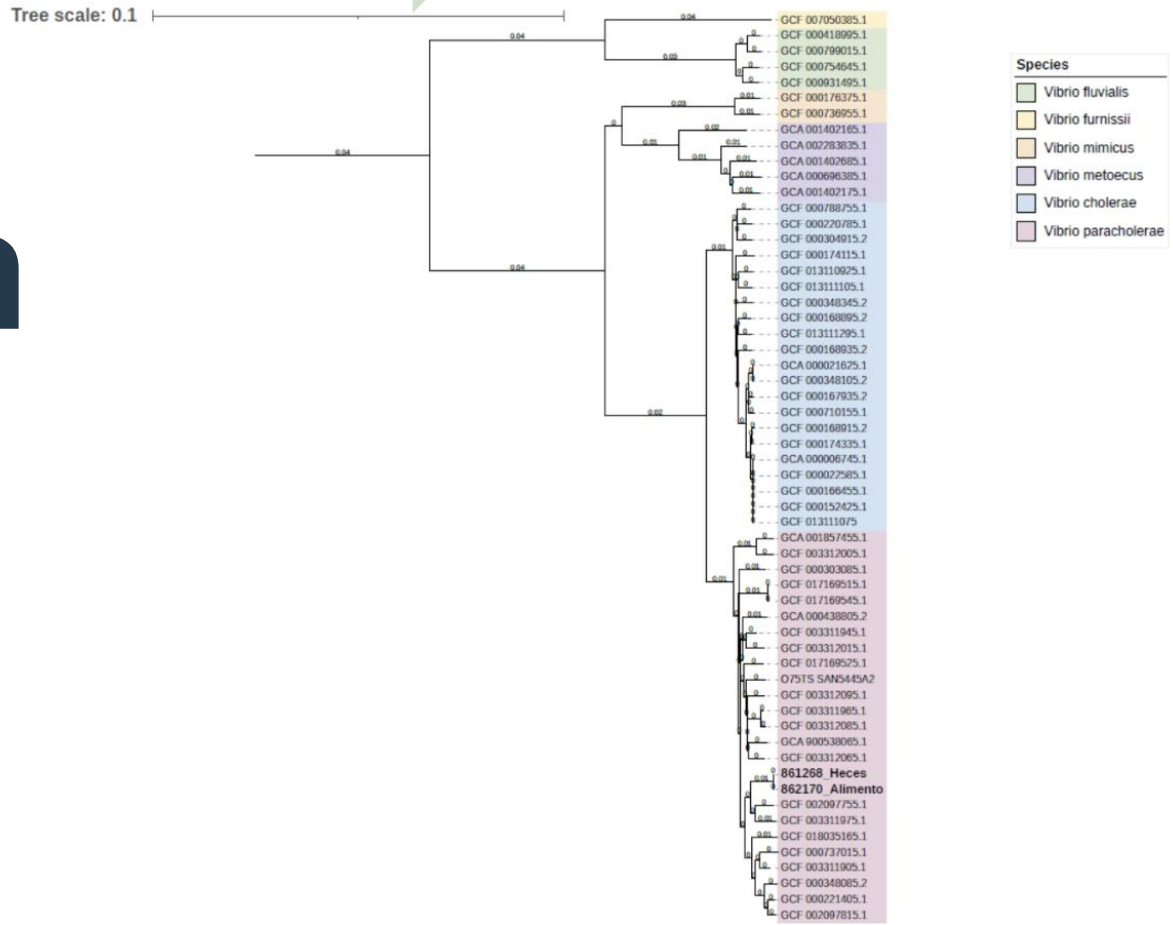

Anatomía de un árbol filogenético

<u>Nodos terminales</u> (puntas/hojas): Muestra secuenciada representada en un árbol filogenético

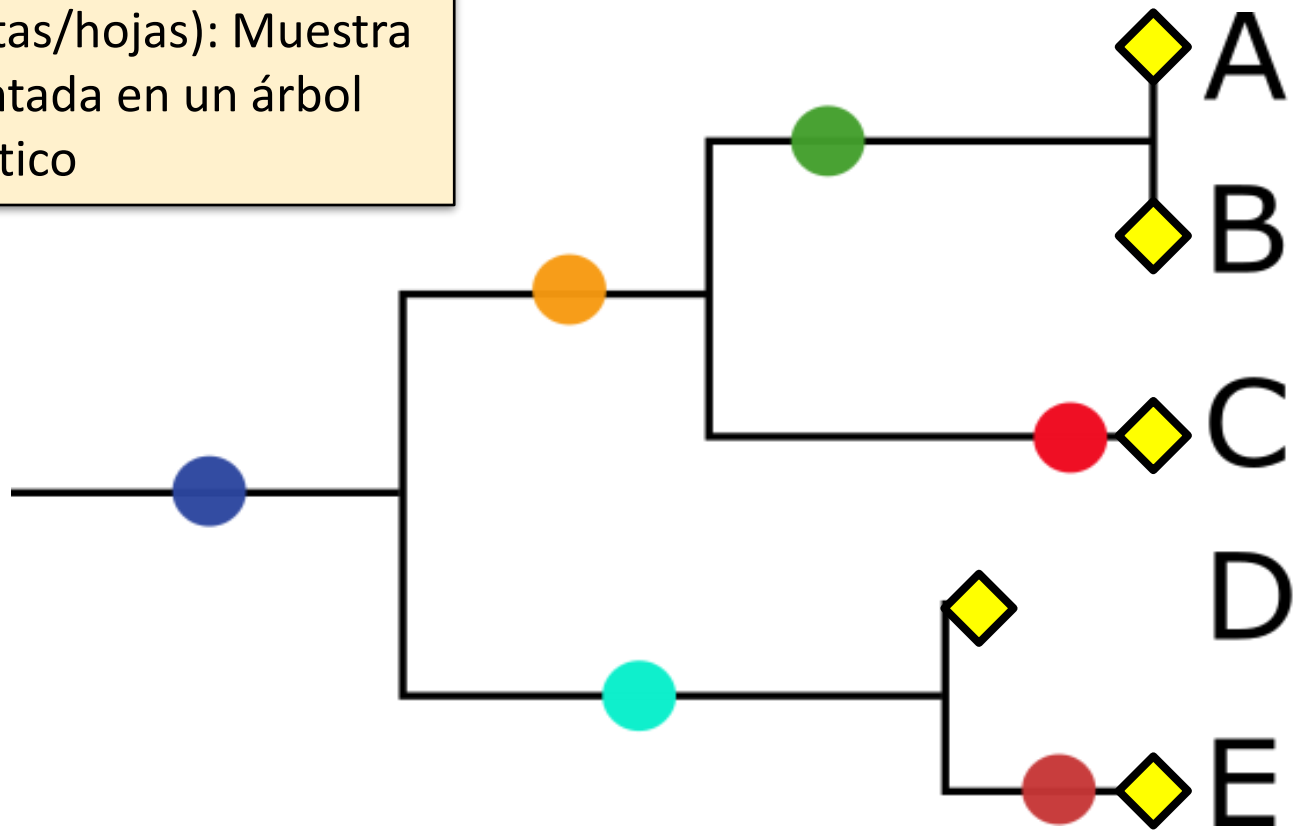

Estos son todos los **nodos terminales** de este árbol filogenético

Anatomía de un árbol filogenético

<u>Nodos internos</u> (nodo ancestral):
Antepasado común inferido

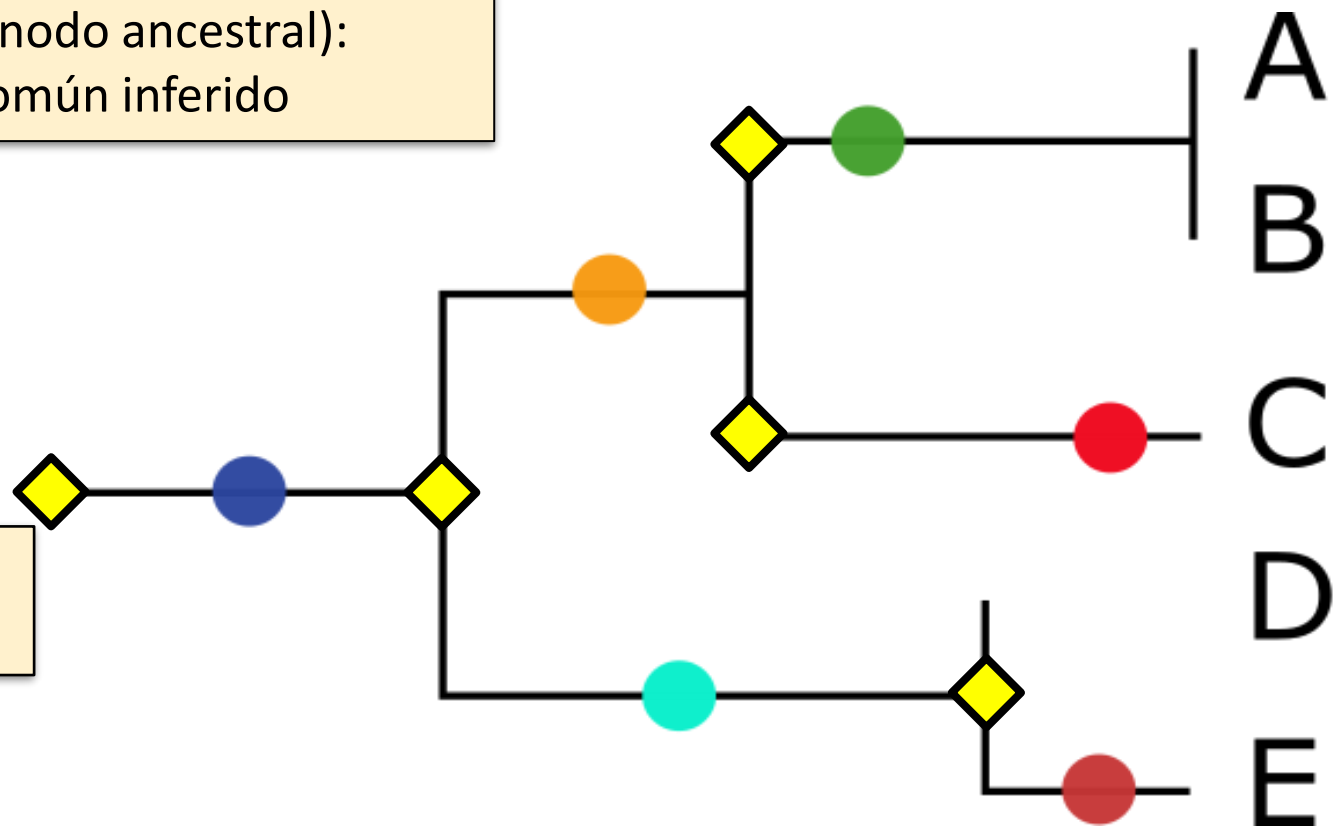

Ancestro común para todo el árbol

Estos son todos los **nodos internos** de este árbol filogenético

Anatomía de un árbol filogenético

Longitud de rama: Representación visual de la distancia evolutiva (número de diferencias filogenéticas)

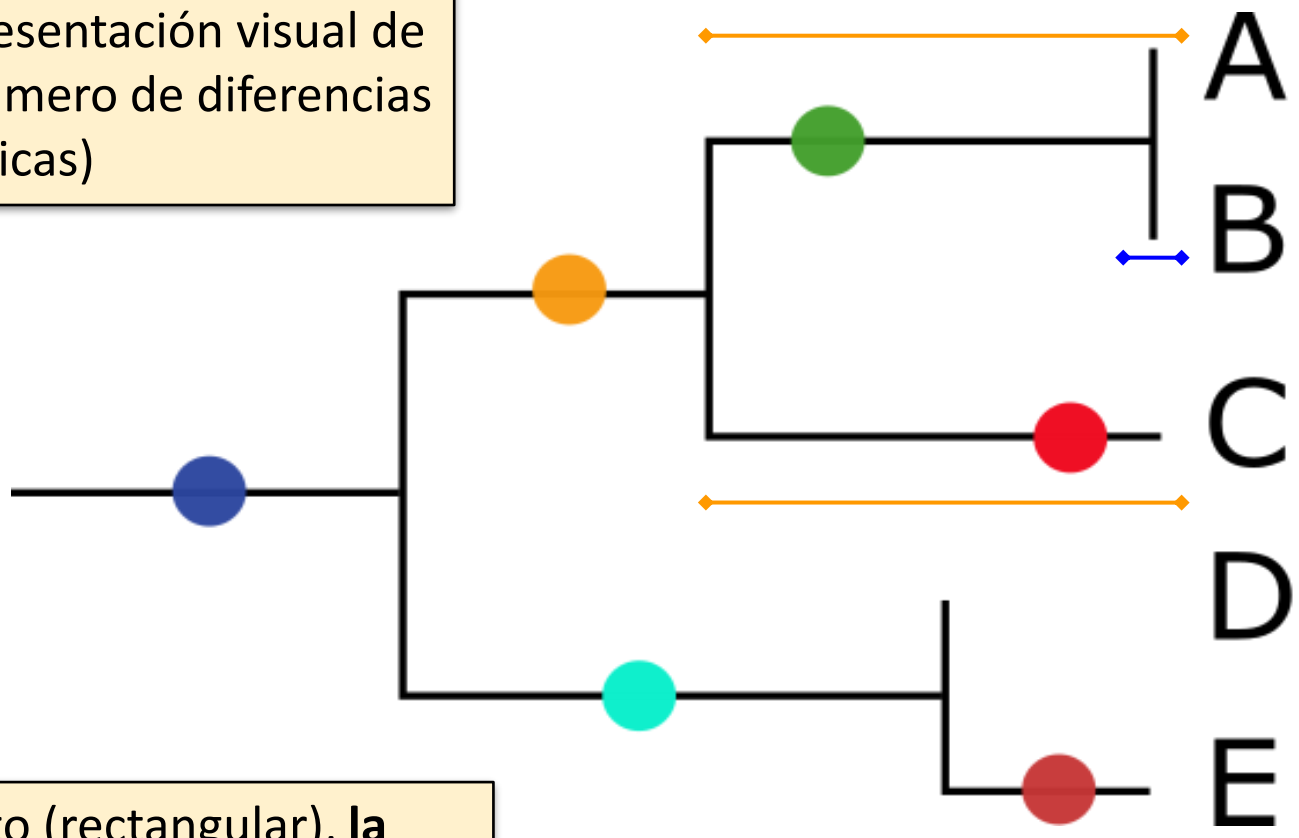

La longitud de rama entre **A and B** es cero, lo que indica identidad filogenética*

La longitud de rama entre **A and C** es mayor, lo que indica una relación evolutiva distante

Nota: En este formato (rectangular), **la longitud de las ramas verticales** sirve estrictamente como **ayuda visual** para mejorar la claridad y la organización

La rotación de las ramas no cambia el árbol

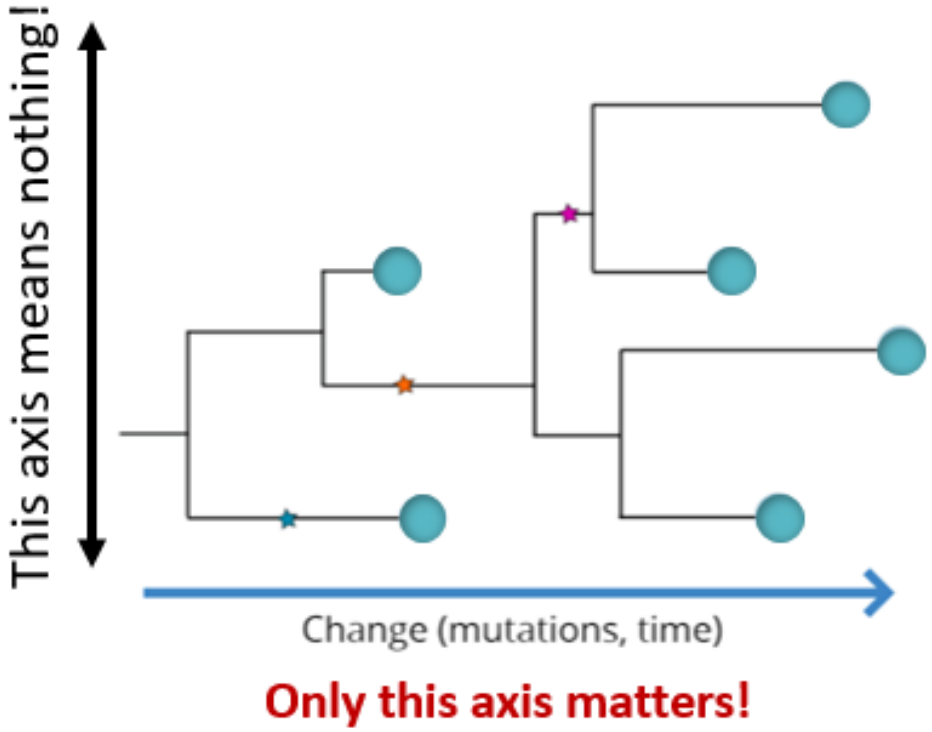

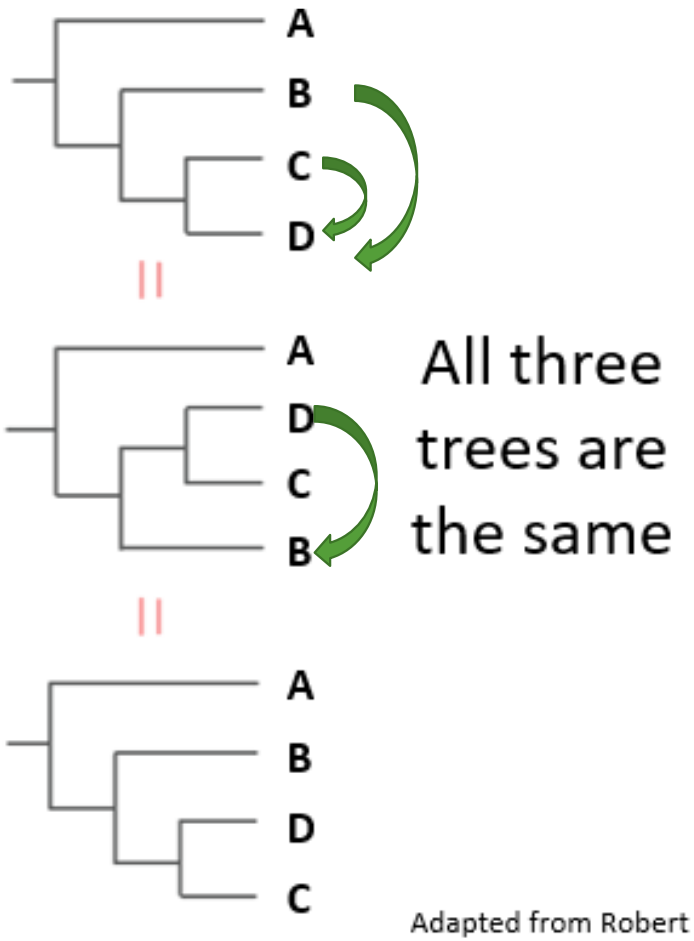

Adapted from Robert Bear

MichaelWeigand, COVID-19 Genomic Epidemiology Toolkit: Module 1.3. How to read a phylogenetic tree

Anatomía de un árbol filogenético

<u>Grupo o Cluster</u>: Término general que se refiere a un grupo de muestras con una relación evolutiva cercana

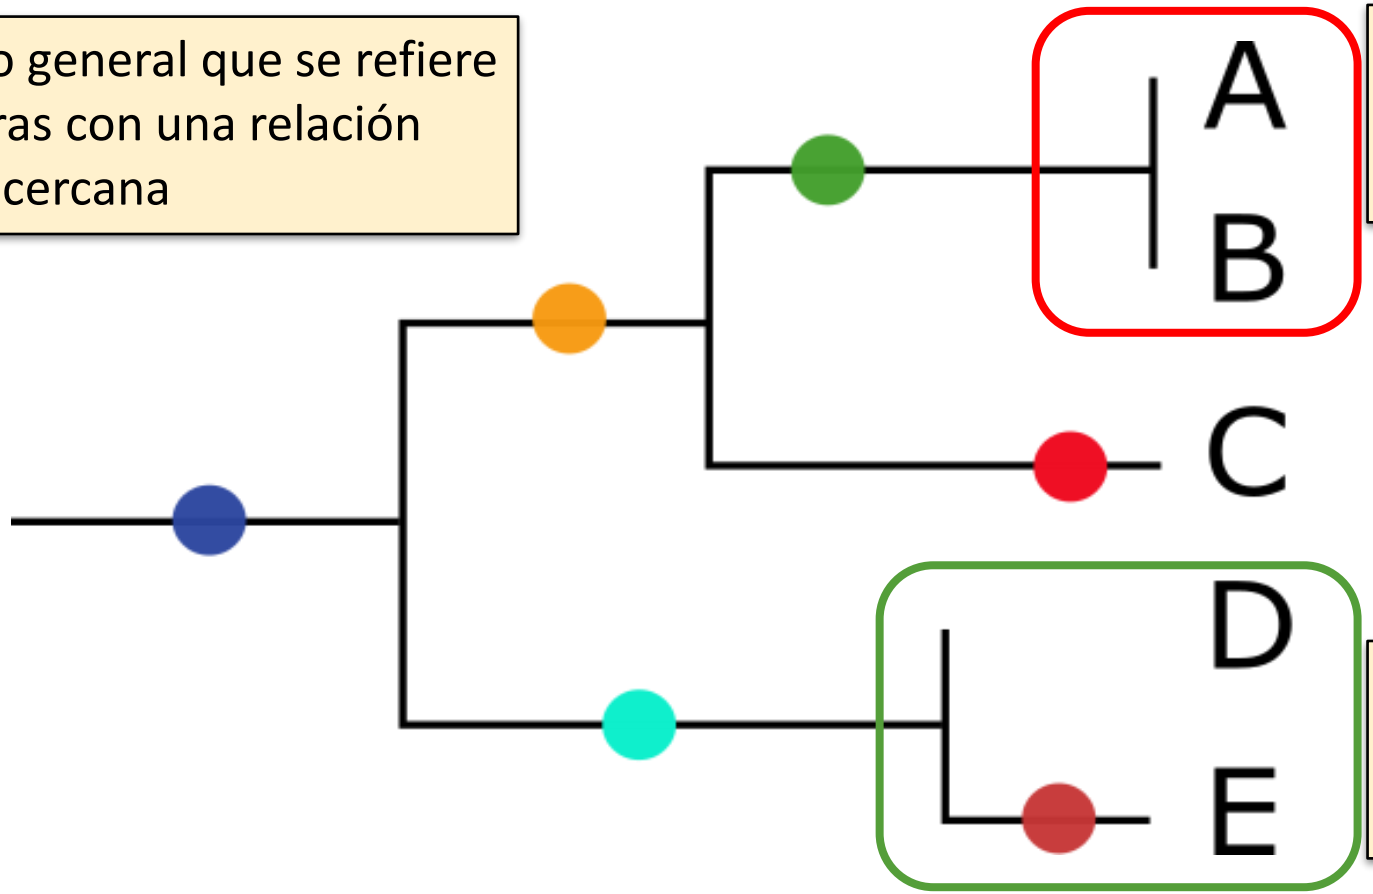

Las muestras **A y B** forman un grupo de muestras

Las muestras **D and E** forman otro grupo de muestras

Interpretación de árboles

Tipos de árbol – partes de un árbol

<u>Topología</u>: ordenamiento de las ramas

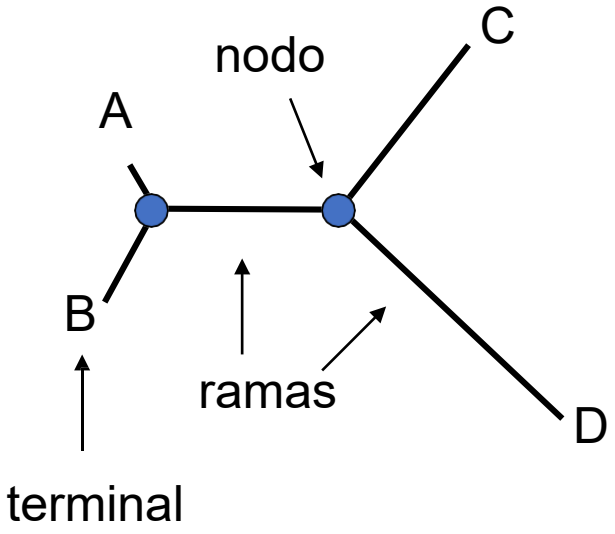

Árbol sin raíz

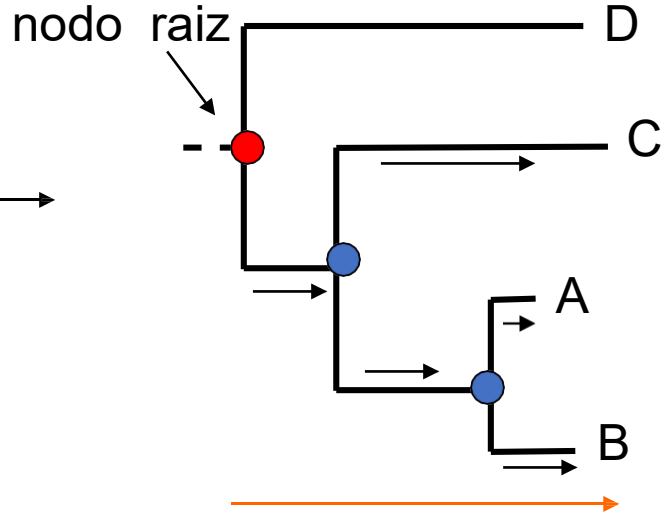

Dirección de la evolución

Árbol con raíz

Interpretación de árboles

¿Cómo determinamos la raiz de un árbol?

- **Método del GRUPO EXTERNO (Outgroup)**

  Lo suficientemente divergente, pero lo mas similar posible.

- **Método del PUNTO MEDIO (Midpoint rooting)**

  La raíz se establece en el punto medio entre los dos taxones más divergentes.

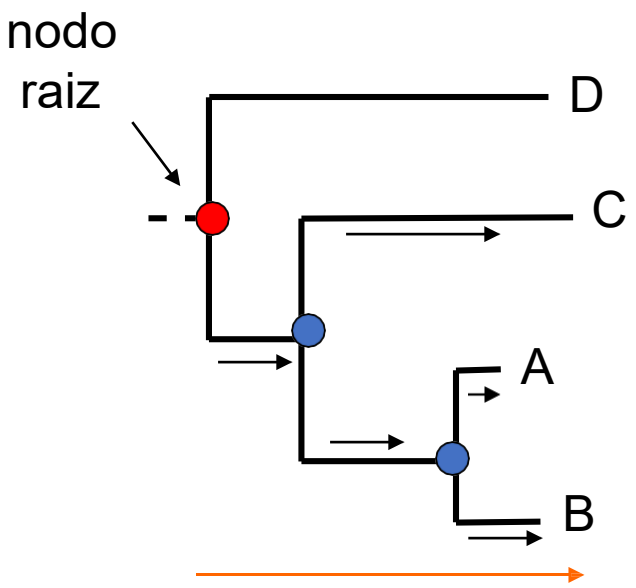

Dirección de la evolución

La raíz permite establecer la dirección del proceso evolutivo.

Árboles filogenéticos

Tipos de árbol – partes de un árbol

CLADOGRAMA

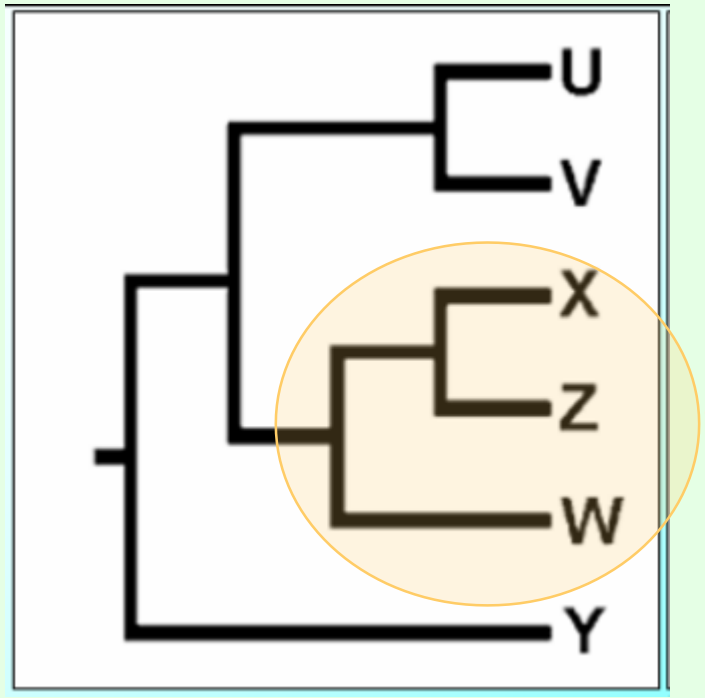

Muestra información sobre el agrupamiento de las secuencias

Grupo monofilético

FILOGRAMA

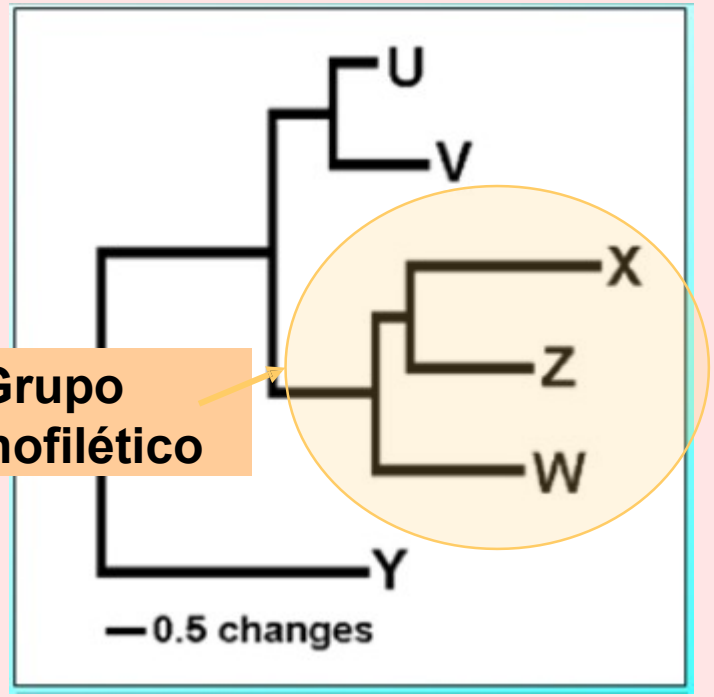

Muestra información sobre el agrupamiento de las secuencias y su distancia genética

Grupo monofilético: grupo en el que todas las secuencias de interés comparten un ancestro común sin ninguna otra secuencia dentro del grupo.

Origen común, fuente común de infección, misma cadena de transmisión

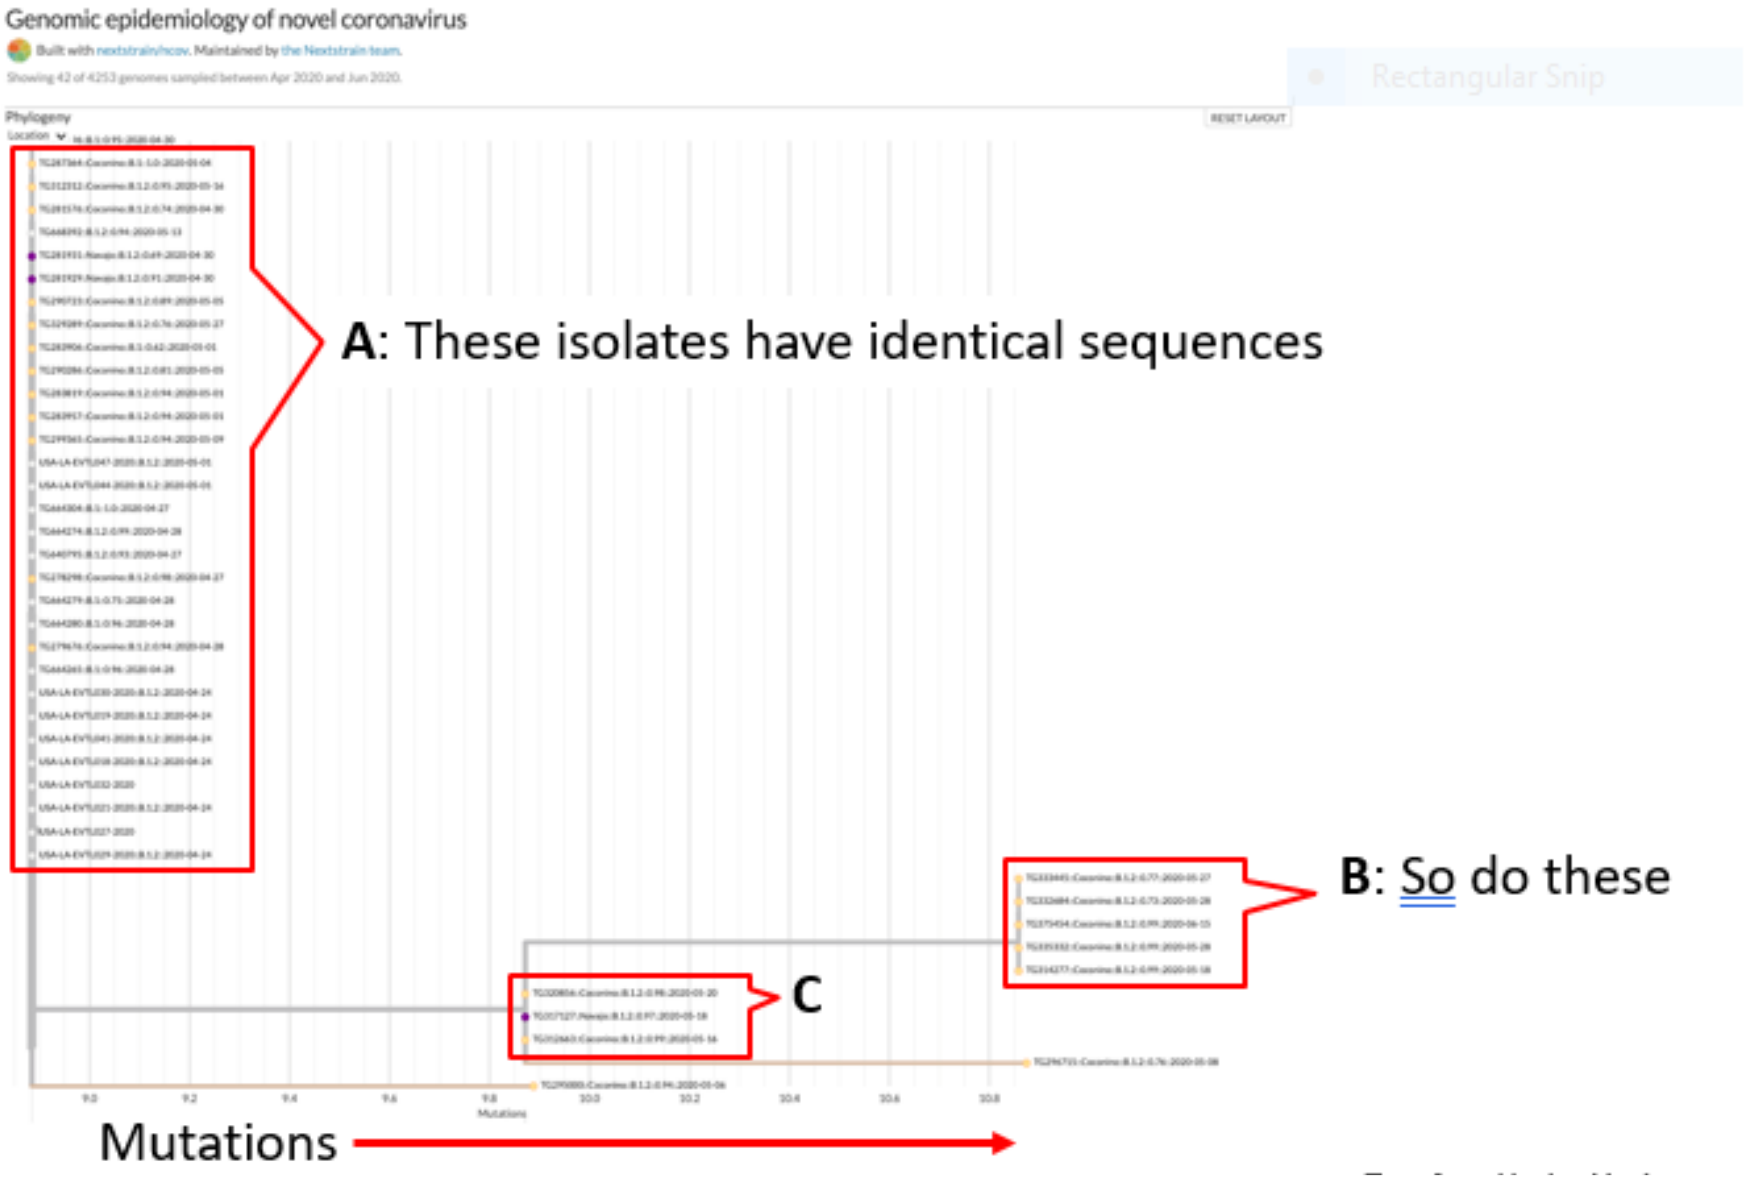

MichaelWeigand, COVID-19 Genomic Epidemiology Toolkit: Module 1.3. How to read a phylogenetic tree

Árbol SNP del Genoma Central vs Árbol SNP del Genoma Pan

- El genoma central de un conjunto de secuencias contiene sólo los **sitios compartidos por todas las secuencias**
  - Esto es muy útil al analizar un conjunto de secuencias donde se espera cierta diversidad (múltiples genotipos en el mismo árbol, o incluyendo/excluyendo muestras de un brote)
  - Es más rápido y menos intensivo desde el punto de vista computacional construir un árbol utilizando el genoma central

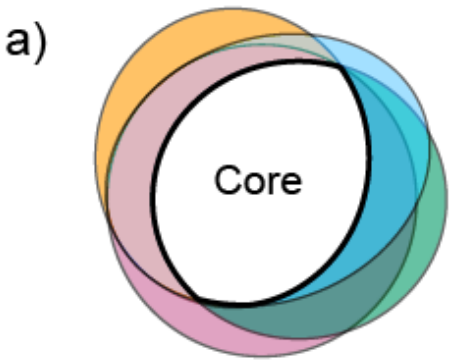

- El <u>pangenoma</u> contiene **todos los sitios** encontrados en todas las secuencias del conjunto
  - Es muy útil cuando se trata de evaluar la posible transmisión entre individuos, caracterizar un brote durante un largo periodo de tiempo o describir la estructura general de la población de un patógeno
  - El número de SNP en el pangenoma siempre será mayor que en el genoma central

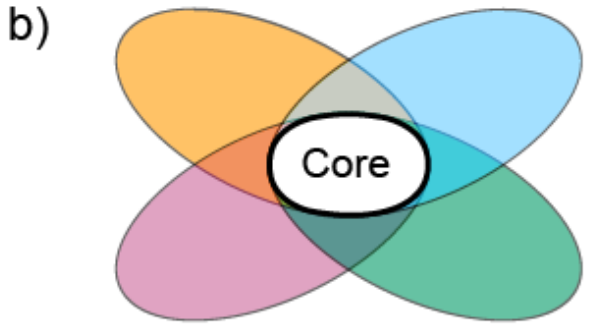

Más sobre árboles del genoma central...

- Ten en cuenta que cuantas más secuencias añadas al árbol, menos SNP se utilizarán para construirlo

- Esto sucede porque los SNP centrales (sitios SNP que todos los genomas tienen en común) son los que se utilizan para construir el árbol

  - Esto no es un problema cuando las secuencias están estrechamente relacionadas (parte de un brote) porque son muy similares

  - Esto puede convertirse en un problema con secuencias más divergentes; ¡tener cuidado al añadir secuencias contextuales al árbol!

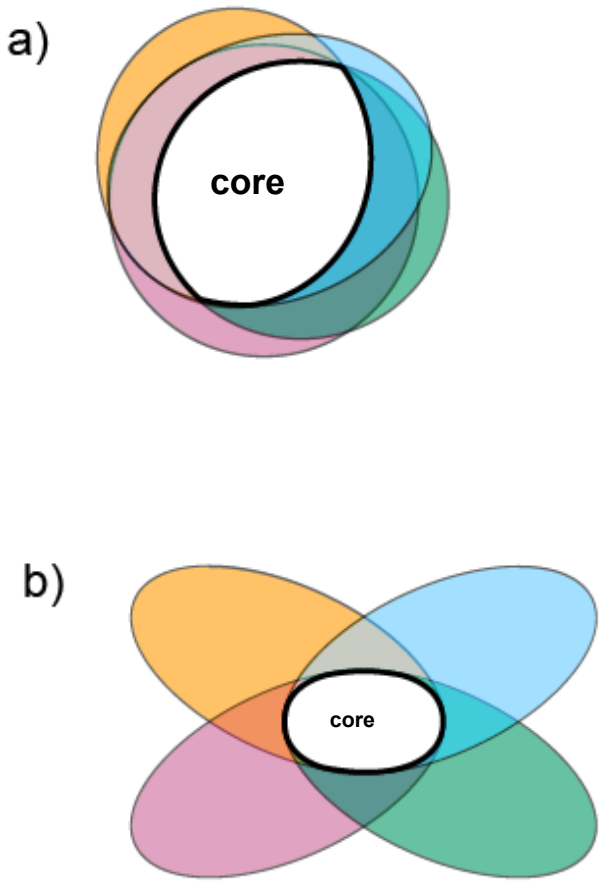

Ejemplo: Alineación del SNP central

Muestra 1	ST1	A	T	G	C	T	T	G	C	**A**	T	G	C	A	A	G	C	A	**A**	G	G	G	**A**	G	C	A	C
Muestra 2	ST1	A	**C**	G	C	T	T	**T**	C	T	T	G	**G**	A	A	G	C	A	T	**C**	G	G	T	**C**	C	A	C
Muestra 3	ST1	A	T	G	C	T	T	**T**	C	A	T	G	C	A	A	**C**	**G**	A	T	G	G	G	T	**C**	C	A	C
Muestra 4	ST1	A	**C**	G	C	**A**	T	G	C	**T**	T	G	C	**T**	A	**C**	C	A	T	G	**C**	G	**A**	G	**T**	A	**G**
Muestra 5	ST1	A	**C**	G	C	T	T	G	C	**T**	T	G	C	A	A	G	C	**T**	T	G	**C**	G	**A**	G	**T**	A	**G**
Muestra 6	ST2	A	T	G	C	T	T	G	C	**T**	-	G	C	A	A	**C**	C	A	T	G	**C**	G	**A**	G	**T**	A	C
Muestra 7	ST2	A	T	G	C	T	T	G	C	**T**	-	G	C	A	A	G	C	**T**	T	G	**C**	G	**A**	G	**T**	A	C
Muestra 8	ST2	A	T	G	C	T	T	**T**	C	**T**	-	G	C	A	A	G	C	A	T	G	**C**	G	T	G	**T**	A	C
Muestra 9	ST3	A	**C**	G	C	T	T	G	C	A	-	G	C	A	A	**C**	C	A	T	G	-	-	-	-	-	-	-
Muestra 10	ST3	A	T	G	C	**A**	T	G	C	A	-	G	C	A	A	**C**	C	A	T	G	-	-	-	-	-	-	-

Los sitios centrales con SNPs son los que se utilizan para construir el árbol

Los genomas ST2 y ST3 no tienen este sitio, por lo que se elimina de la alineación

Los genomas ST3 no tienen estos sitios, por lo que se excluyen de la alineación

Limitaciones de los supuestos básicos: implicaciones en la interpretación

- Las secuencias que están filogenéticamente más cerca tienen más probabilidades de compartir una asociación epidemiológica. PERO…
  - No se puede suponer que las vías de transmisión (y la dirección de transmisión) reflejen la filogenia (sin otros datos)
  - Los vínculos causales (por ejemplo, entre casos y exposiciones) no pueden asumirse únicamente a partir de los datos de secuencia.
  - ¡Los árboles son solo una aproximación de la verdadera historia!

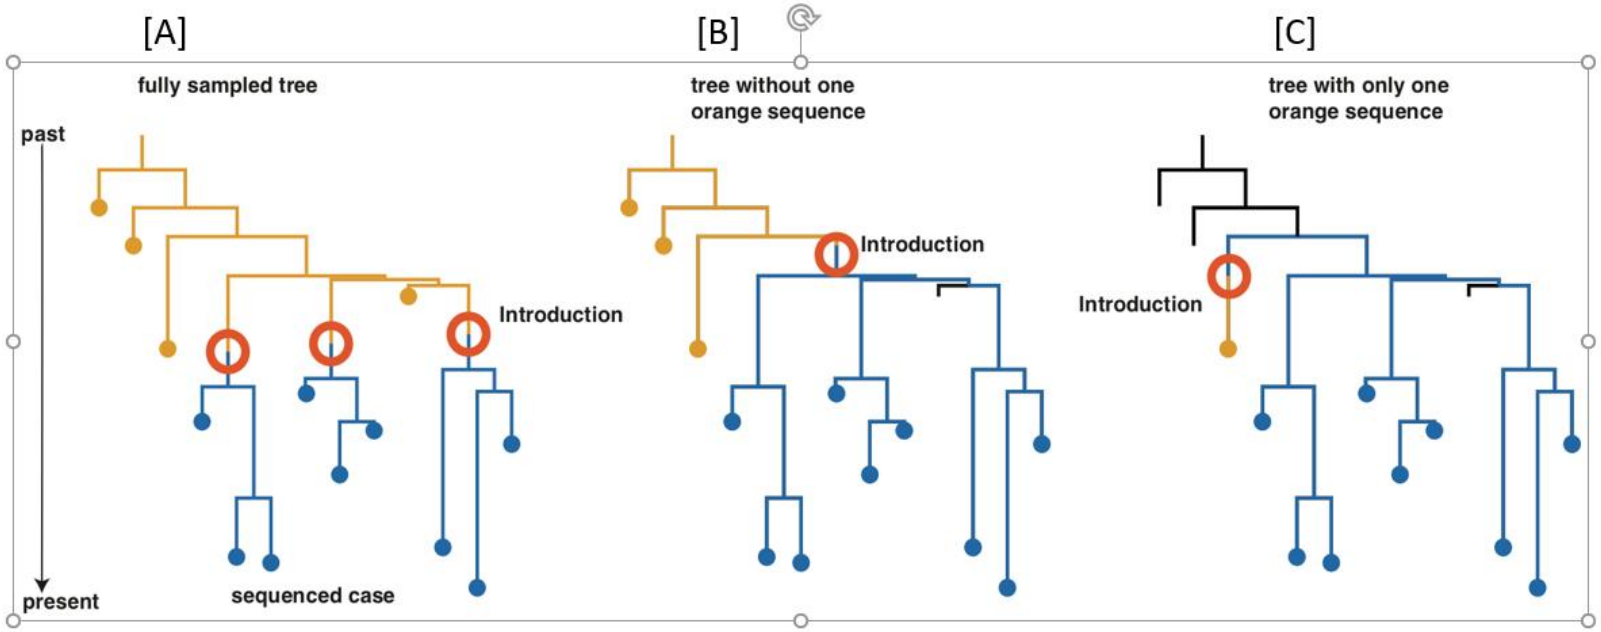

MichaelWeigand, COVID-19 Genomic Epidemiology Toolkit: Module 1.3. How to read a phylogenetic tree

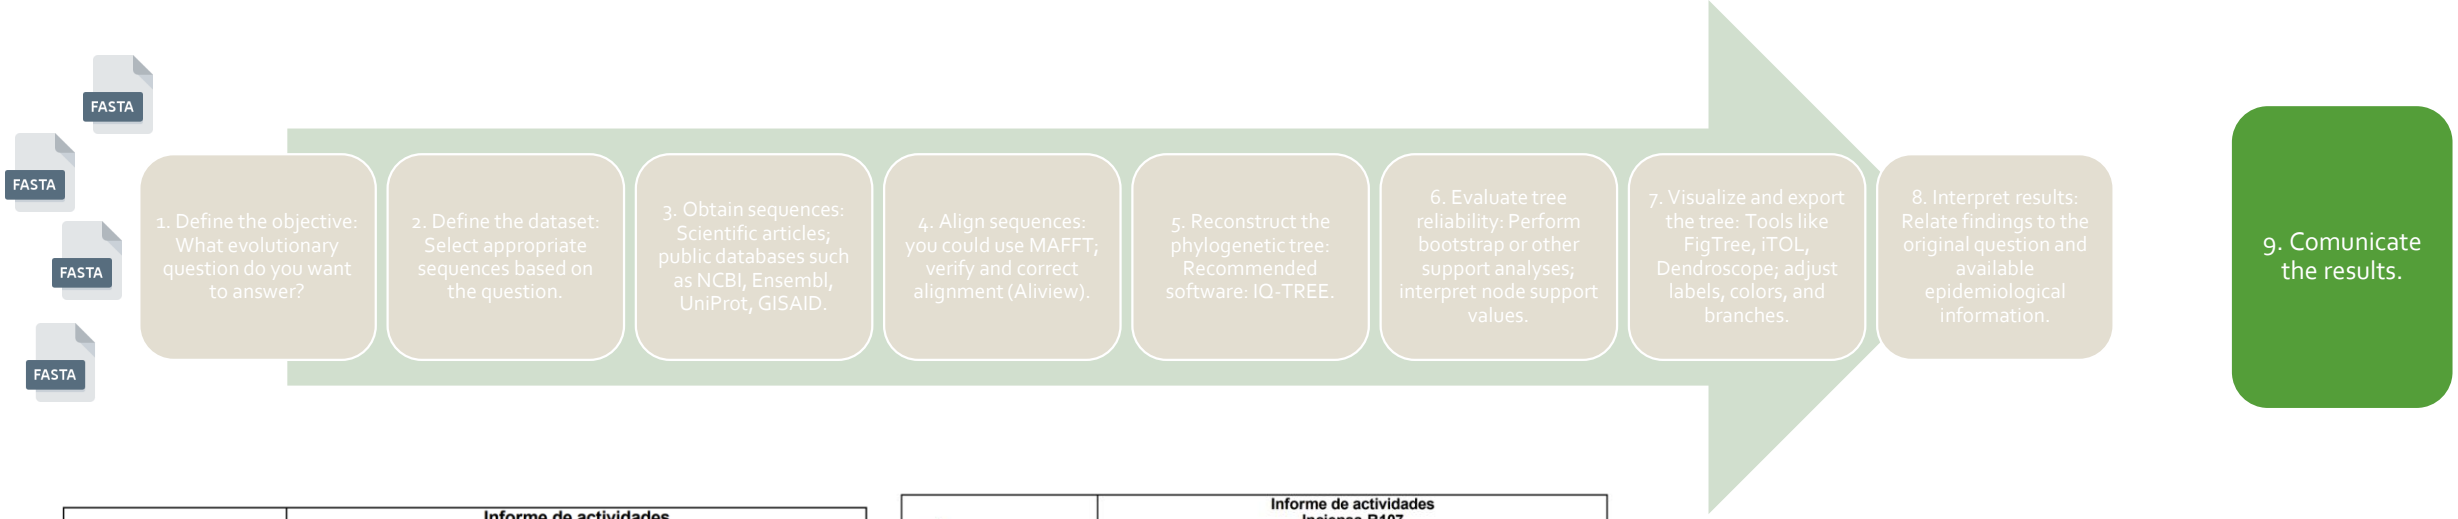

INCIENSA	Informe de actividades Inciensa-R107	
	Versión 1	Consecutivo: CNRIMA-2025-001

Tipo de actividad:
Secuenciación de genoma completo y análisis bioinformático de las muestras Inciensa # 861268 y # 862170 correspondientes a cepas bacterianas identificadas como *V. cholerae,* aisladas a partir de una muestra clínica de heces de paciente y de una muestra de licuado de verduras respectivamente, ambas muestras estaban asociadas a un evento de enfermedad diarreica aguda ocurrido en el centro de cuido Fundación [redacted] a finales de abril del año en 2025.

Fecha:
2025-06-12

Objetivo:
Confirmar la identificación de las cepas recibidas y determinar la relación filogenética entre ellas.

Responsable(s) de la actividad:
Equipo de trabajo del Laboratorio de genómica y biología molecular, Inciensa.

Descripción detallada:
La secuenciación *paired-end* del genoma completo de las muestras recibidas se llevó a cabo en un equipo Illumina MiSeq a 250 ciclos, con una celda V2 de 500 ciclos, las bibliotecas fueron generadas con el kit Illumina DNA Prep, acorde al procedimiento estandarizado de la red PulseNet Latinoamérica y Caribe
El ensamblaje de novo de las secuencias se realizó con la herramienta Shovill, incluida en el software Terra bio, pipeline theiaprok_illumina_pe_PHB v3.0.1. Se utilizaron las herramientas de identificación incluidas en este pipeline de análisis: Average Nucleotide Identity- ANI _mummer_version 4.0.0rc1; Gambit-metadata-2.0.0 y Kmerfinder_bacteria_20230911. Además, se utilizó MLST ribosomal (Jolley et al, 2012).
Se realizó un análisis por Neighbor joining para determinar las relaciones filogenéticas entre las secuencias de las cepas en cuestión y un conjunto de secuencias de diferentes especies del *género* Vibrio tomadas del artículo "Population Analysis of *Vibrio cholerae* in Aquatic Reservoirs Reveals a Novel Sister Species (*Vibrio paracholerae* sp. nov.) with a History of Association with Humans" (Islam MT et al, 2021), donde se describe la especie *V. paracholerare.* Además, se incluyó en el análisis comparativo la secuencia de referencia de *V. paracholerae* (O75TS_SAN5442A2).

Resultados obtenidos:
Previamente, utilizando métodos de espectrometría de masas (MALDI-TOF) y métodos moleculares (PCR multiplex para identificación de *V. cholerae* y sus serotipos) ambos aislamientos habían sido identificados como *V. cholerae* No O1/No O139.

Las herramientas de identificación genómicas utilizadas presentaron resultados heterogéneos en la identificación a nivel de especie para las secuencias analizadas, siendo que en dos de ellas se identificaron como *V. cholerae* y en otras dos como *V. paracholerae* (Ver cuadro 1)

INCIENSA	Informe de actividades Inciensa-R107	
	Versión 1	Consecutivo: CNRIMA-2025-001

Cuadro 1. Identificación a nivel de especie de las secuencias obtenidas por cuatro herramientas bioinformáticas diferentes.

	Herramienta bioinformática			
Muestra	**ani_top_species_match**	**gambit_predicted_taxon**	**kmerfinder_top_hit**	**Ribosomal MLST**
861268	*Vibrio_cholerae*	*Vibrio paracholerae*	*Vibrio cholerae*	*Vibrio paracholerae*
862170	*Vibrio_cholerae*	*Vibrio paracholerae*	*Vibrio cholerae*	*Vibrio paracholerae*

En la figura 1 se muestra el análisis de las relaciones evolutivas de las secuencias examinadas y las secuencias de contexto descritas previamente. Se pudo observar que las secuencias analizadas se ubican en el mismo grupo monofilético con las secuencias de *V. paracholerae,* incluyendo la secuencia de referencia O75TS_SAN5442A2. Además, se corrobora que las secuencias provenientes de las cepas de paciente y de alimento correspondientes al evento están estrechamente relacionadas entre sí a nivel genómico, sugiriendo que el alimento podría ser una posible fuente de infección.

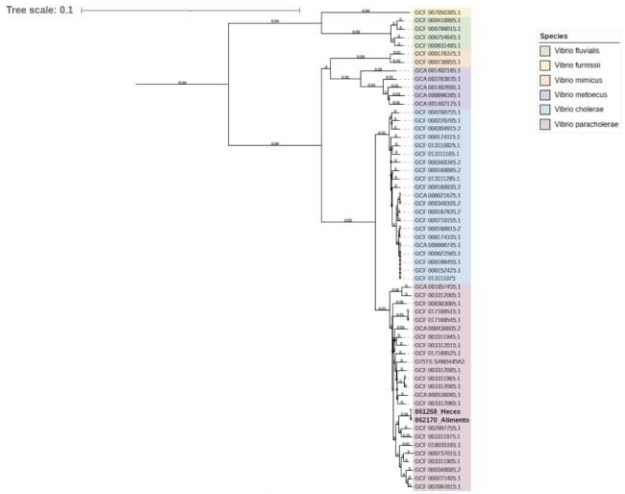

Figura 1. Análisis por Neighbor joining para identificación de especies de *Vibrio* sp.
Árbol filogenético enraizado en el punto medio que muestra las relaciones evolutivas de 56 secuencias del genoma core de diferentes especies de *Vibrio* sp y 2 secuencias problema provenientes de una muestra clínica y una muestra de alimento relacionadas al evento del centro de cuido [redacted]

INCIENSA	Informe de actividades Inciensa-R107	
	Versión 1	Consecutivo: CNRIMA-2025-001

Conclusiones:
Se confirmó la identificación las muestras 861268 y 862170 como *Vibrio paracholerae*. La identificación a nivel de especie de ambas cepas fue posible gracias al uso de la secuenciación genómica y los análisis filogenéticos, ya que otras técnicas disponibles no logran hacer una discriminación correcta entre las especies *V. cholerae* y *V. paracholerae*. El resultado anterior refuerza lo estipulado en el protocolo nacional de vigilancia, atención y control de Cólera en Costa Rica donde se indica "Para todos los laboratorios a nivel nacional, la totalidad de las muestras o aislamientos sospechosos de *Vibrio cholerae* debe referirse al CNR Bacteriología del Inciensa para su confirmación". Este análisis también demostró una estrecha relación genómica entre la cepa clínica y la cepa de alimento, esto aunado al vínculo epidemiológico sugiere al licuado de vegetales como posible fuente de contaminación.

Resumen

- Inferir filogenias te permite **reconstruir relaciones ancestrales** y **recuperar información oculta**
- Es importante utilizar **un buen método de construcción de árboles**
- **Las longitudes de las ramas** representan distancias genéticas entre secuencias. Pueden representar tiempo en árboles temporales
- Podemos probar la fiabilidad de un árbol inferido utilizando el **remuestreo bootstrap**
- Construir un árbol es solo la mitad del desafío. El verdadero desafío es **cómo interpretar el árbol**
- Existen múltiples métodos disponibles para generar filogenias de patógenos
- Los análisis filogenéticos de árboles de cgMLST y SNP son ampliamente adoptados en salud pública
  - Ambos han demostrado una utilidad increíble para la vigilancia de patógenos y las investigaciones de brotes