Capacitación en Secuenciación por NGS y análisis bioinformático de *Salmonella* spp. para la vigilancia en salud pública

Herramientas de comparación genómica

MSc. Melany Calderón Osorno
mcalderono@inciensa.sa.cr
Laboratorio de genómica y biología molecular

Marzo, 2026

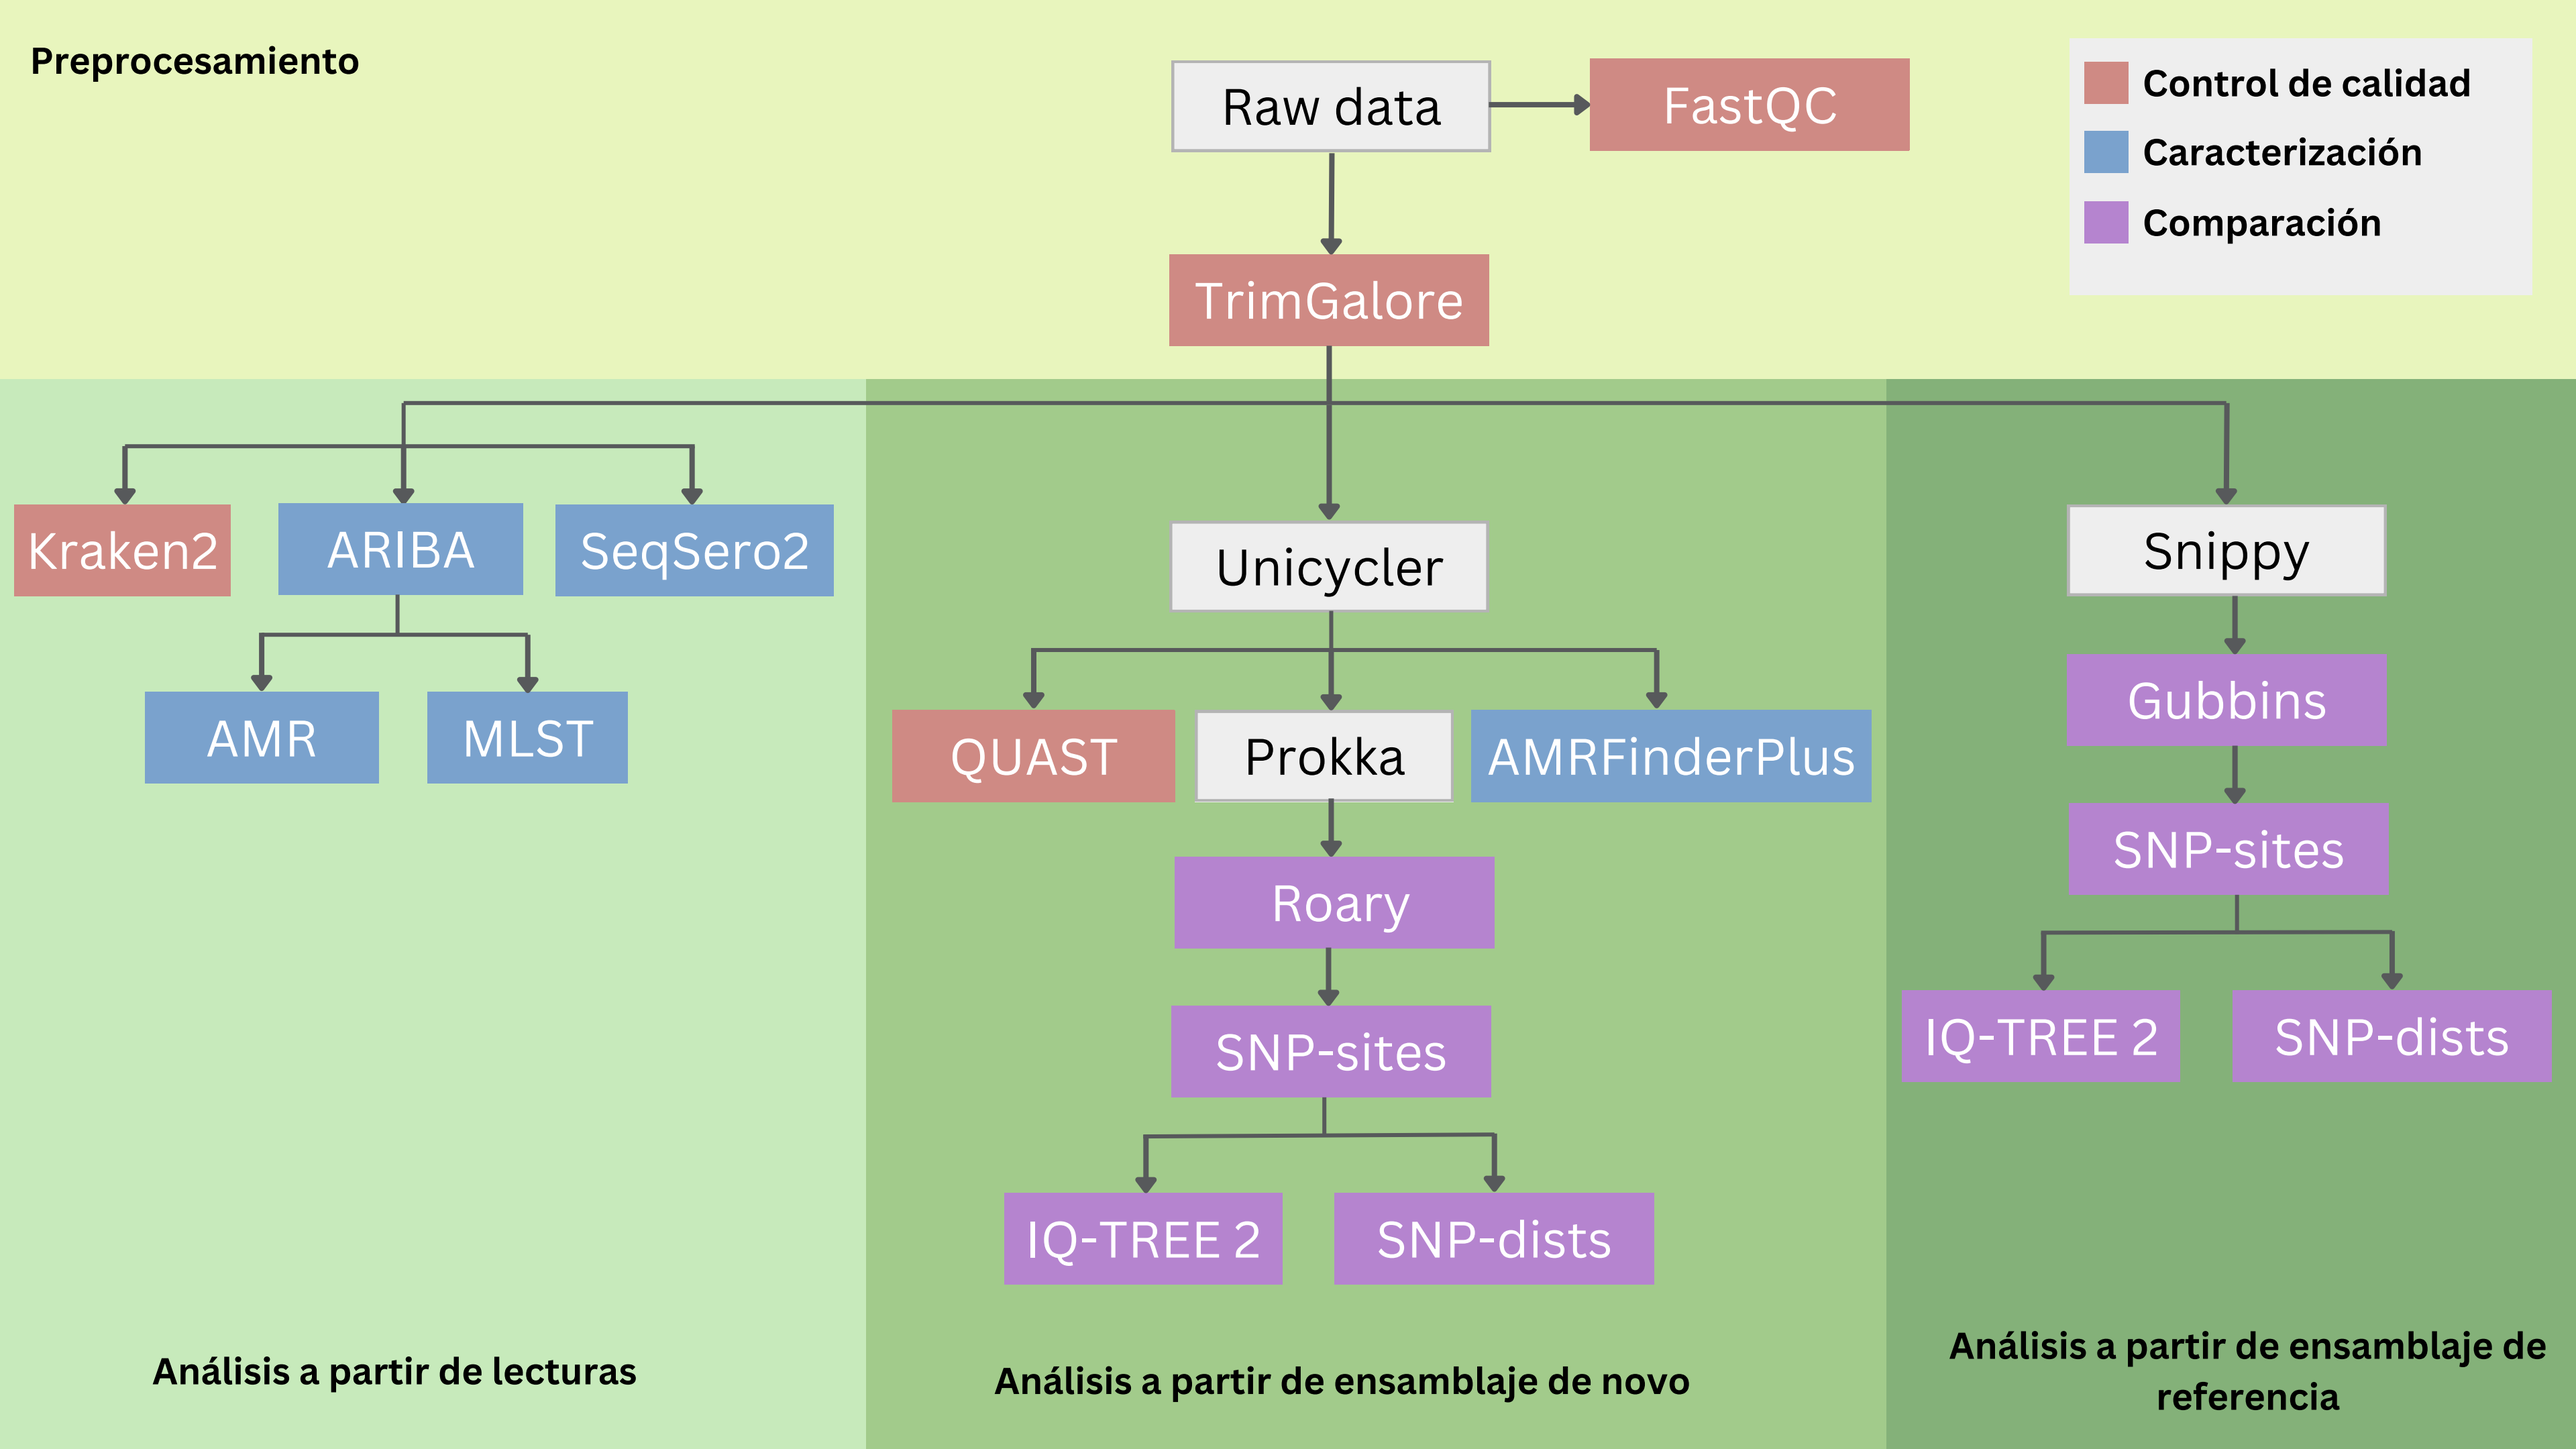
Preprocesamiento
Raw data
FastQC
Control de calidad
Caracterización
Comparación
TrimGalore
Kraken2
ARIBA
SeqSero2
AMR
MLST
Unicycler
QUAST
Prokka
AMRFinderPlus
Roary
SNP-sites
IQ-TREE 2
SNP-dists
Snippy
Gubbins
SNP-sites
IQ-TREE 2
SNP-dists
Análisis a partir de lecturas
Análisis a partir de ensamblaje de novo
Análisis a partir de ensamblaje de referencia

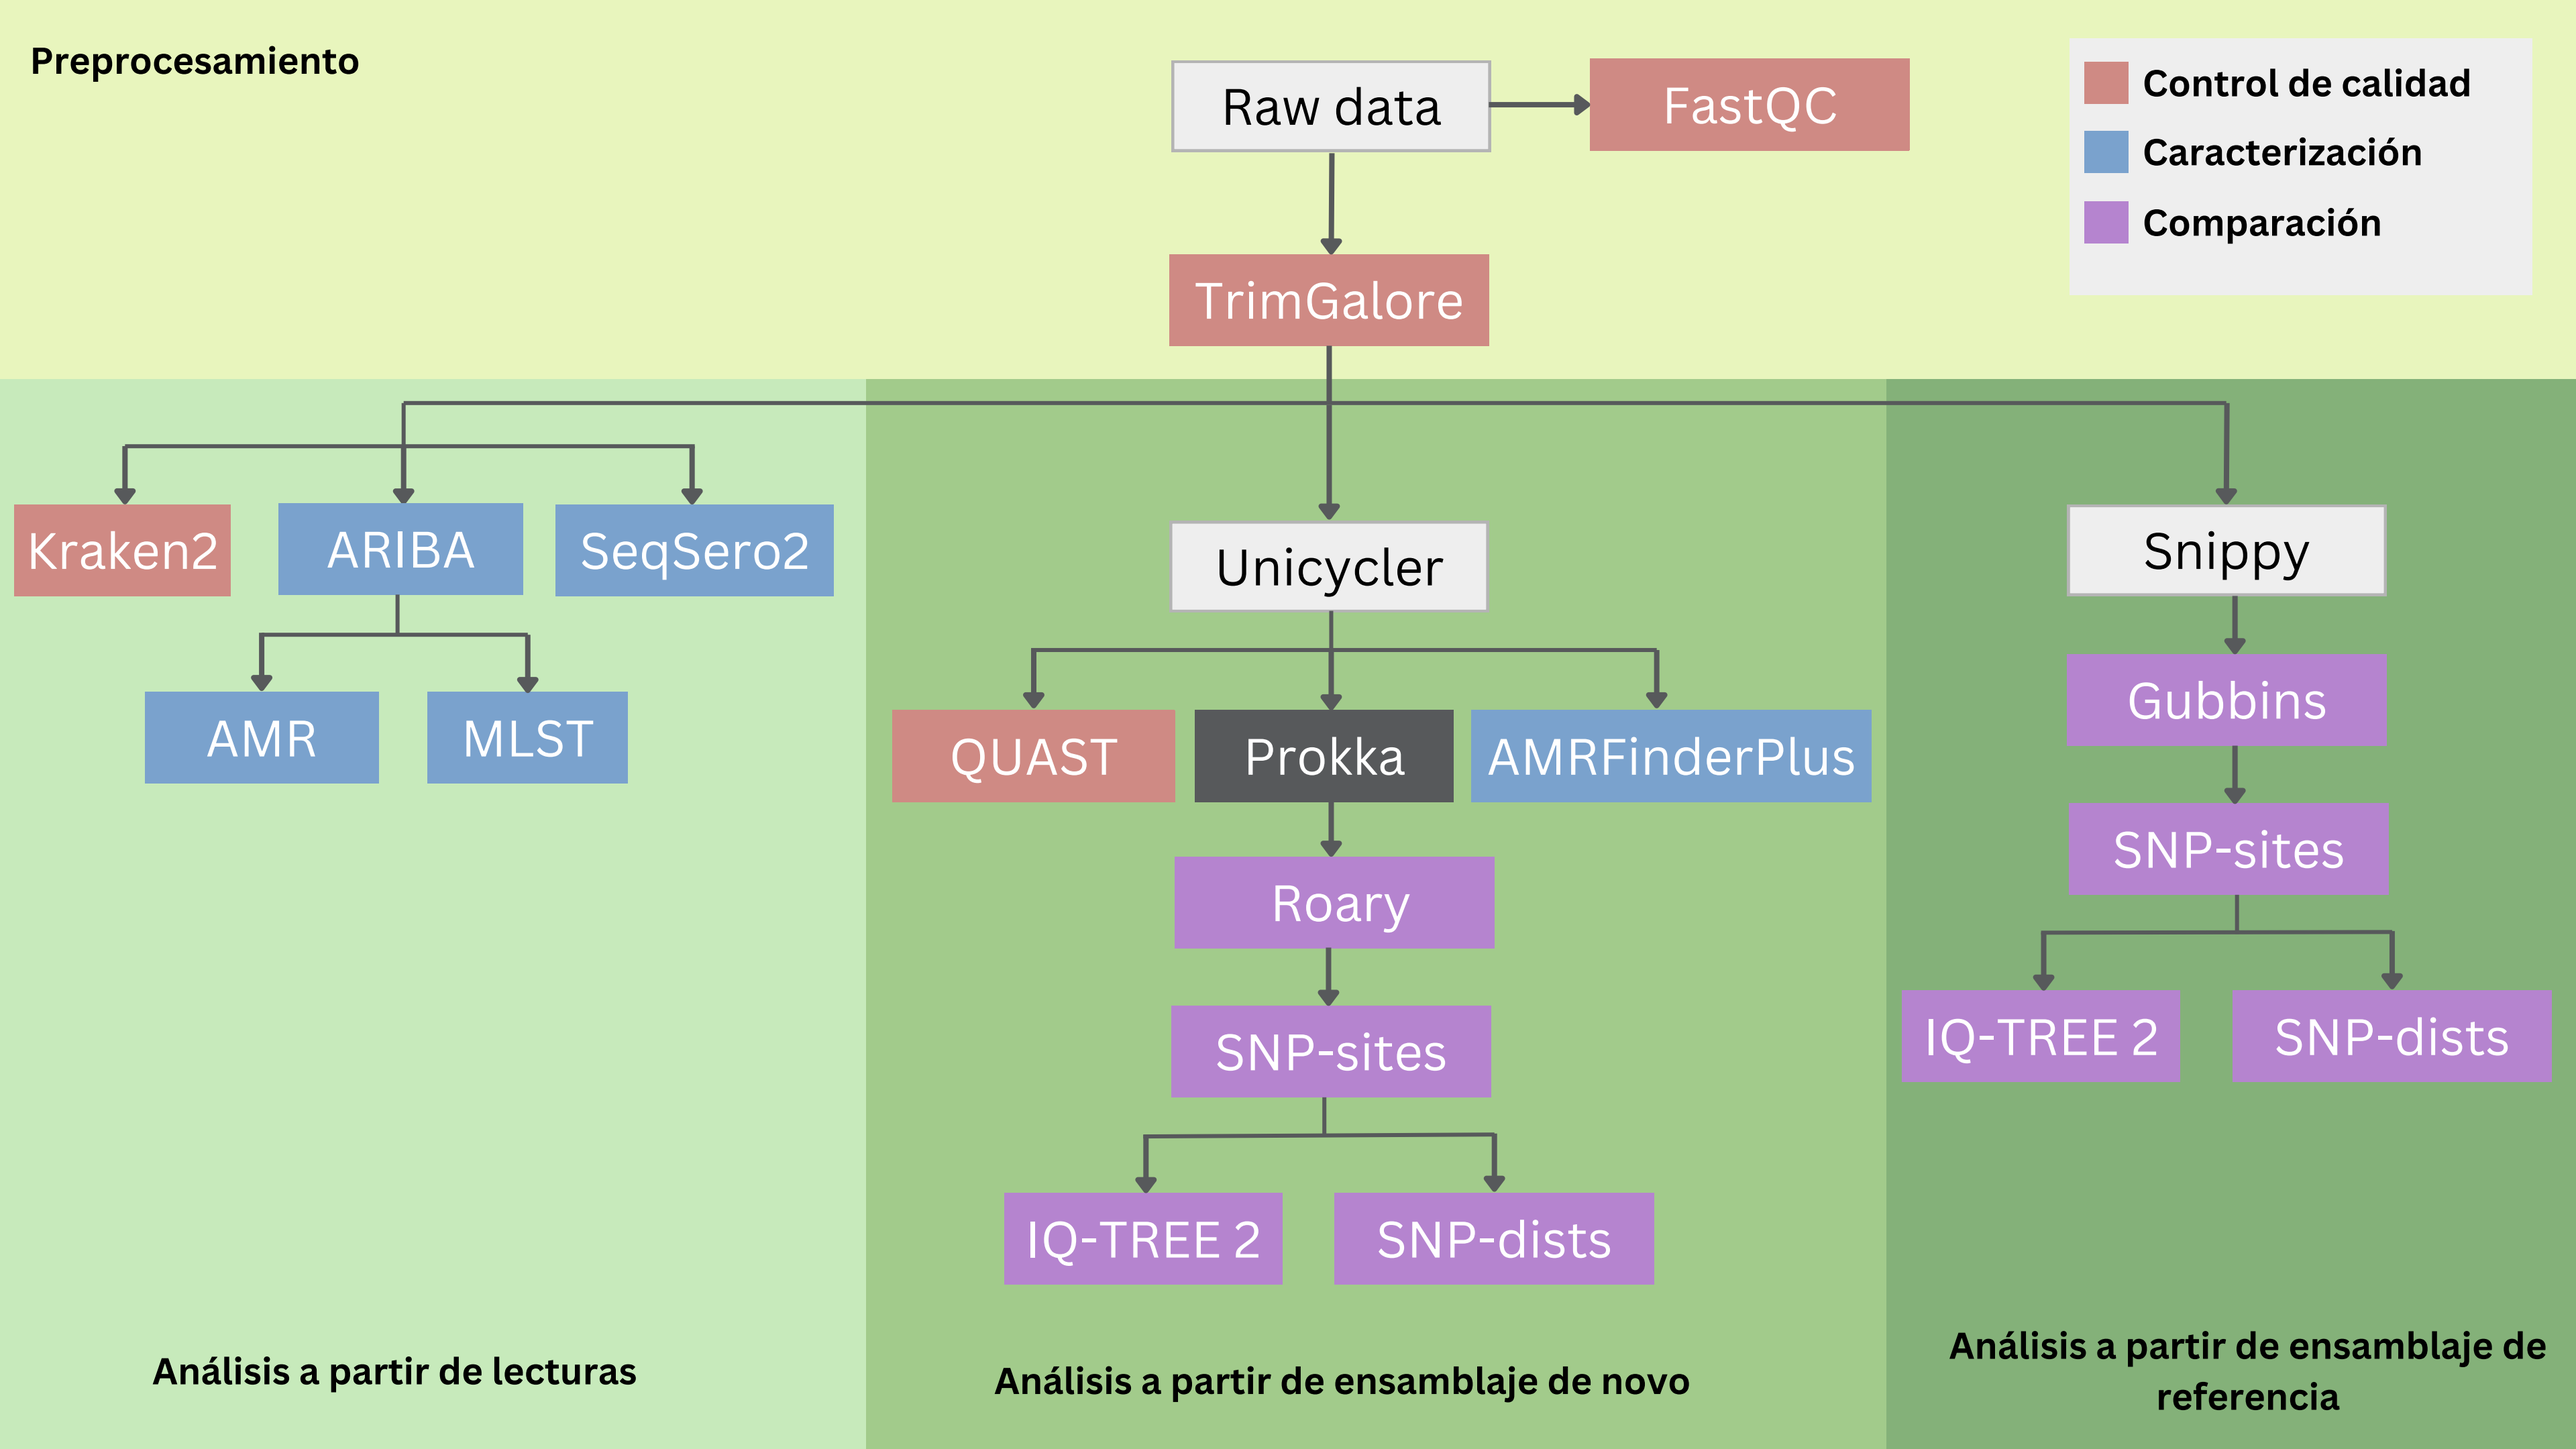
Preprocesamiento
Raw data
FastQC
Control de calidad
Caracterización
Comparación
TrimGalore
Kraken2
ARIBA
SeqSero2
AMR
MLST
Unicycler
QUAST
Prokka
AMRFinderPlus
Roary
SNP-sites
IQ-TREE 2
SNP-dists
Snippy
Gubbins
SNP-sites
IQ-TREE 2
SNP-dists
Análisis a partir de lecturas
Análisis a partir de ensamblaje de novo
Análisis a partir de ensamblaje de referencia

Prokka

Anotación genómica

Anotación estructural

Posiciones de las características genómicas a lo largo del genoma

Anotación funcional

Asignación de funciones a esas características

Prokka

Anotación genómica

Anotación estructural

Es el proceso de detectar y ubicar elementos genéticos en el genoma:

- Genes que codifican proteínas
- Regiones codificantes (ORFs)
- ARN no codificante (rRNA, tRNA, etc.)
- Elementos móviles (como fagos)

Prokka

Anotación genómica

Anotación estructural-Prodigal

Contig ATGAAATTTGGGCCCTAAATGCCCGGGTTTAA

Prokka

Anotación genómica

Anotación estructural-Prodigal

Buscar ORFs

Contig ATGAAATTTGGGCCCTAAATGCCCGGGTTTAA

Prokka

Anotación genómica

Anotación estructural-Prodigal

Buscar ORFs

Contig ATGAAATTTGGGCCCTAAATGCCCGGGTTTAA

Codones de inicio	Codones de stop
ATG	TAA
GTG	TAG
TTG	TGA

Prokka

Anotación genómica

Anotación estructural-Prodigal

Buscar ORFs

Contig **ATG**AAATTTGGGCCC**TAA**ATGCCCGGGTTTAA

Codones de inicio	Codones de stop
ATG	TAA
GTG	TAG
TTG	TGA

Prokka

Anotación genómica

Anotación estructural-Prodigal

Buscar ORFs

Contig ATGAAATTTGGGCCCTAAATGCCCGGGTTTAA

ORF1 ATG AAA TTT GGG CCC TAA

Prokka

Anotación genómica

Anotación estructural-Prodigal

Evaluar si es un gen real

ORF1 ATG AAA TTT GGG CCC TAA

- Longitud (muy cortos suelen descartarse)
- Uso de codones (determinar si son genes reales)
- Señal RBS antes del inicio

Prokka

Anotación genómica

Anotación funcional

Es el proceso de asignar una función biológica a los genes o proteínas predichas:

- Qué proteína producen
- Qué hace esa proteína (enzima, transporte, defensa, etc.)
- En qué procesos participa

Prokka

Anotación genómica

Anotación funcional

RBS

delta toxin

```
ACCATTTCGCCCGGGAGACACGCGGATTACACCTATGAGCAGAAATA
CGGCCTGCGCGATTACCGCGGCGGTGGACGTTCTTCCGCGCGTGAAA
CCGCGATGCGCGTAGCGGCAGGGGCGATCGCCAAGAAATACTTGGCG
GAAAAGTTCGGCATCGAAATCCGCGGCTGCCTGACCCAGATGGGCGA
CATTCCGCTGGAGATTAAAGACTGGCGTCAGGTTGAGCTTAATCCGT
TCTGGCGGTGGACGTTCTTCCGCGCGTGAAACCGCGATGCGCGTAGC
GGCAGGGGCGATCGCCAAGAAATACCTGGCGGAAAAGTTCGGCATCG
AAATCCGCGGCTGCCTGACCCAGATGGGCGACATTCCGCTGGAGATT
AAAGACTGGCGTCAGGTTGAGCTTAATCCGTTTTTTTTGCCC
```

Transfer RNA

Homopolymer

Prokka

Anotación genómica

Anotación funcional

Query MKKTAIAIAVALAGFATVAQ

BLASTP

```
Query      MKKTAIAIAVALAGFATVAQ
           | | | | | | | | | | | | | | | | | | | |
Database   MKKTAIAIAVALAGFATVAQ
```

Prokka

Anotación genómica

Anotación funcional

Alineamiento múltiple por familia

MKKTAIAIAVALAGFATVAQ
MKKTAIAIAVALAGFATVAQ
MKKTAIAIAVALAGYATVAQ

HMMER

Probabilidades

aminoácido	probabilidad
F	0.8
Y	0.2

Prokka

```
0  ##gff-version 3.2.1
1  ##sequence-region ctg123 1 1497228
2  ctg123 . gene            1000  9000  .  +  .  ID=gene00001;Name=EDEN
3  ctg123 . TF_binding_site 1000  1012  .  +  .  ID=tfbs00001;Parent=gene00001
4  ctg123 . mRNA            1050  9000  .  +  .  ID=mRNA00001;Parent=gene00001;Name=EDEN.1
5  ctg123 . mRNA            1050  9000  .  +  .  ID=mRNA00002;Parent=gene00001;Name=EDEN.2
6  ctg123 . mRNA            1300  9000  .  +  .  ID=mRNA00003;Parent=gene00001;Name=EDEN.3
7  ctg123 . exon            1300  1500  .  +  .  ID=exon00001;Parent=mRNA00003
8  ctg123 . exon            1050  1500  .  +  .  ID=exon00002;Parent=mRNA00001,mRNA00002
9  ctg123 . exon            3000  3902  .  +  .  ID=exon00003;Parent=mRNA00001,mRNA00003
10 ctg123 . exon            5000  5500  .  +  .  ID=exon00004;Parent=mRNA00001,mRNA00002,mRNA00003
11 ctg123 . exon            7000  9000  .  +  .  ID=exon00005;Parent=mRNA00001,mRNA00002,mRNA00003
12 ctg123 . CDS             1201  1500  .  +  0  ID=cds00001;Parent=mRNA00001;Name=edenprotein.1
13 ctg123 . CDS             3000  3902  .  +  0  ID=cds00001;Parent=mRNA00001;Name=edenprotein.1
14 ctg123 . CDS             5000  5500  .  +  0  ID=cds00001;Parent=mRNA00001;Name=edenprotein.1
15 ctg123 . CDS             7000  7600  .  +  0  ID=cds00001;Parent=mRNA00001;Name=edenprotein.1
16 ctg123 . CDS             1201  1500  .  +  0  ID=cds00002;Parent=mRNA00002;Name=edenprotein.2
17 ctg123 . CDS             5000  5500  .  +  0  ID=cds00002;Parent=mRNA00002;Name=edenprotein.2
18 ctg123 . CDS             7000  7600  .  +  0  ID=cds00002;Parent=mRNA00002;Name=edenprotein.2
19 ctg123 . CDS             3301  3902  .  +  0  ID=cds00003;Parent=mRNA00003;Name=edenprotein.3
20 ctg123 . CDS             5000  5500  .  +  1  ID=cds00003;Parent=mRNA00003;Name=edenprotein.3
21 ctg123 . CDS             7000  7600  .  +  1  ID=cds00003;Parent=mRNA00003;Name=edenprotein.3
22 ctg123 . CDS             3391  3902  .  +  0  ID=cds00004;Parent=mRNA00003;Name=edenprotein.4
23 ctg123 . CDS             5000  5500  .  +  1  ID=cds00004;Parent=mRNA00003;Name=edenprotein.4
24 ctg123 . CDS             7000  7600  .  +  1  ID=cds00004;Parent=mRNA00003;Name=edenprotein.4
```

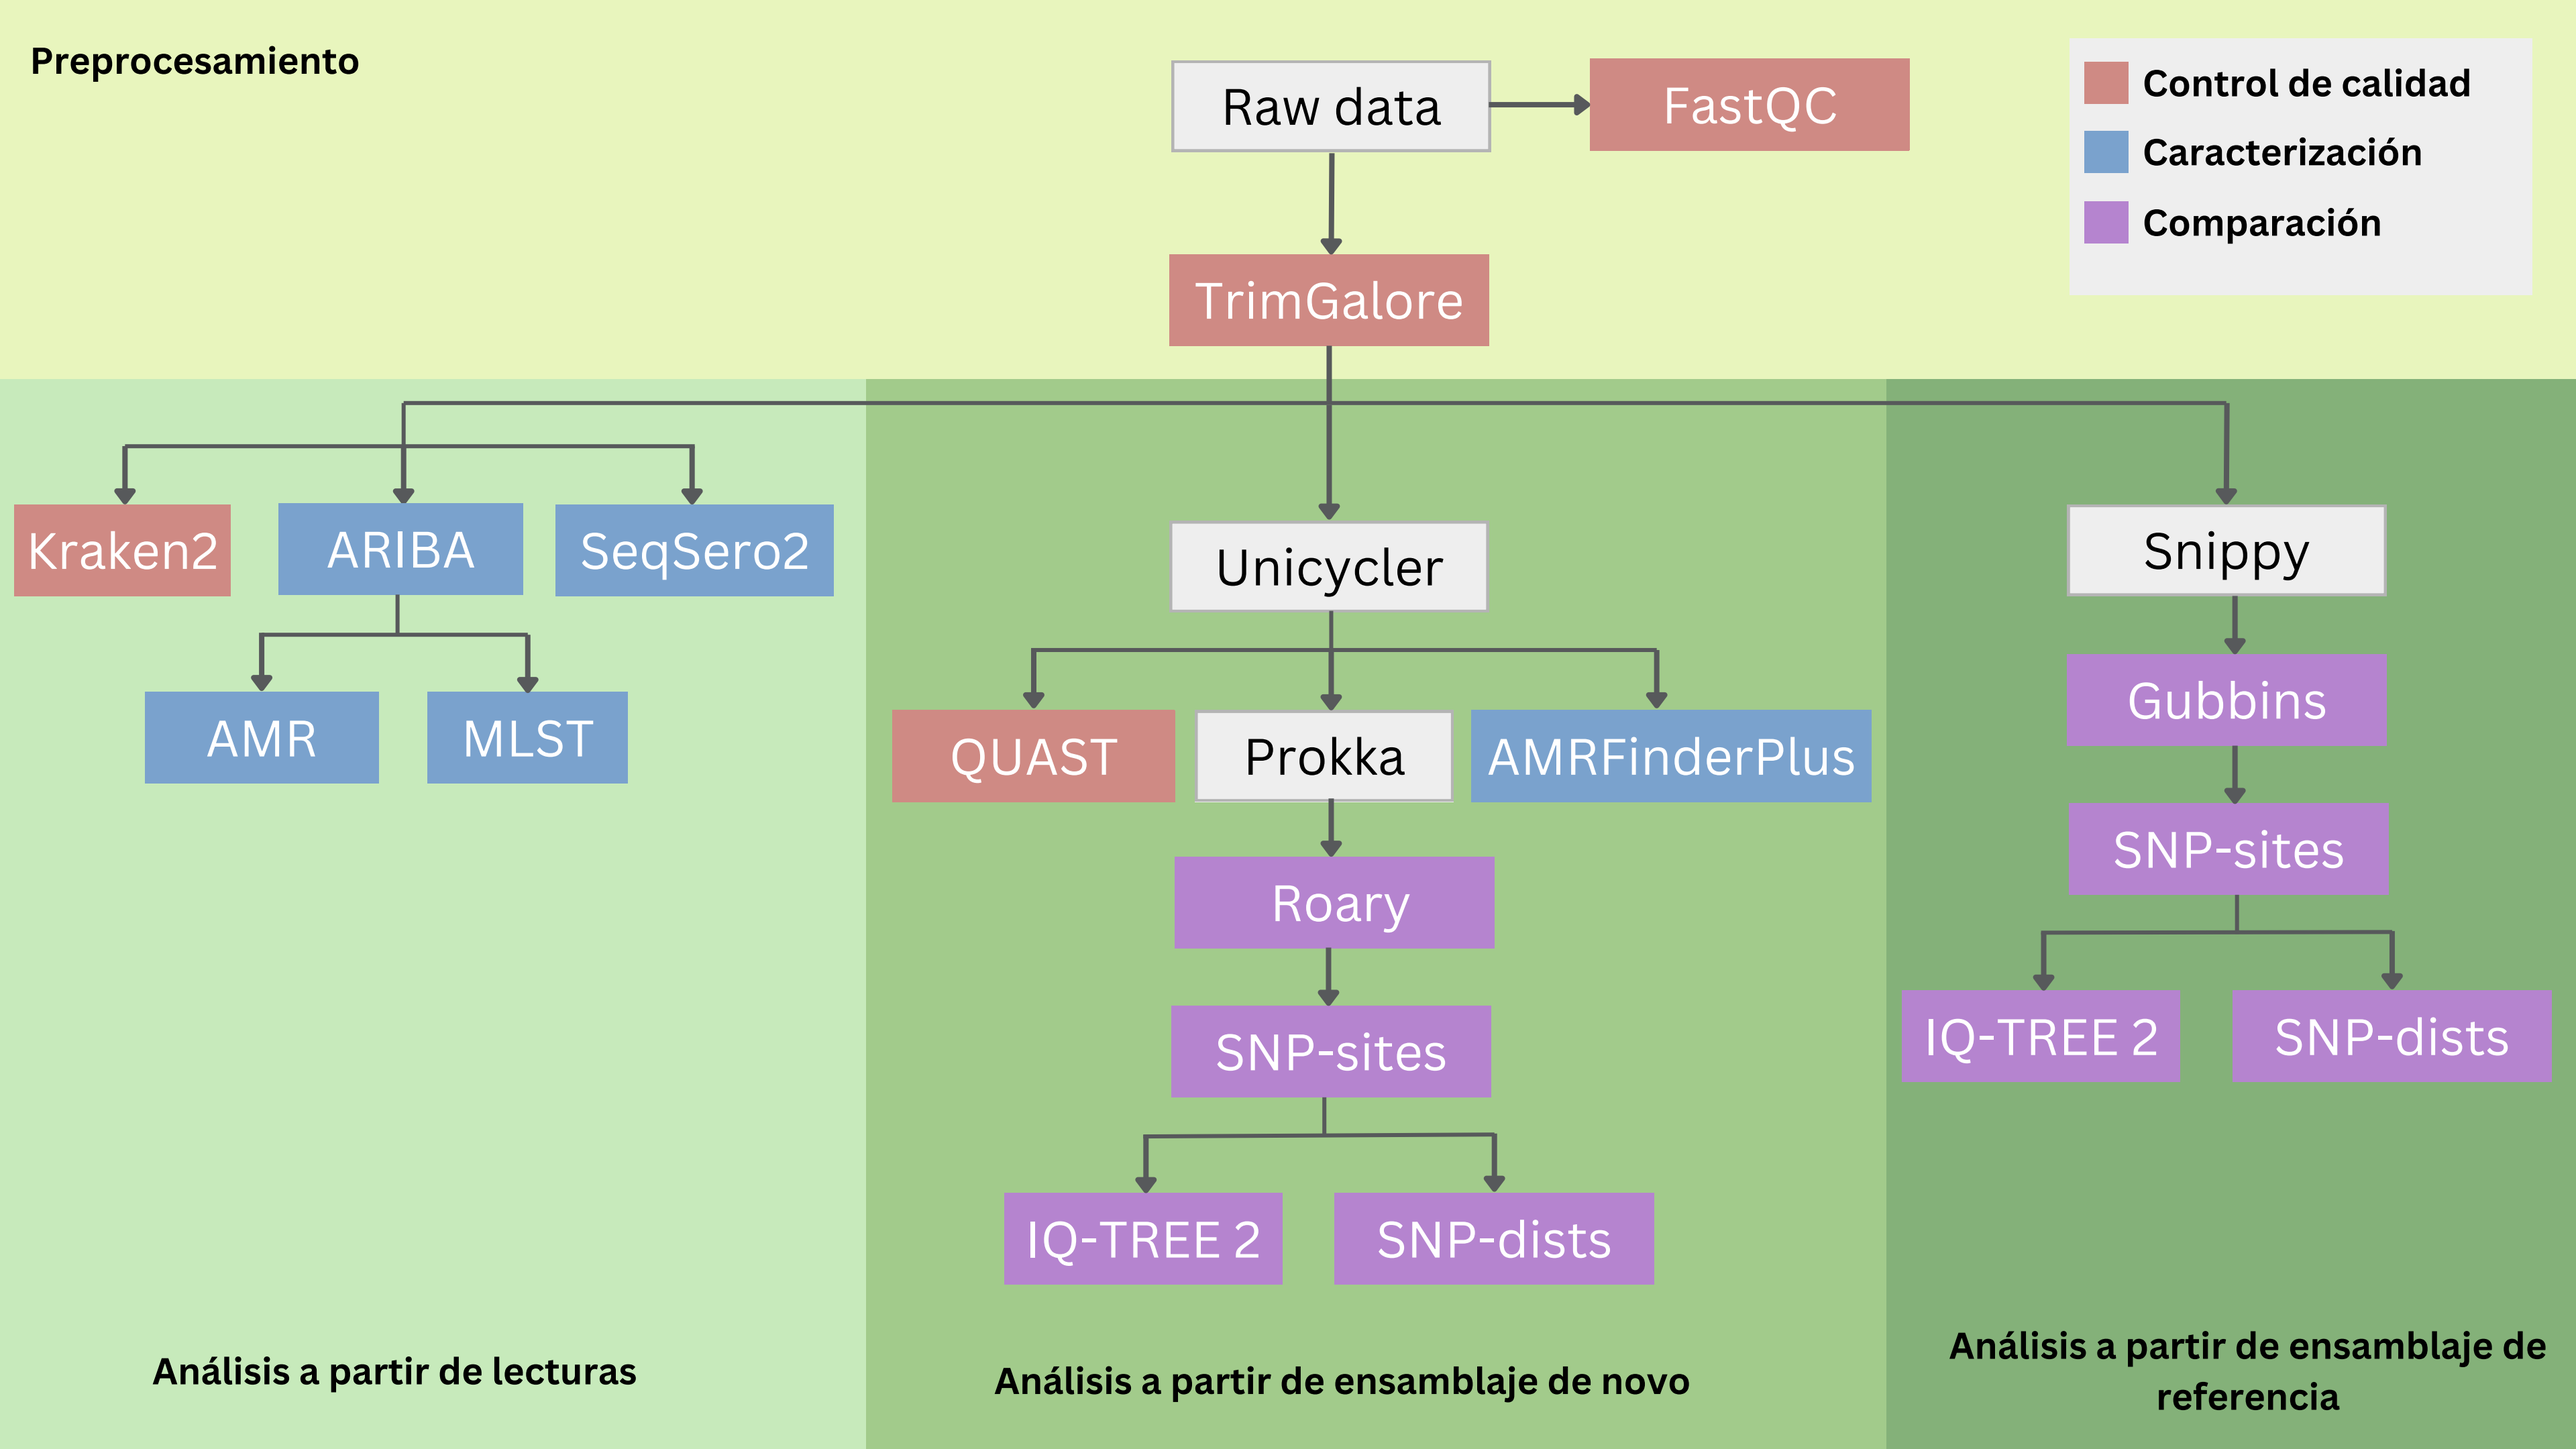
Preprocesamiento
Raw data
FastQC
Control de calidad
Caracterización
Comparación
TrimGalore
Kraken2
ARIBA
SeqSero2
AMR
MLST
Unicycler
QUAST
Prokka
AMRFinderPlus
Roary
SNP-sites
IQ-TREE 2
SNP-dists
Snippy
Gubbins
SNP-sites
IQ-TREE 2
SNP-dists
Análisis a partir de lecturas
Análisis a partir de ensamblaje de novo
Análisis a partir de ensamblaje de referencia

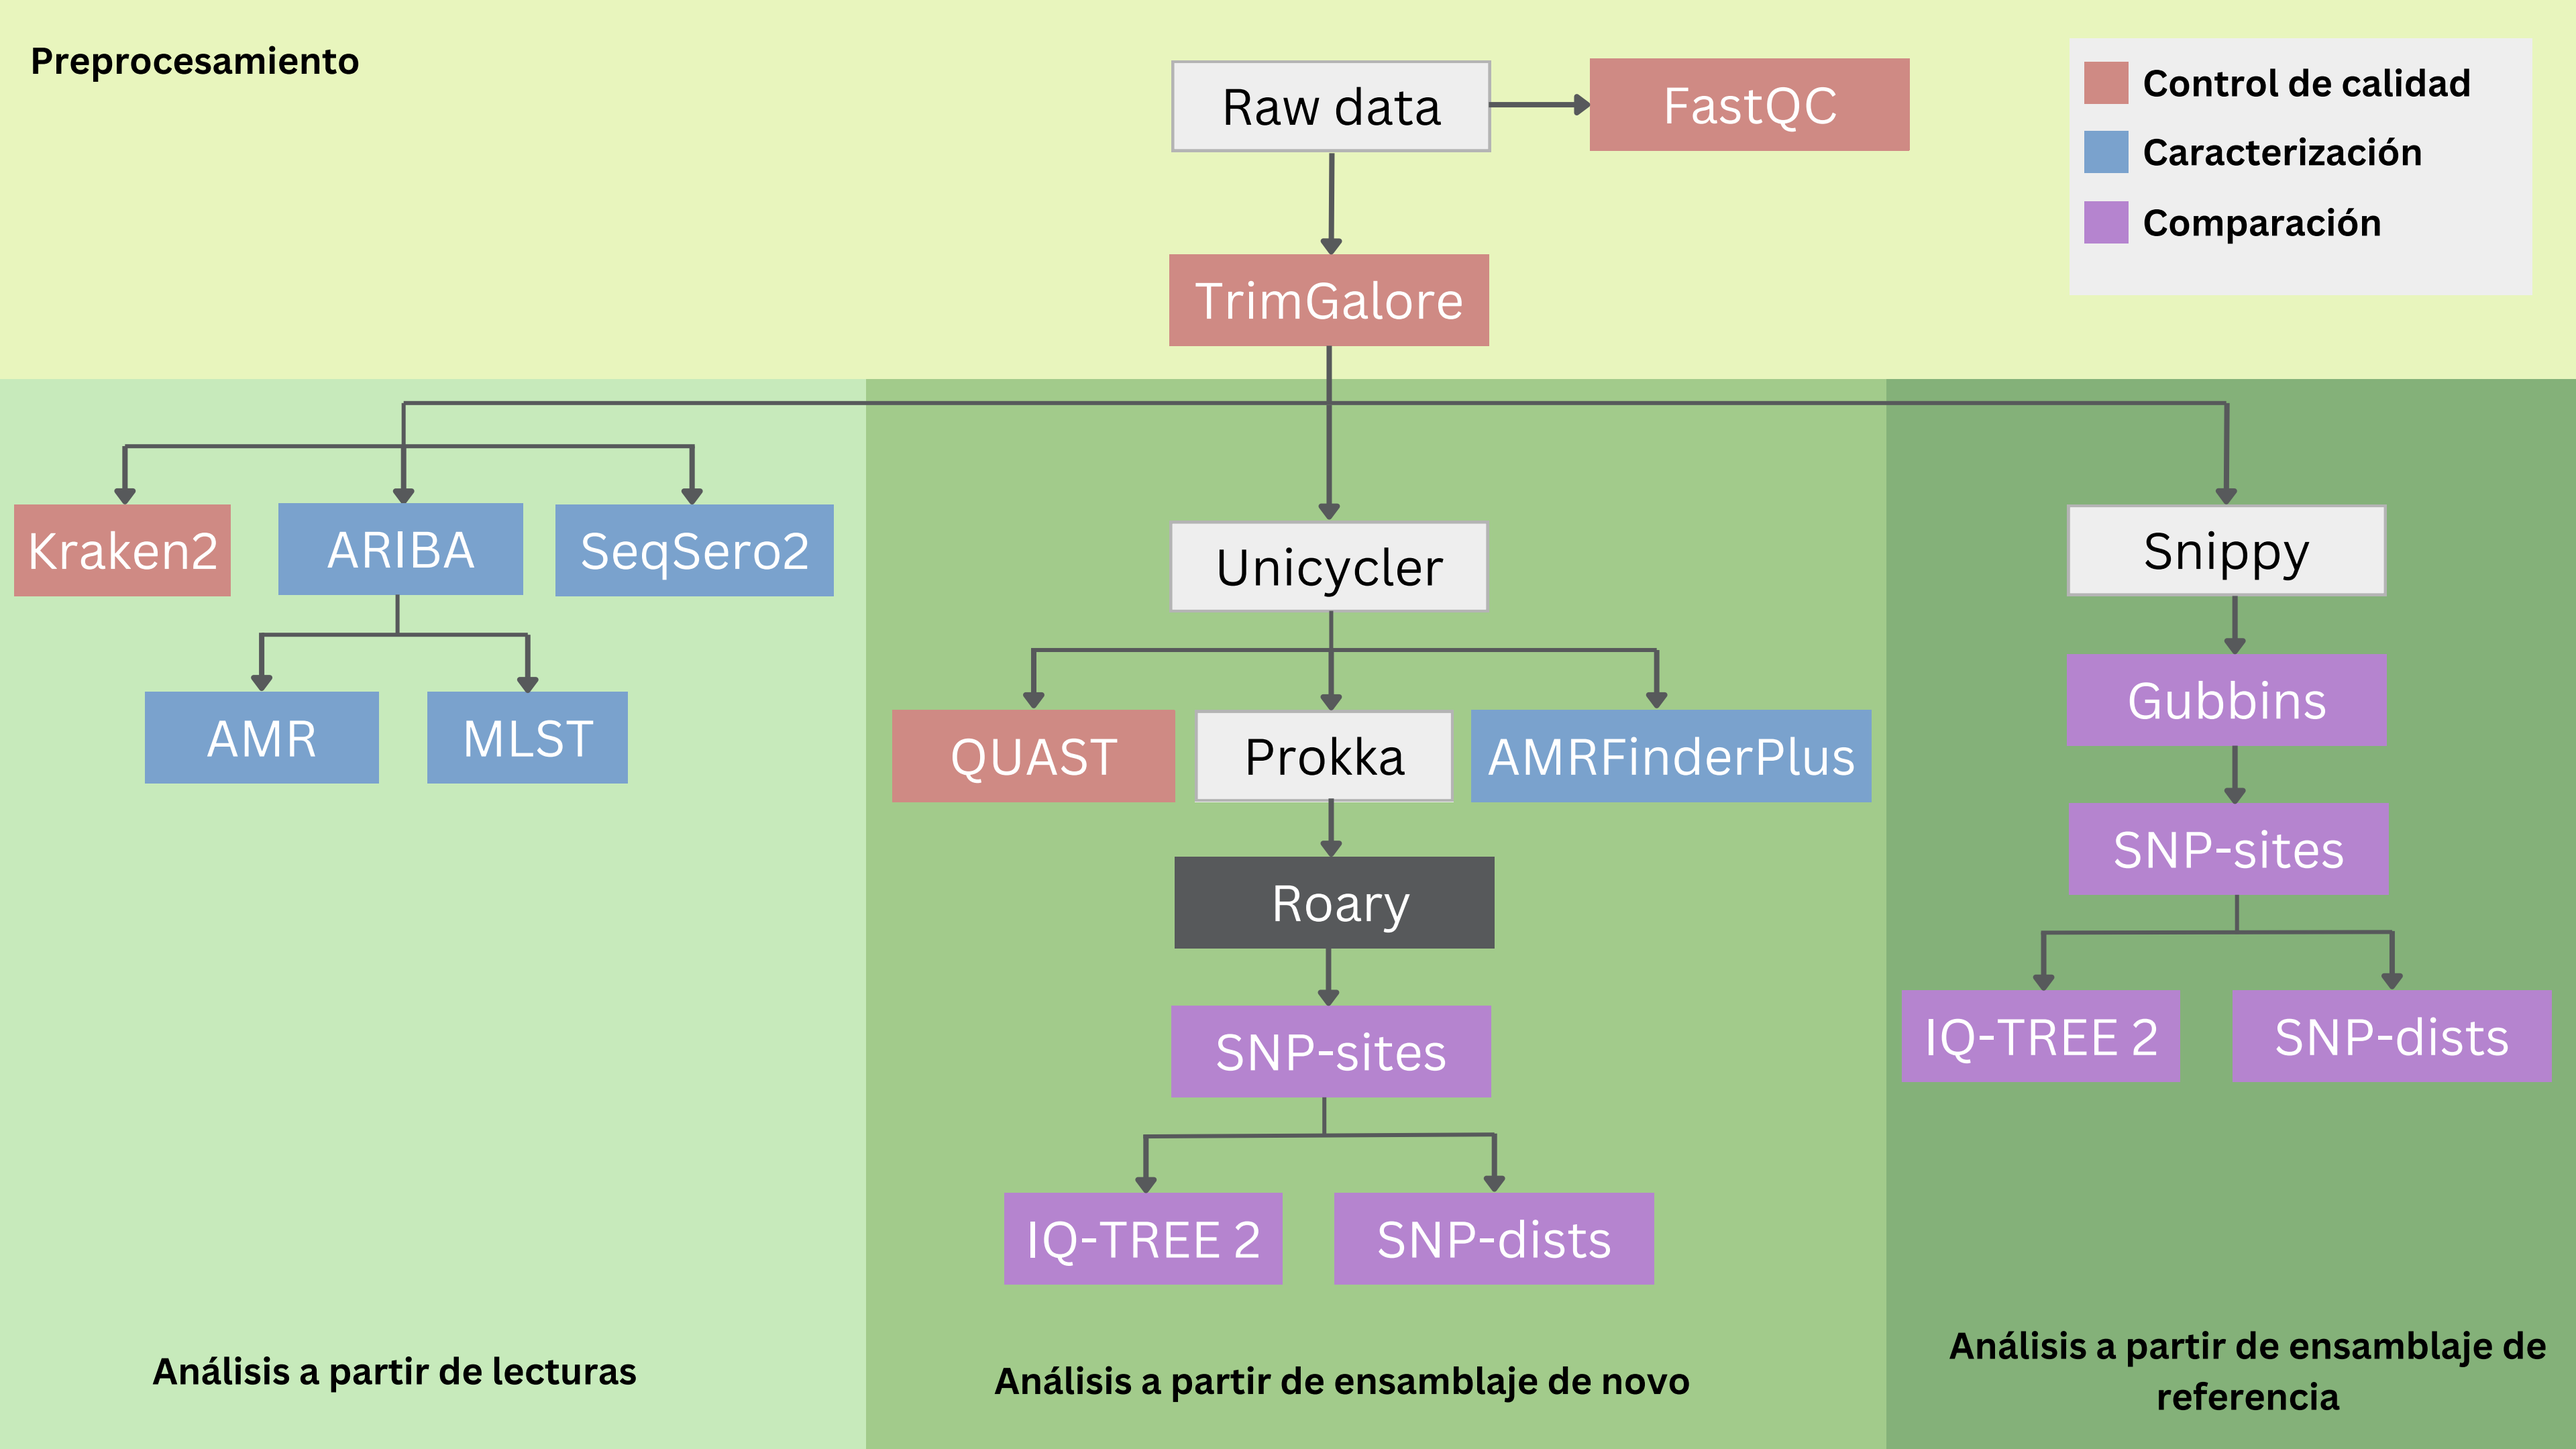
Preprocesamiento
Raw data
FastQC
Control de calidad
Caracterización
Comparación
TrimGalore
Kraken2
ARIBA
SeqSero2
AMR
MLST
Unicycler
QUAST
Prokka
AMRFinderPlus
Roary
SNP-sites
IQ-TREE 2
SNP-dists
Snippy
Gubbins
SNP-sites
IQ-TREE 2
SNP-dists
Análisis a partir de lecturas
Análisis a partir de ensamblaje de novo
Análisis a partir de ensamblaje de referencia

Roary

Pangenoma

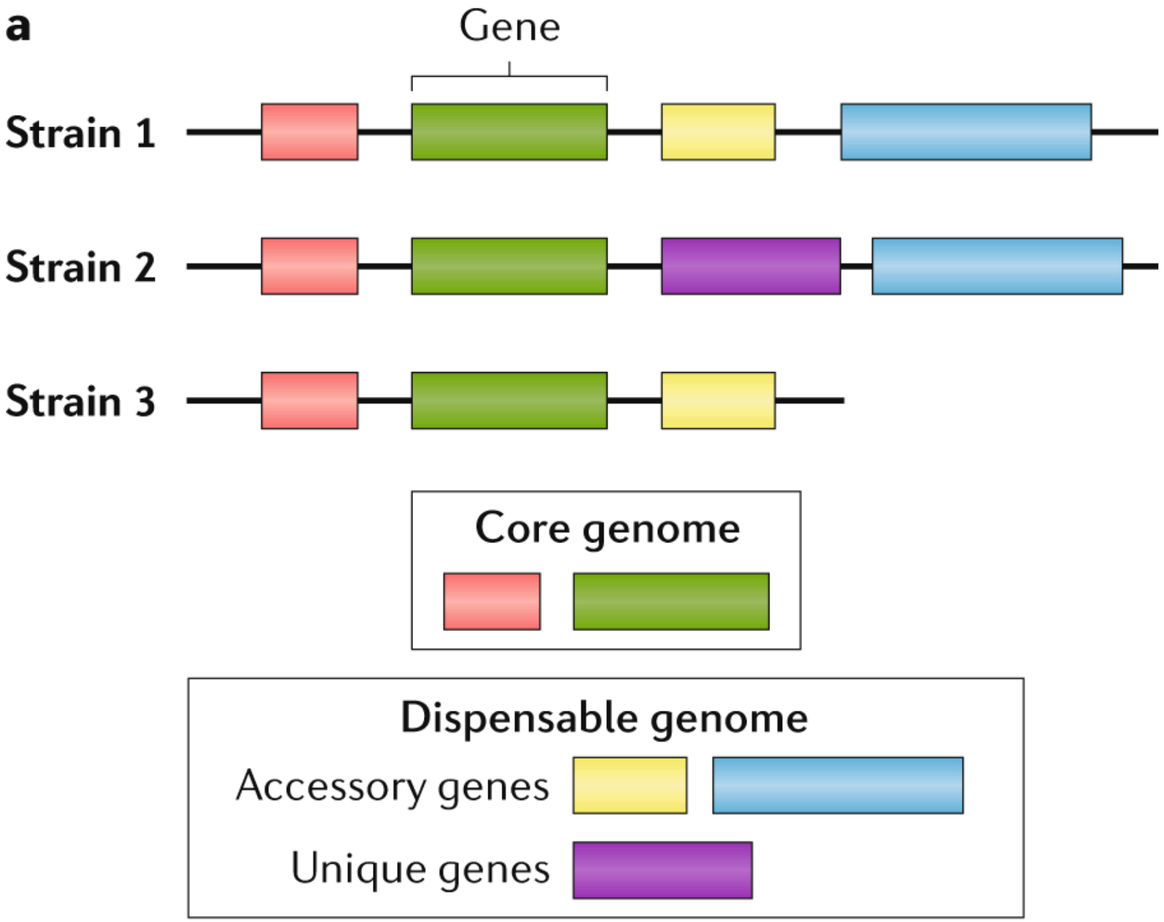

https://doi.org/10.1038/s41576-020-0210-7

Conjunto total de genes que se encuentran en todas las cepas de una misma especie bacteriana

Roary

Genoma central

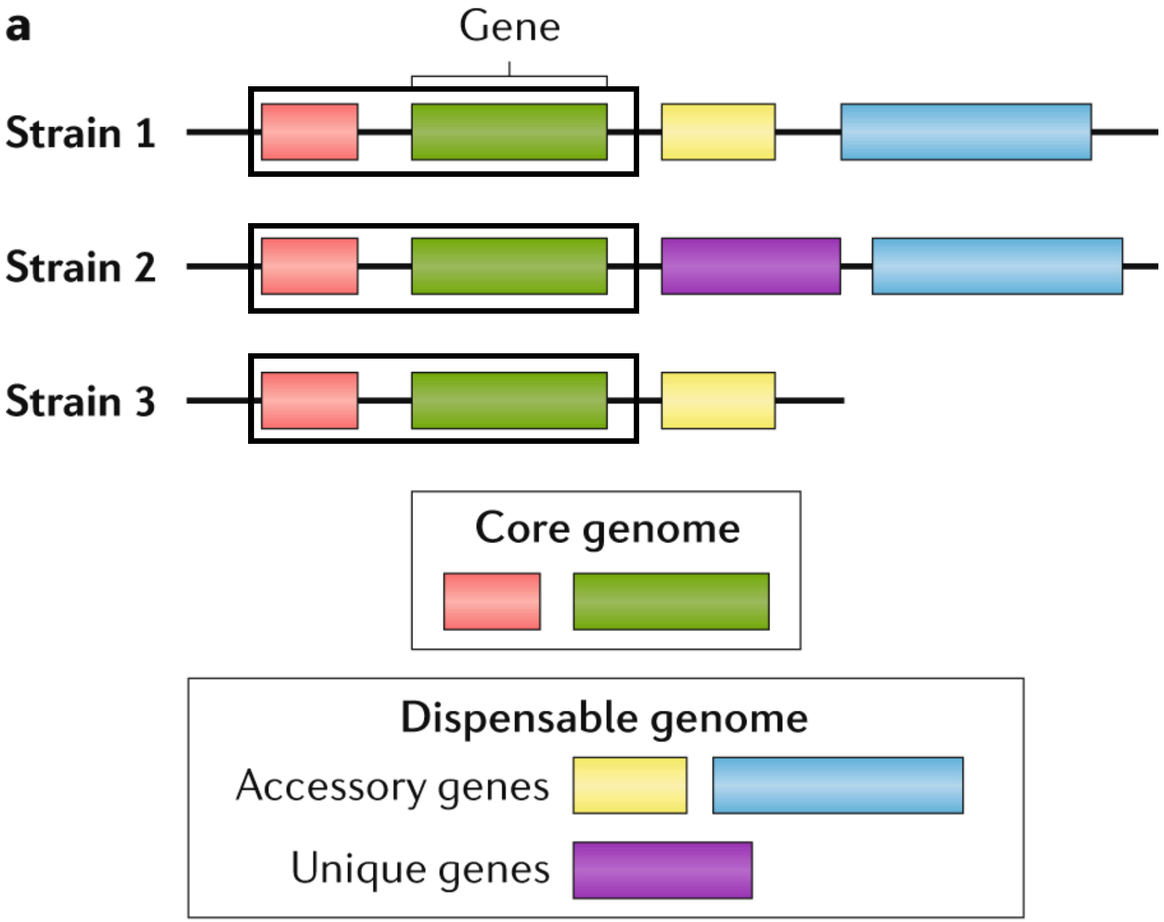

https://doi.org/10.1038/s41576-020-0210-7

Genes que comparten todas las cepas

Relacionados con funciones básicas esenciales

Roary

Genoma accesorio

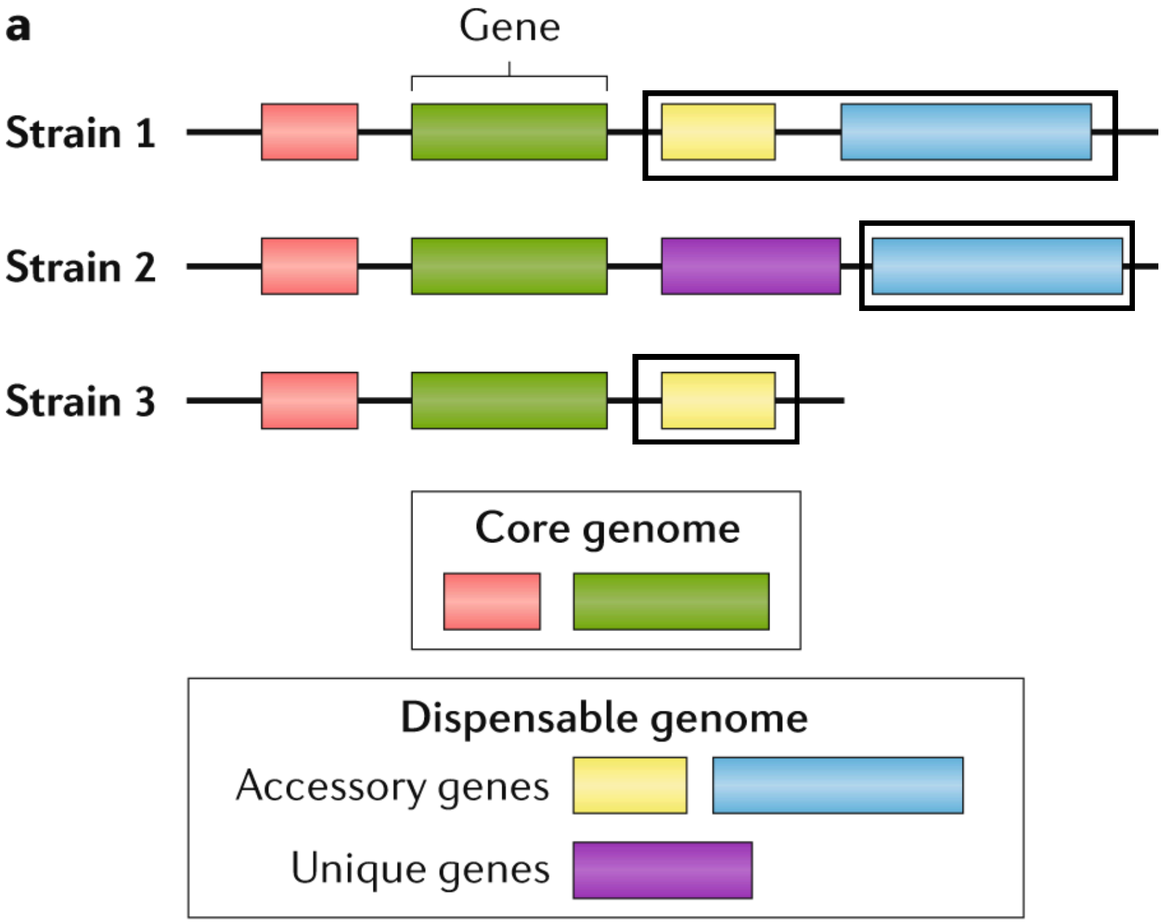

https://doi.org/10.1038/s41576-020-0210-7

Genes presentes en algunas, pero no todas, las cepas

Brindan ventajas adaptativas, como resistencia a antibióticos

Roary

Genes únicos

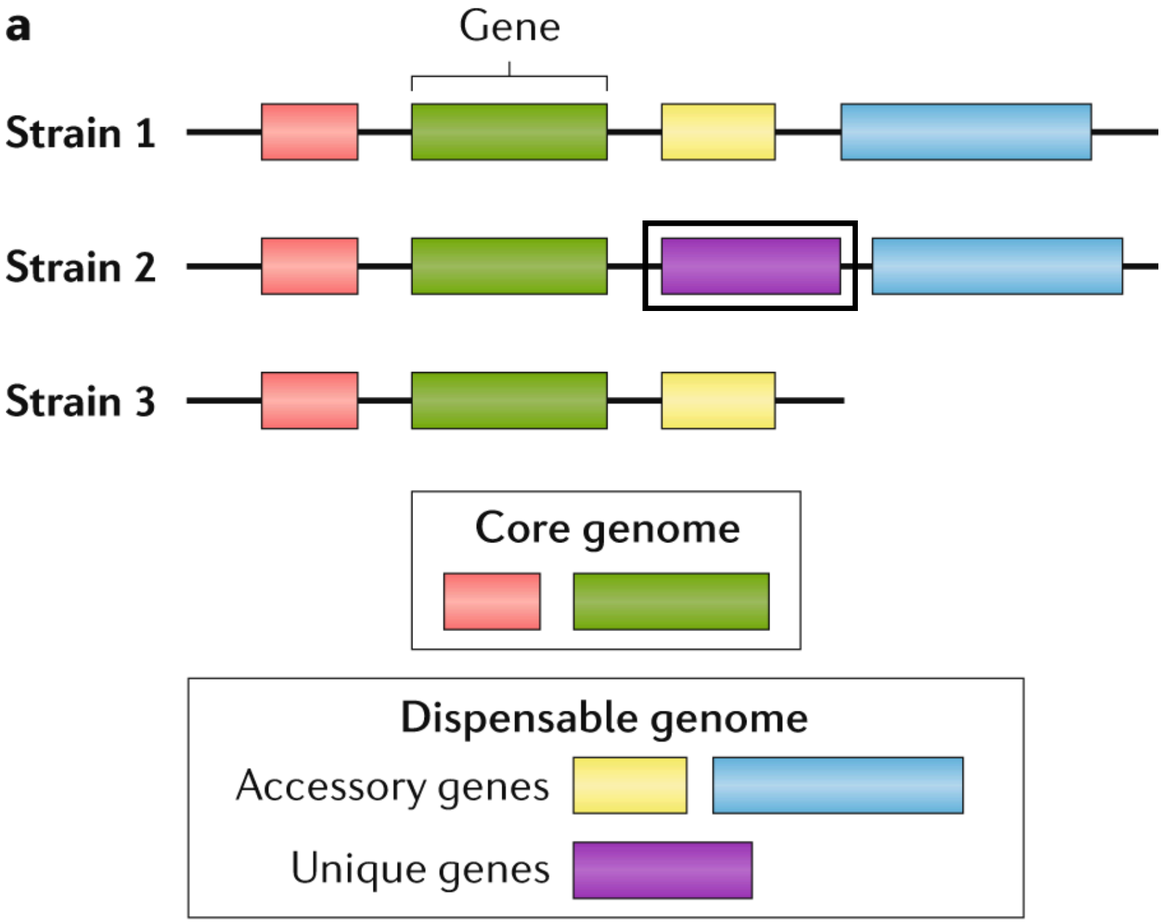

https://doi.org/10.1038/s41576-020-0210-7

Genes exclusivos de una sola cepa

Asociados a adaptaciones muy específicas

Roary

Pangenoma

Extracción de proteínas

Genoma A	geneA1, geneB1, geneC1
Genoma B	geneA2, geneB2, geneD1
Genoma C	geneA3, geneB3, geneE1

Roary

Pangenoma

Genoma	Proteínas
A	geneA1, geneB1, geneC1
B	geneA2, geneB2, geneD1
C	geneA3, geneB3, geneE1

Extracción de proteínas

Roary

Pangenoma

Agrupación por clúster CD-HIT

geneA1 ≈ geneA2 ≈ geneA3 **Clúster temporal 1**

geneB1 ≈ geneB2 ≈ geneB3 **Clúster temporal 2**

Roary

Pangenoma

BLAST

```
geneA1    MKKTAIAIAVALAGFATVAQ
          | | | | | | | | | | | | | | | | | | | |
geneA2    MKKTAIAIAVALAGFATVAQ
```

% identidad
95%

e-value
1e-50

Roary

Pangenoma

grafo de similitud

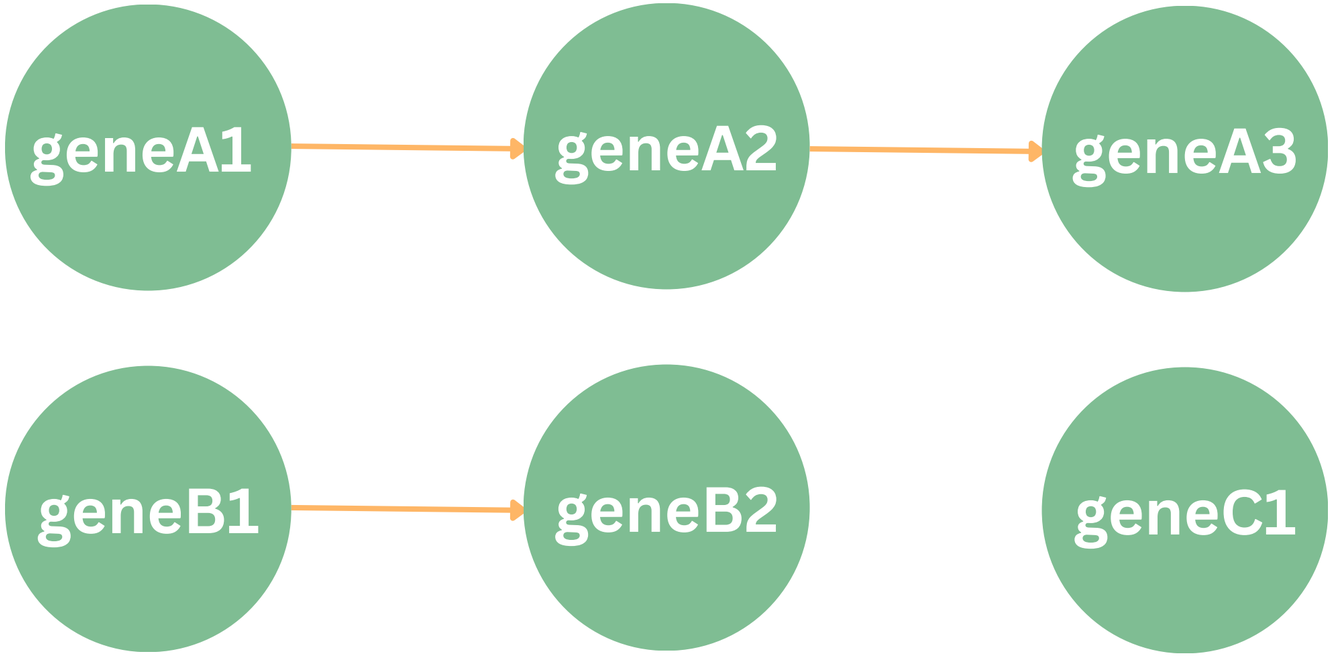

Markov Clustering (MCL)

Clúster 1

geneA1, geneA2, geneA3

Clúster 2

geneB1, geneB2

Roary

Pangenoma

Construcción de la matriz presencia/ausencia

Clúster	Genoma A	Genoma B	Genoma C
Cluster1	1	1	1
Cluster2	1	1	1
Cluster3	1	0	0
Cluster4	0	1	0
Cluster5	0	0	1

Roary

Pangenoma

Definición del pangenoma

Clúster	Genoma A	Genoma B	Genoma C
Cluster1	1	1	1
Cluster2	1	1	1
Cluster3	1	0	0
Cluster4	0	1	0
Cluster5	0	0	1

Roary

Pangenoma

Definición del pangenoma

Core genome (genes presentes en todos los genomas)

Cluster1, Cluster2: geneA y geneB

Accessory genome (presentes en algunos genomas)

Cluster3, Cluster4, Cluster5: geneC, geneD, geneE

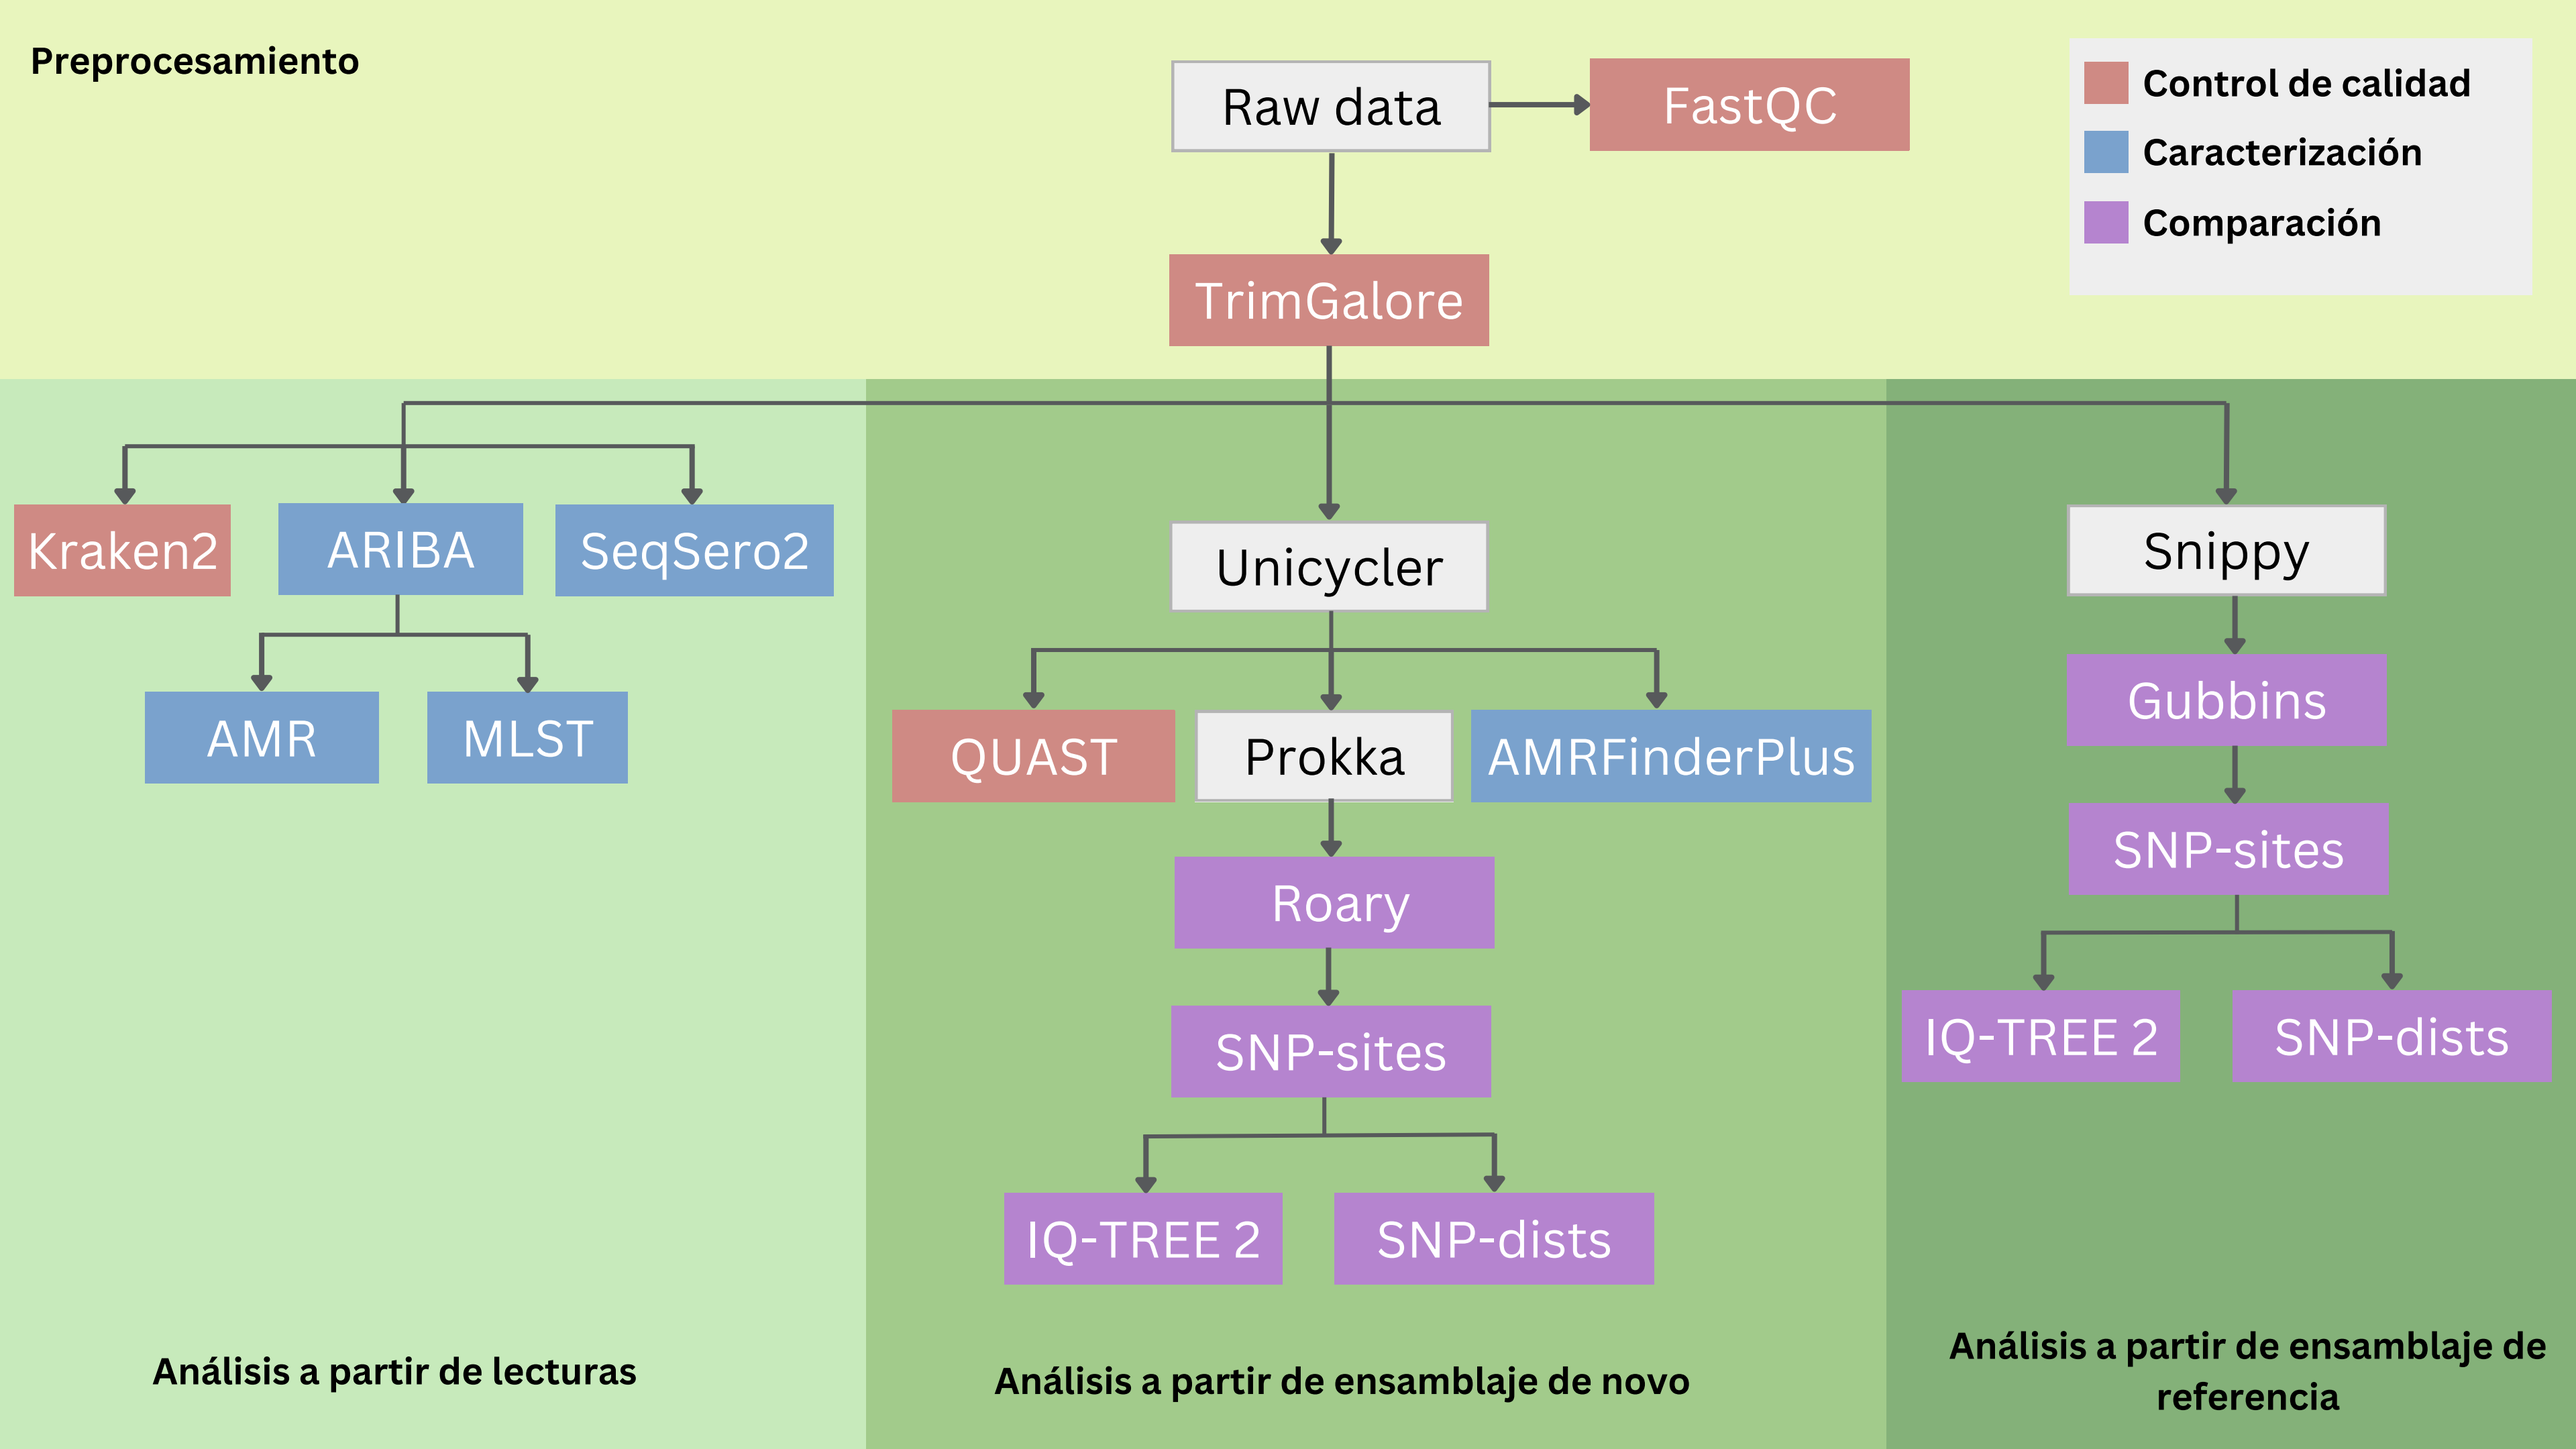
Preprocesamiento
Raw data
FastQC
Control de calidad
Caracterización
Comparación
TrimGalore
Kraken2
ARIBA
SeqSero2
AMR
MLST
Unicycler
QUAST
Prokka
AMRFinderPlus
Roary
SNP-sites
IQ-TREE 2
SNP-dists
Snippy
Gubbins
SNP-sites
IQ-TREE 2
SNP-dists
Análisis a partir de lecturas
Análisis a partir de ensamblaje de novo
Análisis a partir de ensamblaje de referencia

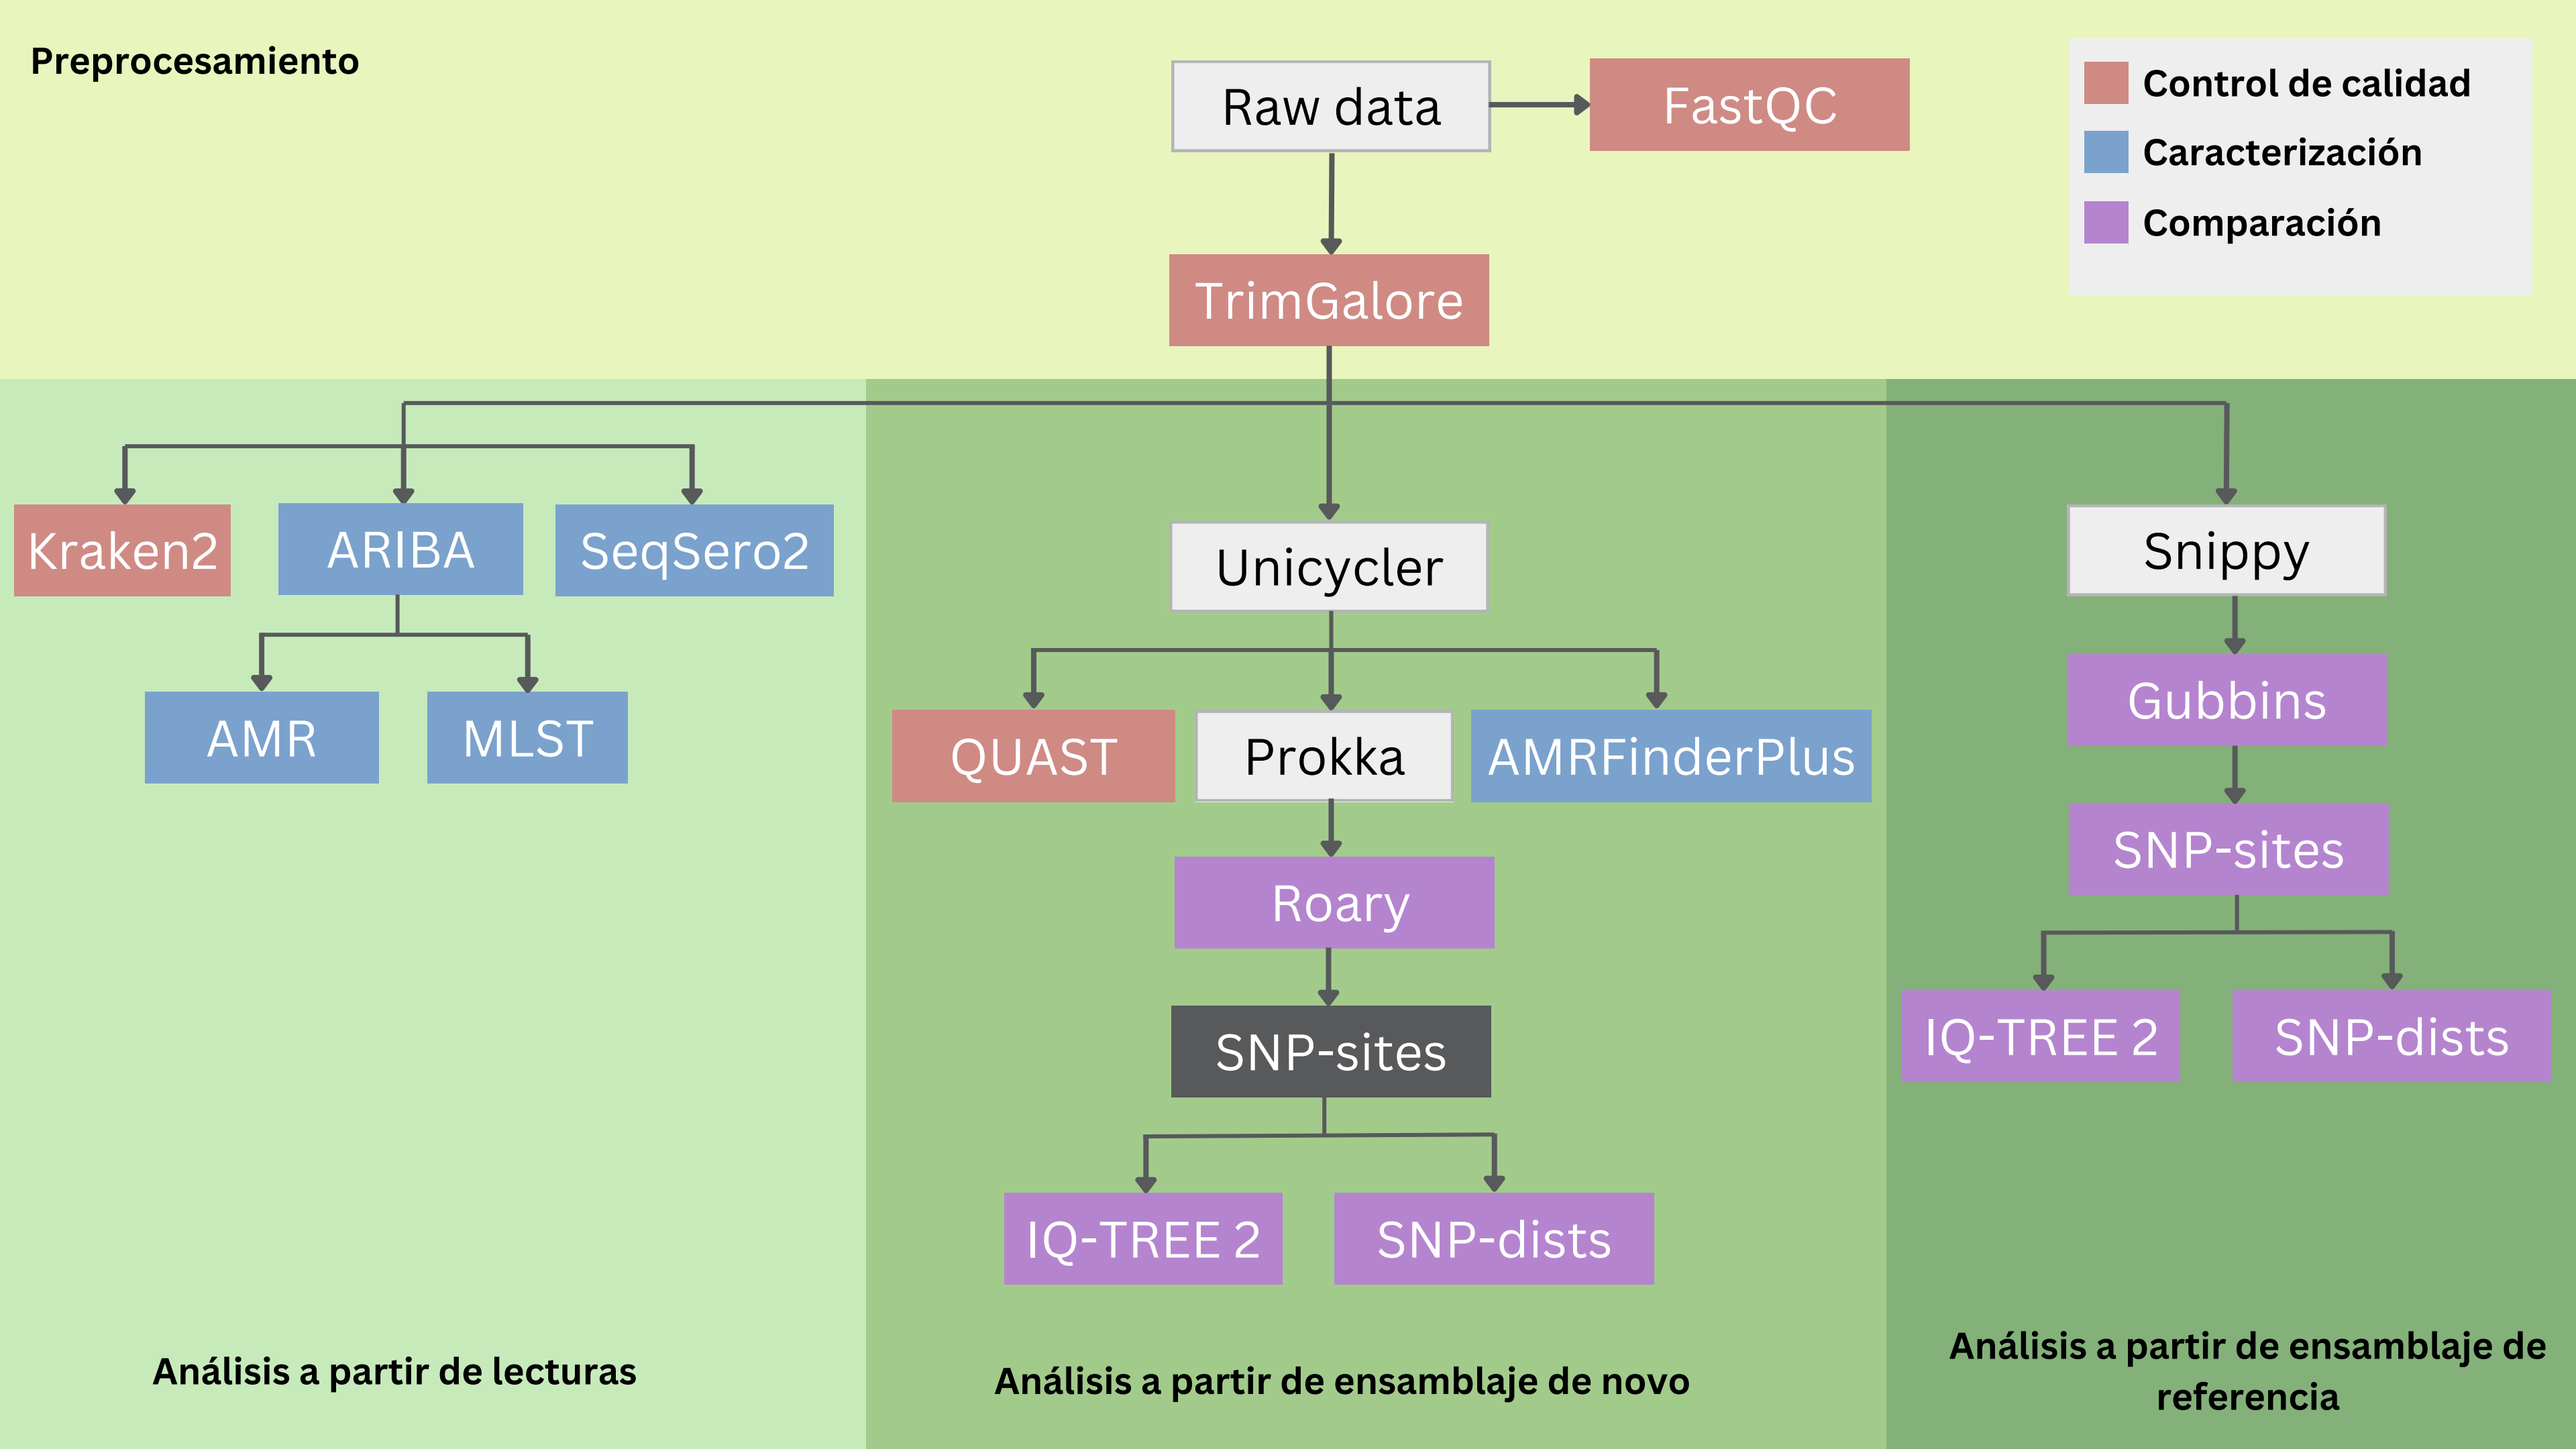
Preprocesamiento
Raw data
FastQC
Control de calidad
Caracterización
Comparación
TrimGalore
Kraken2
ARIBA
SeqSero2
AMR
MLST
Unicycler
QUAST
Prokka
AMRFinderPlus
Roary
SNP-sites
IQ-TREE 2
SNP-dists
Snippy
Gubbins
SNP-sites
IQ-TREE 2
SNP-dists
Análisis a partir de lecturas
Análisis a partir de ensamblaje de novo
Análisis a partir de ensamblaje de referencia

SNP-sites

core alignment

```
ATGCTAGCTAGCTAGC
ATGCTTGCTAGCTAGC
ATGCTAGCTAGCTTGC
```

SNP-sites

core alignment

```
>g1
ATGCTA
>g2
ATGCTT
>g3
ATGCTA
```

SNP-sites

Columna por columna

core alignment

>g1
ATGCTA
>g2
ATGCTT
>g3
ATGCTA

SNP-sites

core alignment

>g1
ATGCTA
>g2
ATGCTT
>g3
ATGCTA

Columna por columna

Columna 1

g1: A
g2: A
g3: A

si tamaño del conjunto = 1
No SNP

{A,} → tamaño = 1

SNP-sites

core alignment

>g1
ATGCT**A**
>g2
ATGCT**T**
>g3
ATGCT**A**

Columna por columna

Columna 6

g1: A
g2: T
g3: A

si tamaño del conjunto > 1
SNP

SNP-sites

Si una columna es SNP:

- Se guarda su posición
- Se agrega al nuevo alineamiento

SNP-sites

Si una columna es SNP:

- Se guarda su posición
- Se agrega al nuevo alineamiento

Entrada	Salida
ATGCTA	A
ATGCTT	T
ATGCTA	A

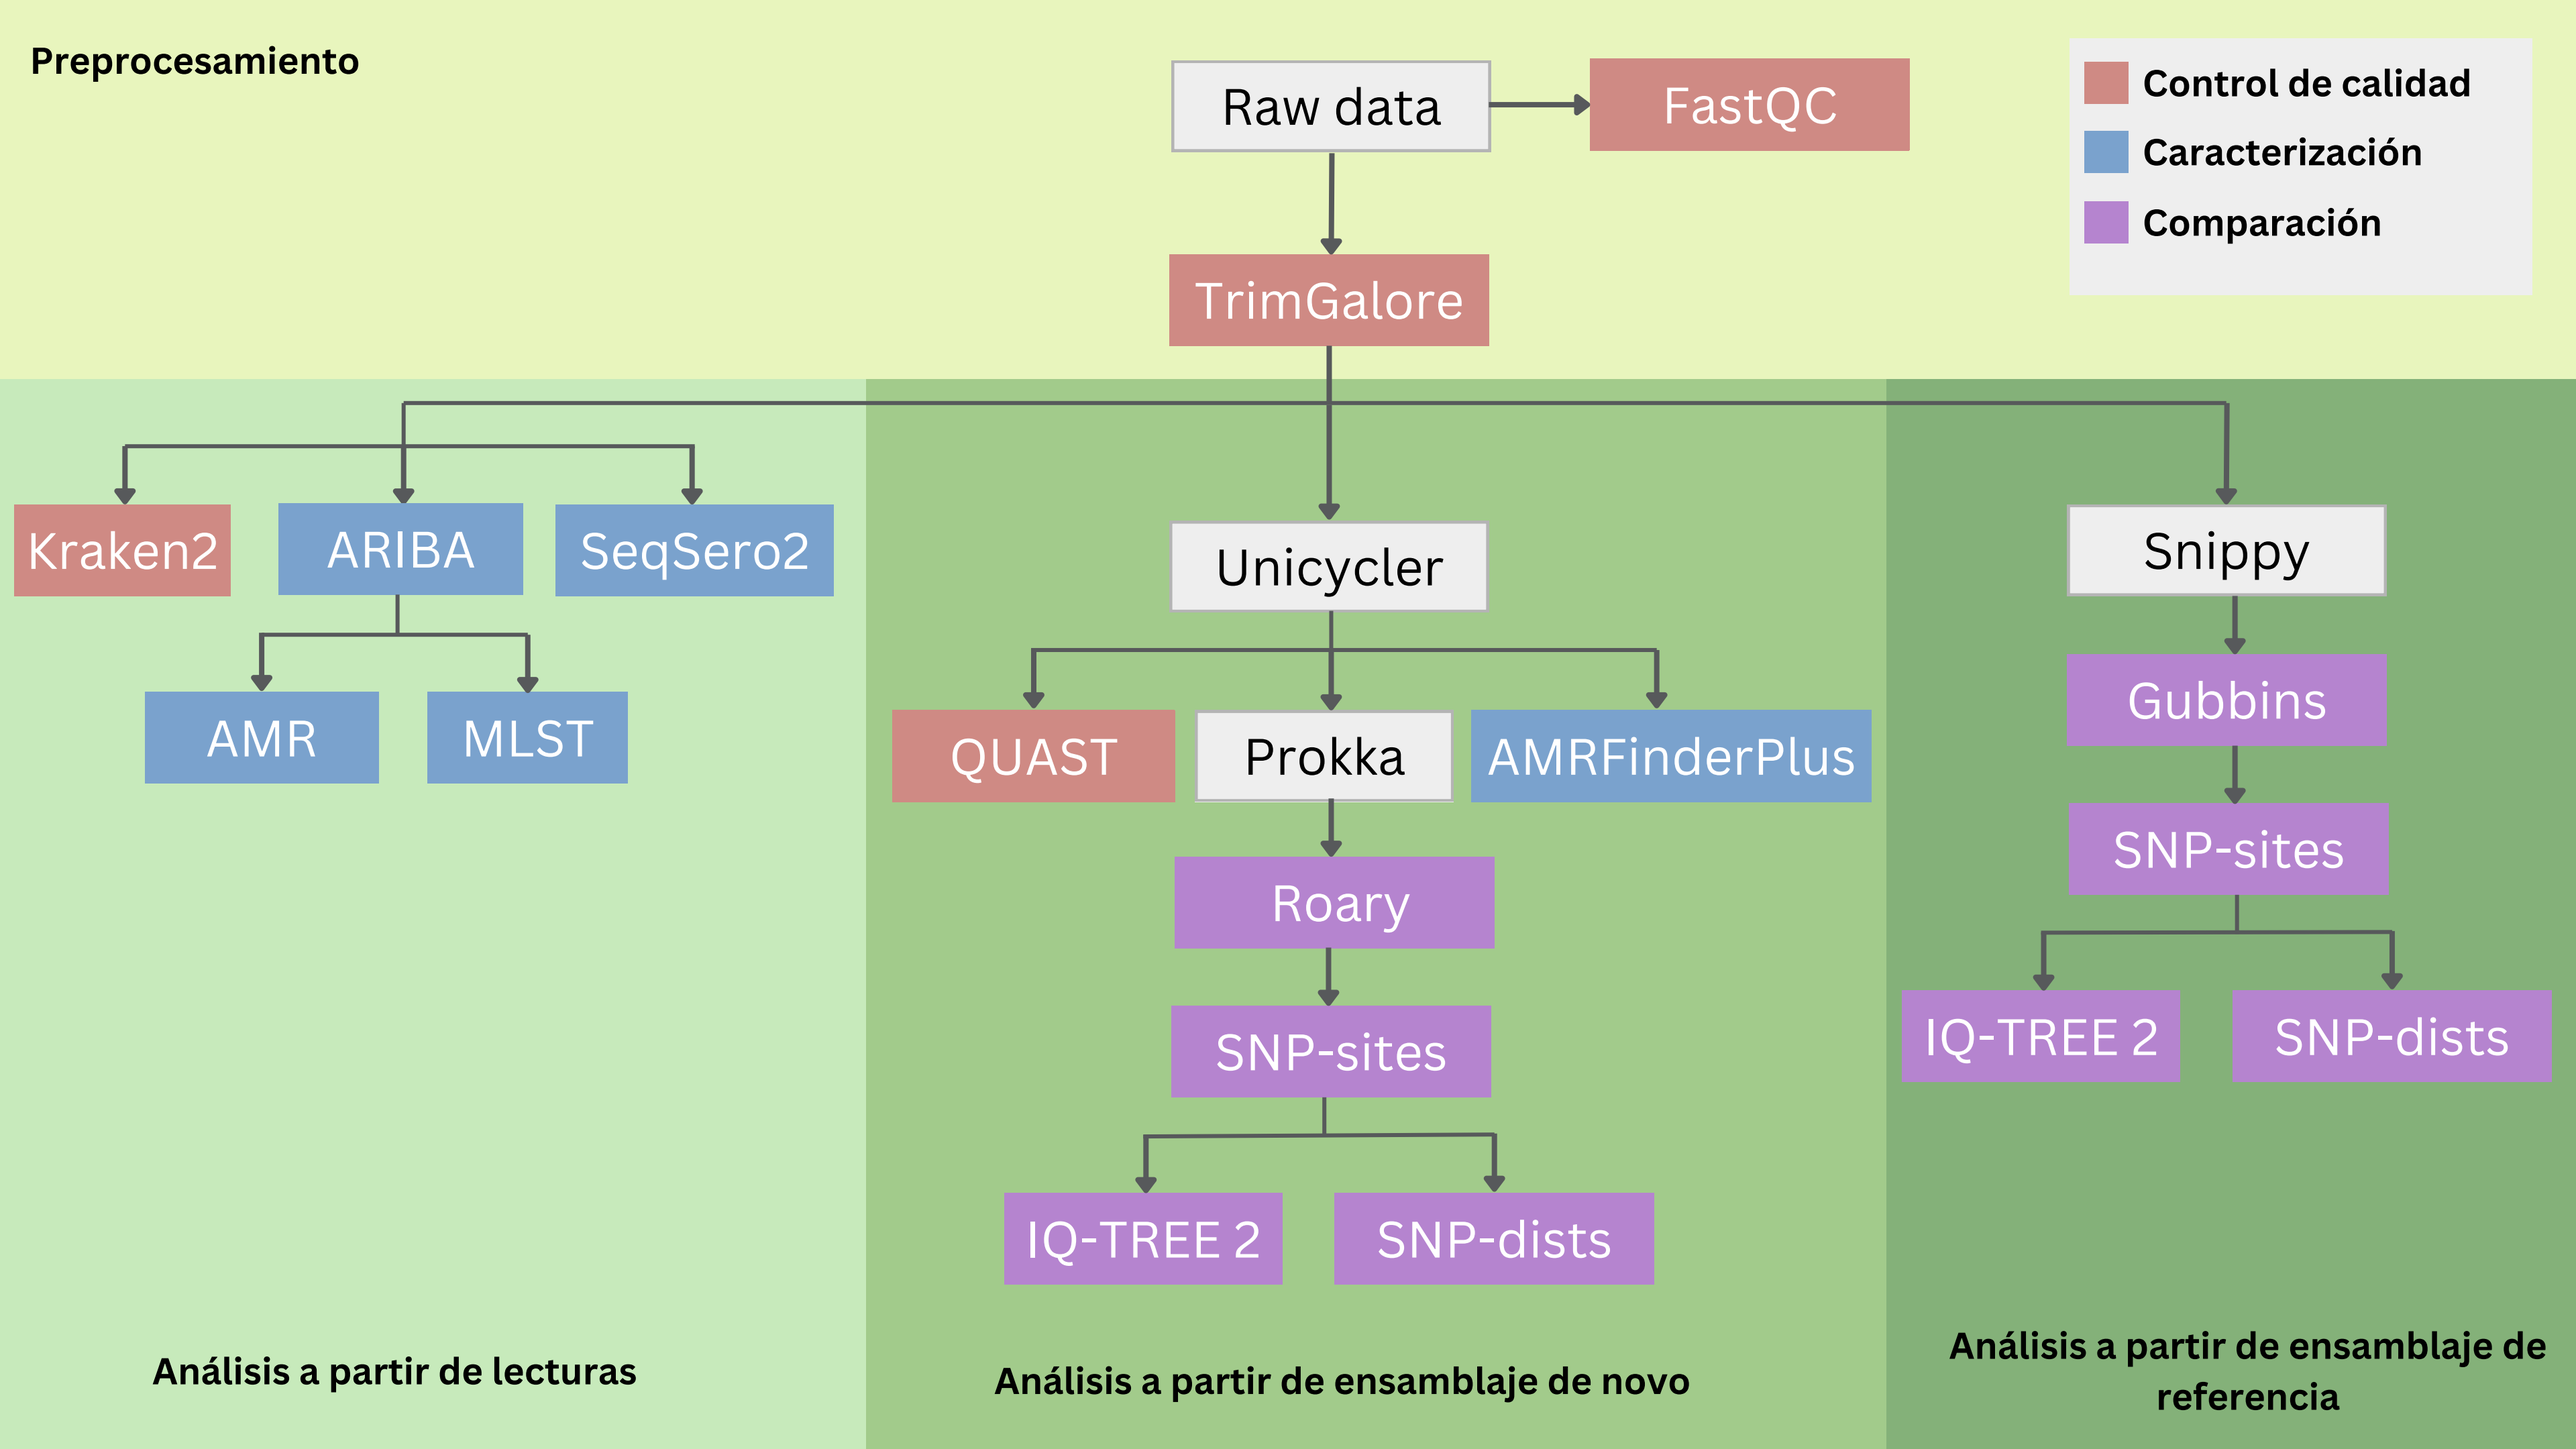
Preprocesamiento
Raw data
FastQC
Control de calidad
Caracterización
Comparación
TrimGalore
Kraken2
ARIBA
SeqSero2
AMR
MLST
Unicycler
QUAST
Prokka
AMRFinderPlus
Roary
SNP-sites
IQ-TREE 2
SNP-dists
Snippy
Gubbins
SNP-sites
IQ-TREE 2
SNP-dists
Análisis a partir de lecturas
Análisis a partir de ensamblaje de novo
Análisis a partir de ensamblaje de referencia

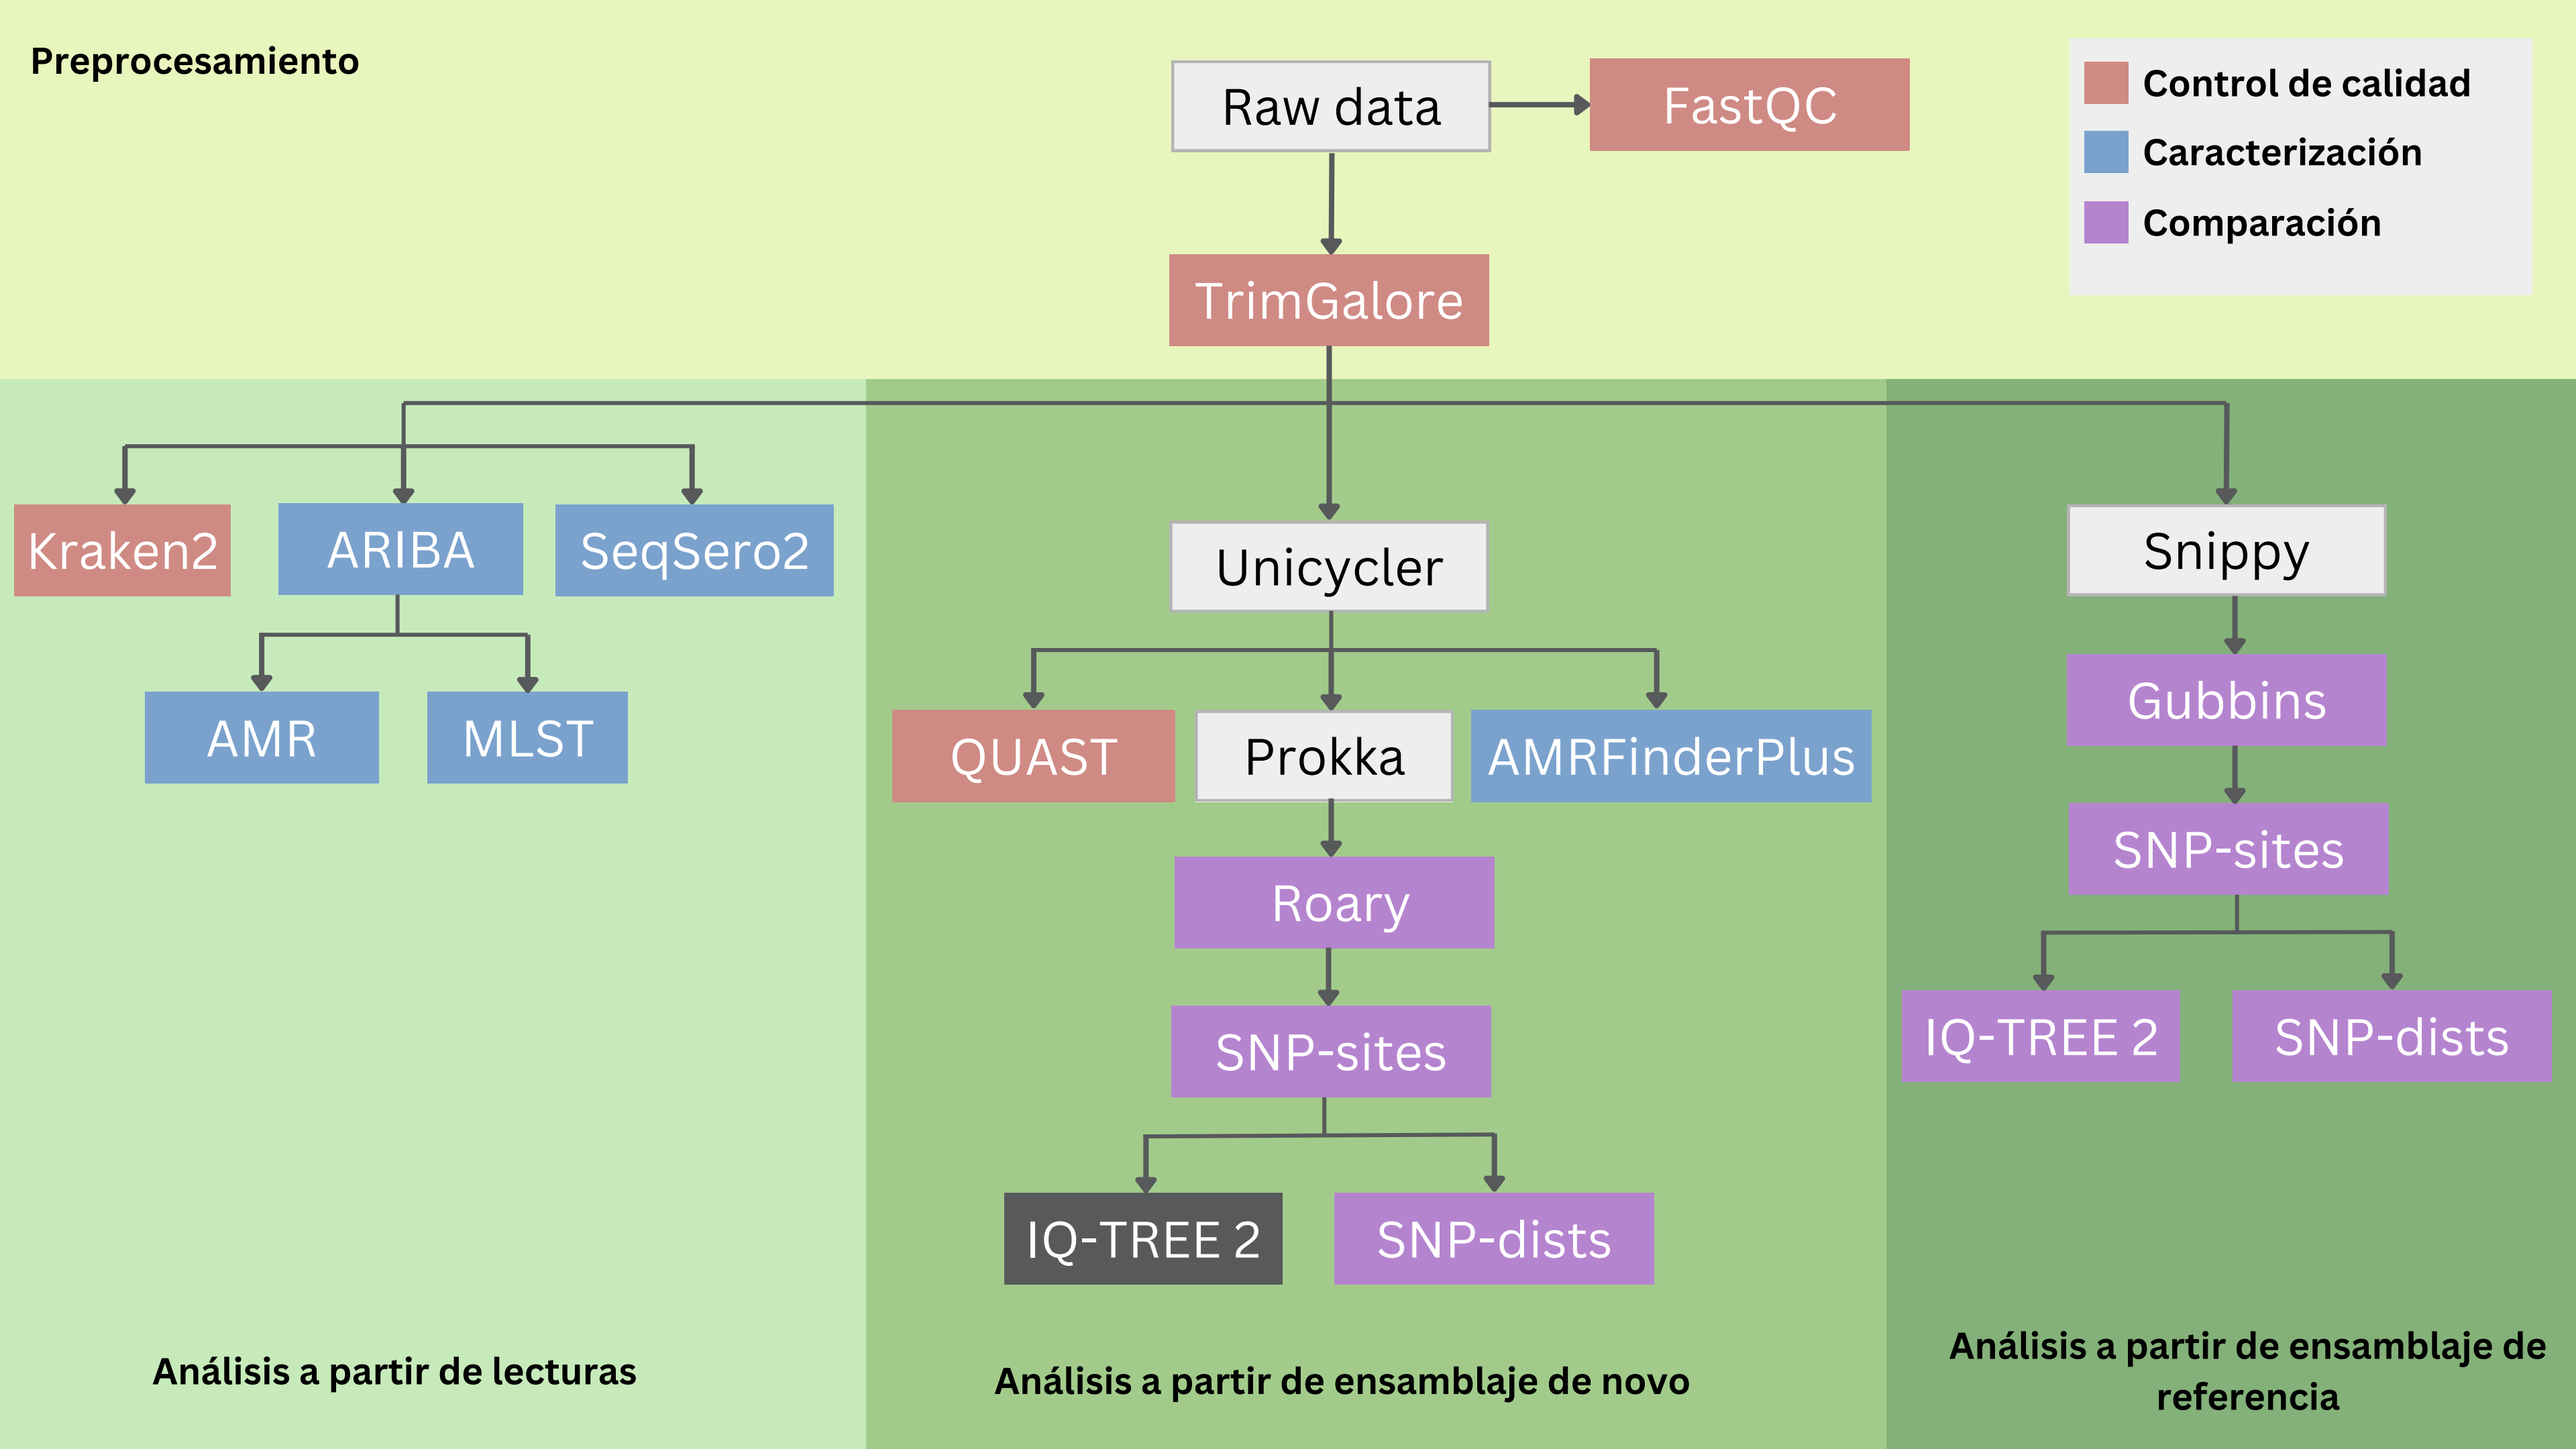
Preprocesamiento
Raw data
FastQC
Control de calidad
Caracterización
Comparación
TrimGalore
Kraken2
ARIBA
SeqSero2
AMR
MLST
Unicycler
QUAST
Prokka
AMRFinderPlus
Roary
SNP-sites
IQ-TREE 2
SNP-dists
Snippy
Gubbins
SNP-sites
IQ-TREE 2
SNP-dists
Análisis a partir de lecturas
Análisis a partir de ensamblaje de novo
Análisis a partir de ensamblaje de referencia

IQ-TREE 2

Maximum likelihood (ML)

1. Se propone un árbol filogenético (una hipótesis).
2. Se asume un modelo de evolución (cómo cambian las secuencias).
3. Se calcula la probabilidad de observar los datos reales bajo ese árbol y ese modelo.
4. Se repite con muchos árboles posibles.
5. Se elige el árbol con la mayor probabilidad (likelihood).

IQ-TREE 2

Maximum likelihood (ML)

Alineamiento

A: AT
B: AT
C: TT
D: TA

IQ-TREE 2

Maximum likelihood (ML)

Alineamiento

A: AT
B: AT
C: TT
D: TA

Propone árboles candidatos

Tree1: ((A,B),(C,D))
Tree2: ((A,C),(B,D))
Tree3: ((A,D),(B,C))

IQ-TREE 2

Maximum likelihood (ML)

Alineamiento

A: AT
B: AT
C: TT
D: TA

Evaluar cada árbol (Maximum Likelihood)

Posición 1

A: A
B: A
C: T
D: T

IQ-TREE 2

Maximum likelihood (ML)

Alineamiento

A: AT
B: AT
C: TT
D: TA

Evaluar cada árbol (Maximum Likelihood)

Posición 1

A: A
B: A
C: T
D: T

A y B iguales
C y D iguales

IQ-TREE 2

Maximum likelihood (ML)

Alineamiento

A: AT
B: AT
C: TT
D: TA

Evaluar cada árbol (Maximum Likelihood)

Tree1: ((A,B),(C,D))

A y B vienen de un ancestro común (sin cambio)

C y D vienen de otro (sin cambio)

Solo 1 cambio entre grupos

IQ-TREE 2

Maximum likelihood (ML)

Alineamiento

A: AT
B: AT
C: TT
D: TA

Muy probable

Evaluar cada árbol (Maximum Likelihood)

Tree1: ((A,B),(C,D))

A y B vienen de un ancestro común (sin cambio)

C y D vienen de otro (sin cambio)

Solo 1 cambio entre grupos

IQ-TREE 2

Maximum likelihood (ML)

Alineamiento

A: AT
B: AT
C: TT
D: TA

Menos probable

Evaluar cada árbol (Maximum Likelihood)

Tree2: ((A,C),(B,D))

A vs C son diferentes

B vs D son diferentes

Necesita más cambios

IQ-TREE 2

Maximum likelihood (ML)

Alineamiento

A: AT
B: AT
C: TT
D: TA

Menos probable

Evaluar cada árbol (Maximum Likelihood)

Tree3: ((A,D),(B,C))

A vs D son diferentes

B vs C son diferentes

Necesita más cambios

IQ-TREE 2

Maximum likelihood (ML)

Alineamiento

A: AT
B: AT
C: TT
D: TA

Selección del mejor árbol

Tree1: ((A,B),(C,D))

IQ-TREE 2

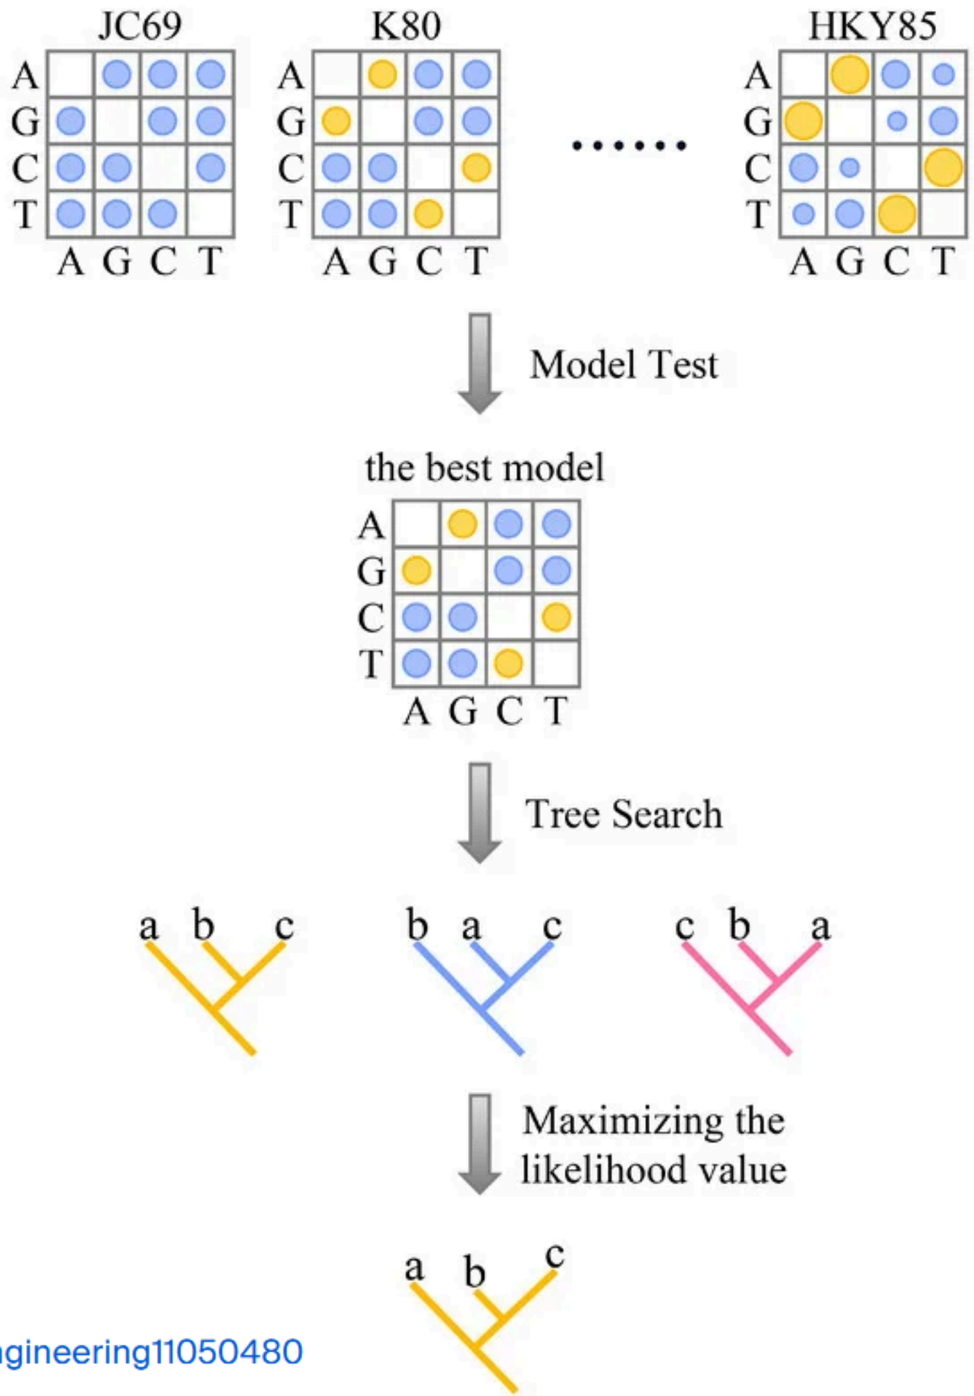

Bioengineering **2024**, *11*(5), 480; https://doi.org/10.3390/bioengineering11050480

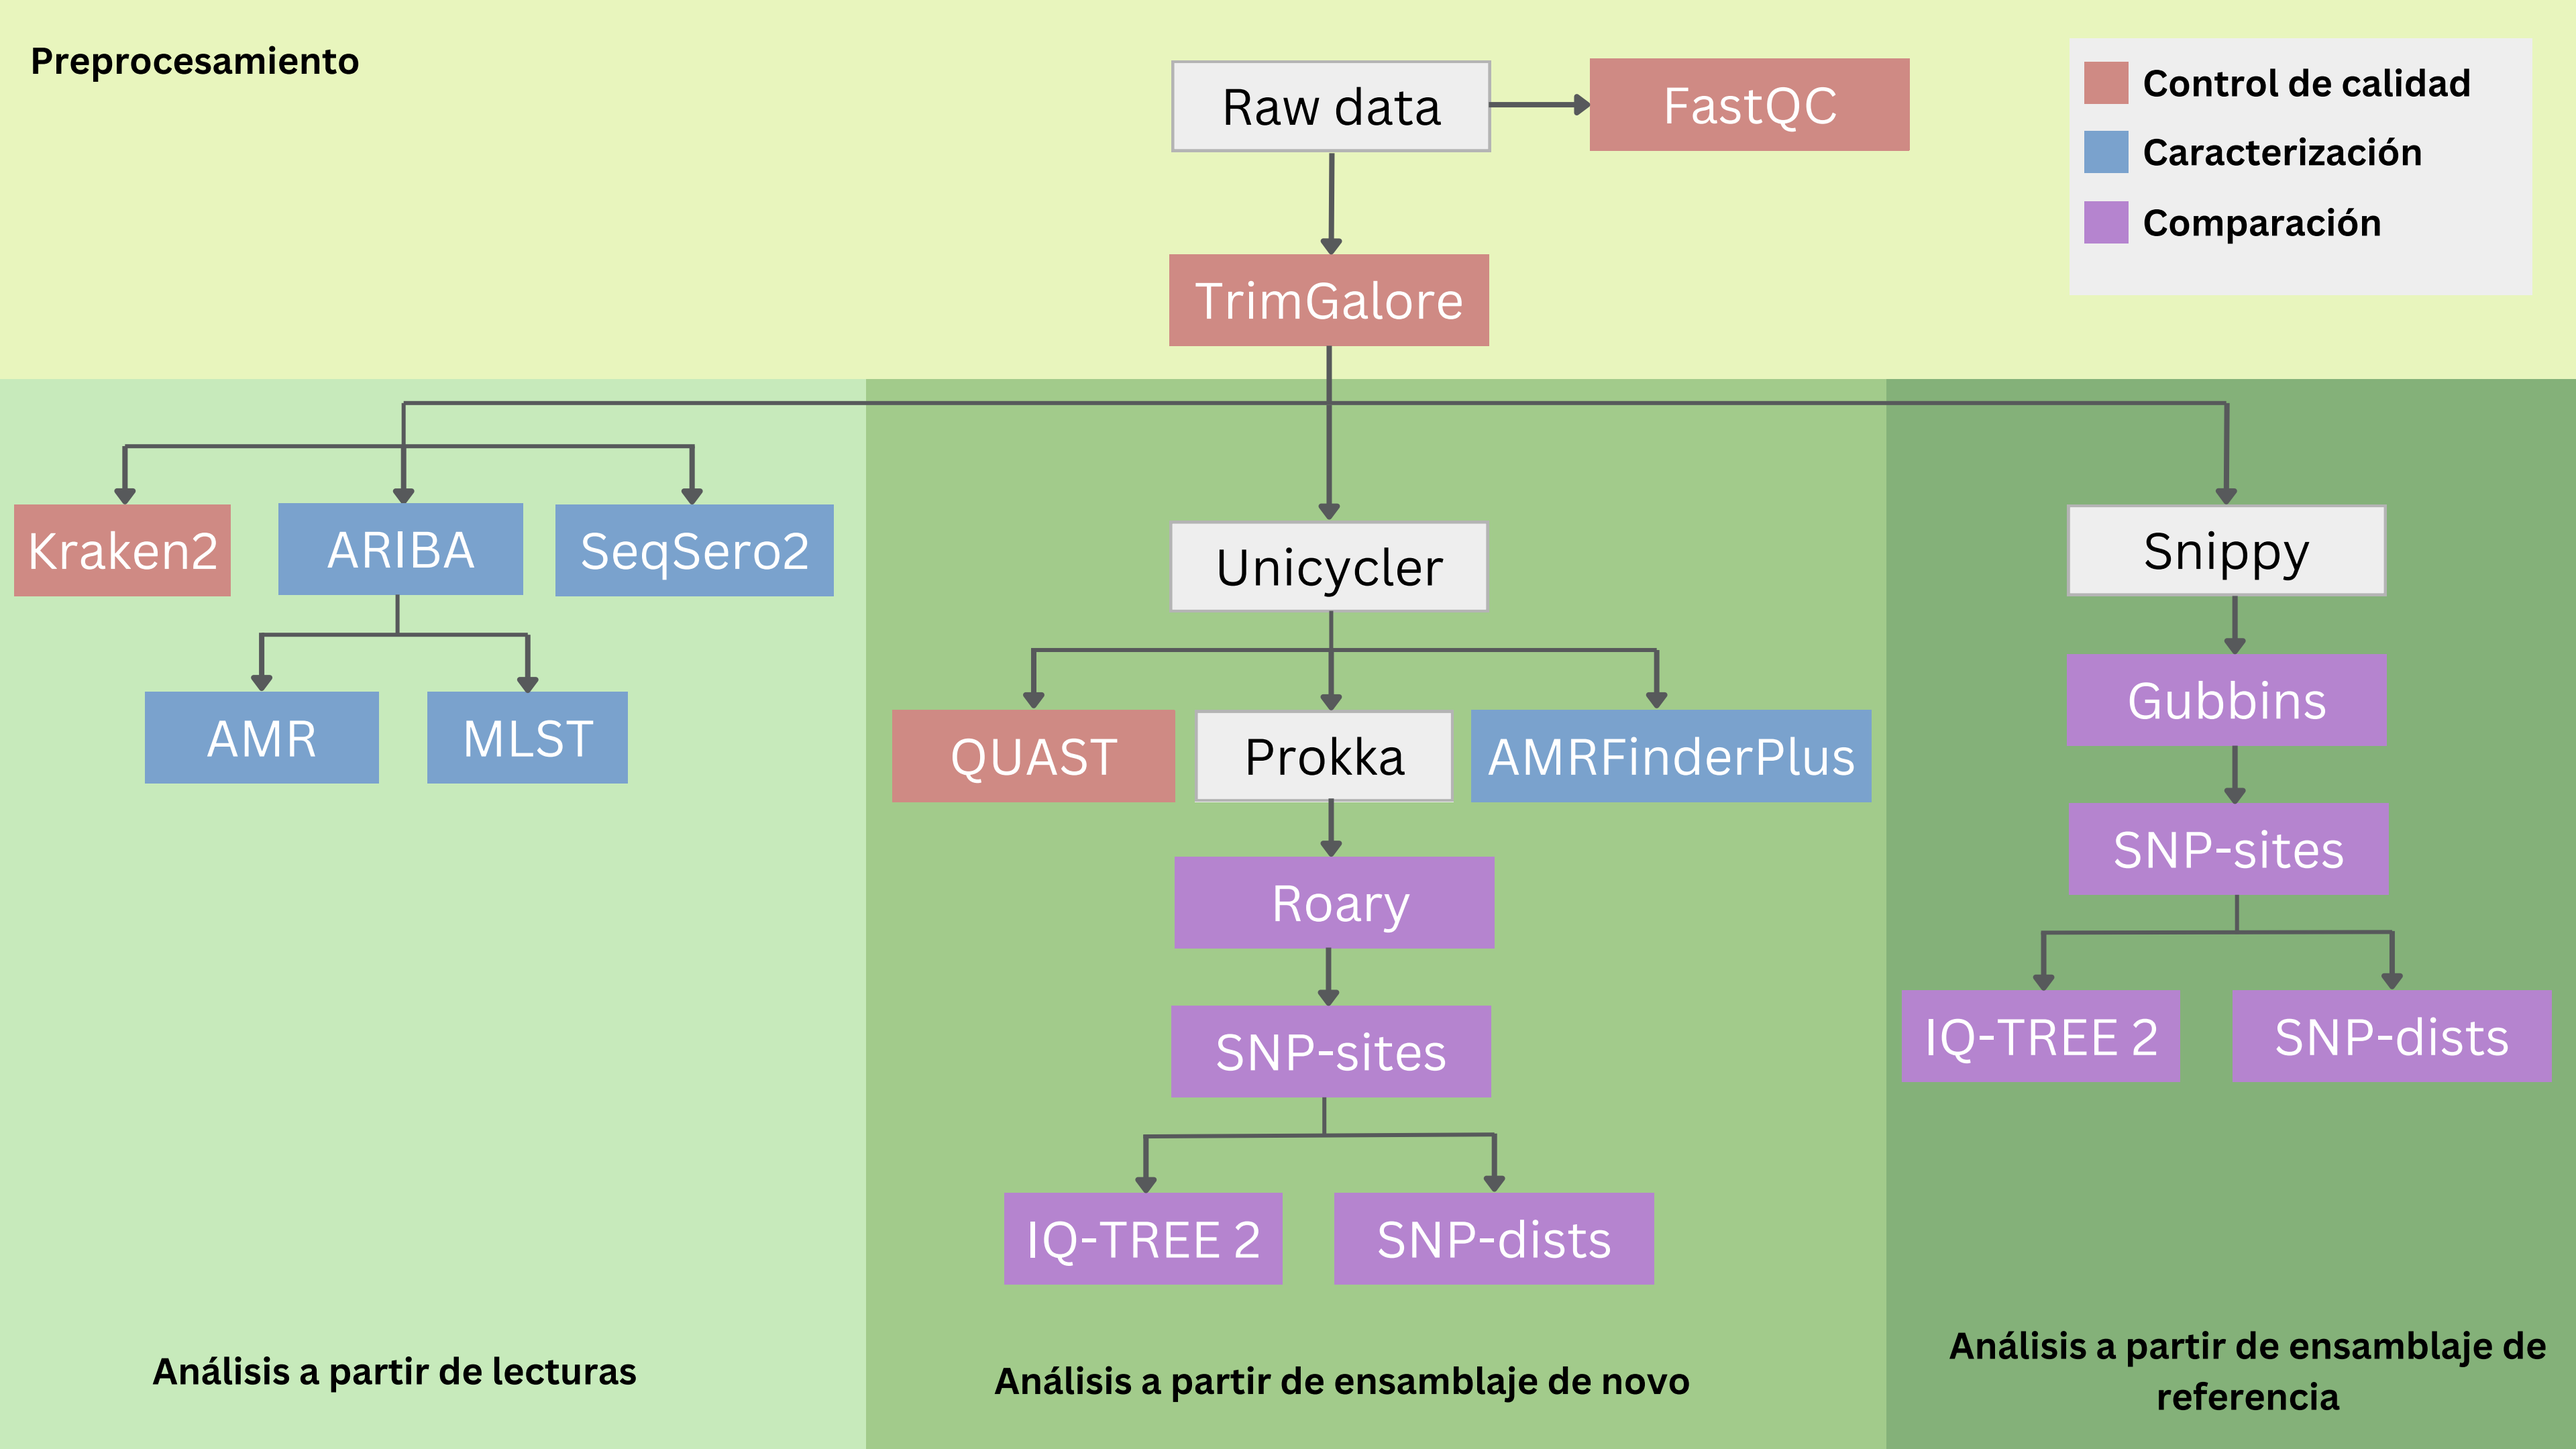
Preprocesamiento
Raw data
FastQC
Control de calidad
Caracterización
Comparación
TrimGalore
Kraken2
ARIBA
SeqSero2
AMR
MLST
Unicycler
QUAST
Prokka
AMRFinderPlus
Roary
SNP-sites
IQ-TREE 2
SNP-dists
Snippy
Gubbins
SNP-sites
IQ-TREE 2
SNP-dists
Análisis a partir de lecturas
Análisis a partir de ensamblaje de novo
Análisis a partir de ensamblaje de referencia

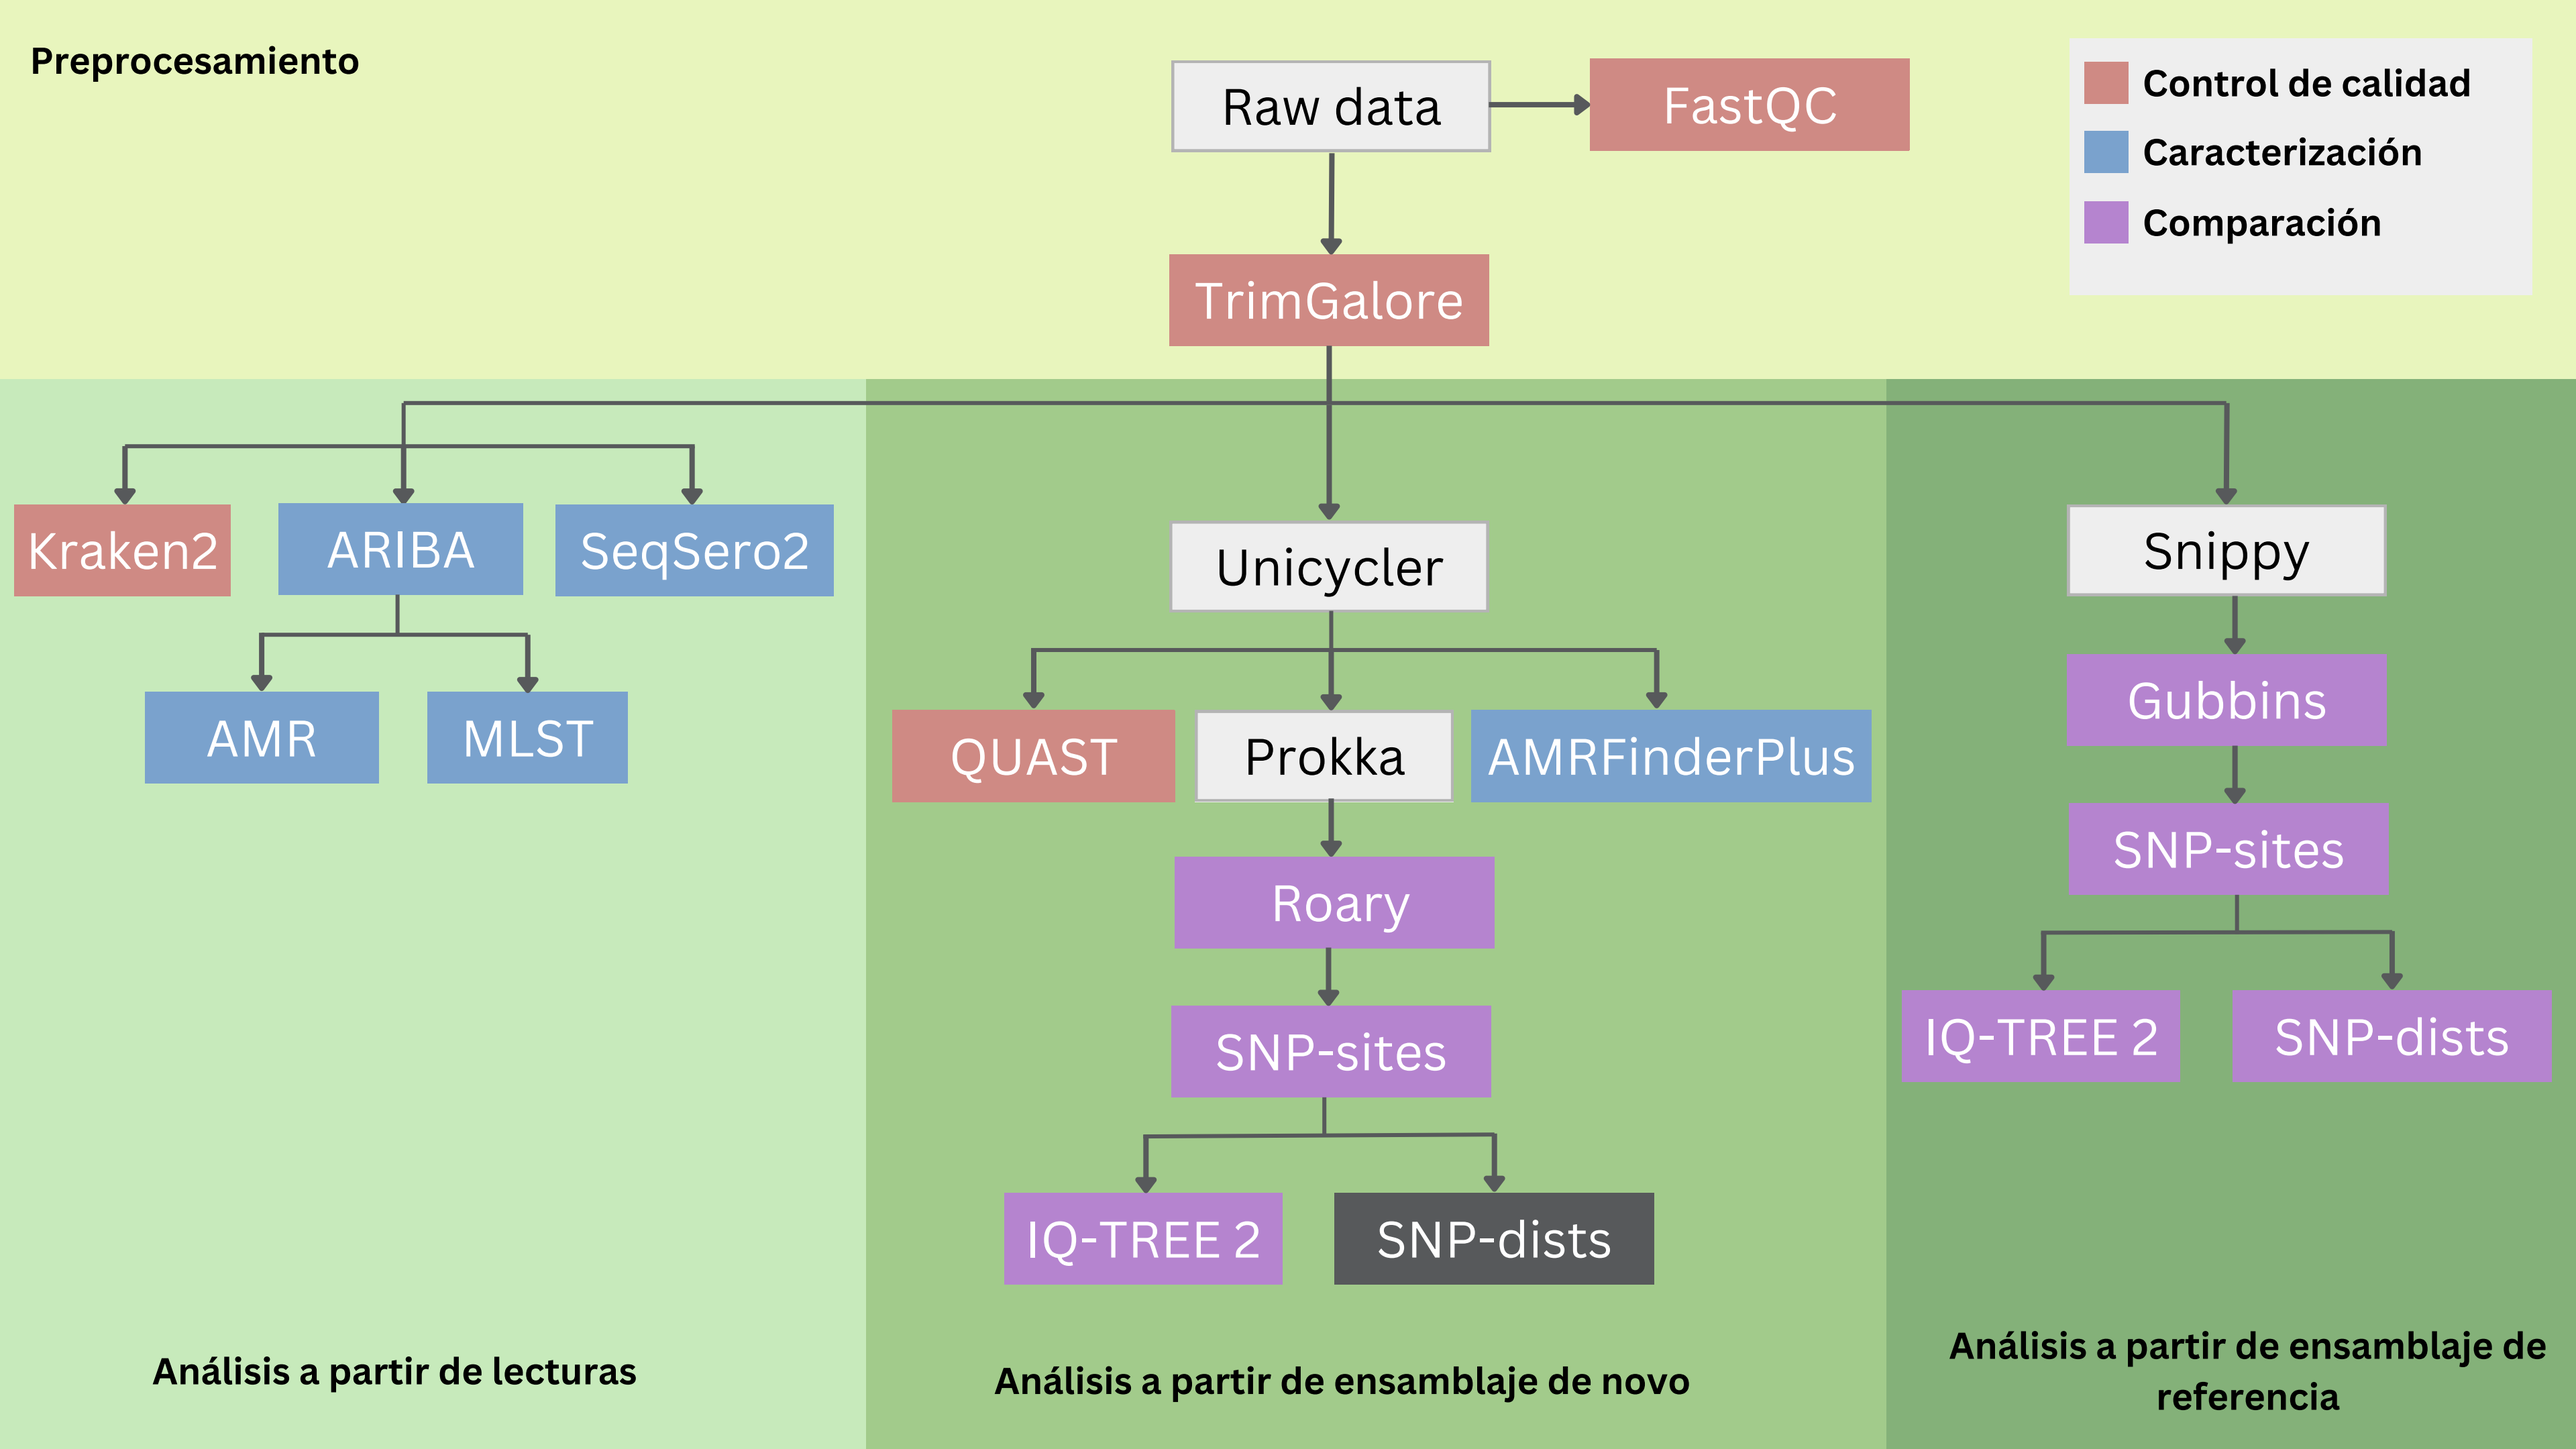
Preprocesamiento
Raw data
FastQC
Control de calidad
Caracterización
Comparación
TrimGalore
Kraken2
ARIBA
SeqSero2
AMR
MLST
Unicycler
QUAST
Prokka
AMRFinderPlus
Roary
SNP-sites
IQ-TREE 2
SNP-dists
Snippy
Gubbins
SNP-sites
IQ-TREE 2
SNP-dists
Análisis a partir de lecturas
Análisis a partir de ensamblaje de novo
Análisis a partir de ensamblaje de referencia

SNP-dists

Calcula la distancia genética entre pares de secuencias

Alineamiento

>g1
AT
>g2
TT
>g3
AT

SNP-dists

Calcula la distancia genética entre pares de secuencias

Alineamiento

>g1
AT
>g2
TT
>g3
AT

Comparación g1 vs g2

g1: A T
g2: T T

SNP-dists

Calcula la distancia genética entre pares de secuencias

Alineamiento

>g1
AT
>g2
TT
>g3
AT

Comparación g1 vs g2

g1: A T
g2: T T

Posición 1

Diferentes

SNP-dists

Calcula la distancia genética entre pares de secuencias

Alineamiento

>g1
AT
>g2
TT
>g3
AT

Comparación g1 vs g2

g1: A T
g2: T T

Posición 1	Posición 2
Diferentes	Iguales

SNP-dists

Calcula la distancia genética entre pares de secuencias

Alineamiento

>g1
AT
>g2
TT
>g3
AT

Comparación g1 vs g2

g1: A T
g2: T T

Posición 1	Posición 2
Diferentes	Iguales

Distancia
1 SNP

SNP-dists

Calcula la distancia genética entre pares de secuencias

Alineamiento

>g1
AT
>g2
TT
>g3
AT

Comparación g1 vs g3

g1: A T
g3: A T

Distancia
0 SNP

SNP-dists

Calcula la distancia genética entre pares de secuencias

Alineamiento

>g1
AT
>g2
TT
>g3
AT

Comparación g2 vs g3

g2: T T
g3: A T

Distancia
1 SNP

SNP-dists

Matriz de distancias

	g1	**g2**	**g3**
g1	0	1	0
g2	1	0	1
g3	0	1	0

Capacitación en Secuenciación por NGS y análisis bioinformático de *Salmonella* spp. para la vigilancia en salud pública

Herramientas de comparación genómica

MSc. Melany Calderón Osorno
mcalderono@inciensa.sa.cr
Laboratorio de genómica y biología molecular

Marzo, 2026